数据枯竭危机与AI可持续发展

Data Exhaustion Crisis and AI Sustainability



探索AI训练数据需求与环境可持续发展之间的关键平衡。从数据消耗危机到创新解决方案，理解下一代人工智能的绿色发展路径。

GPT-4的数据饥渴

45TB训练数据量

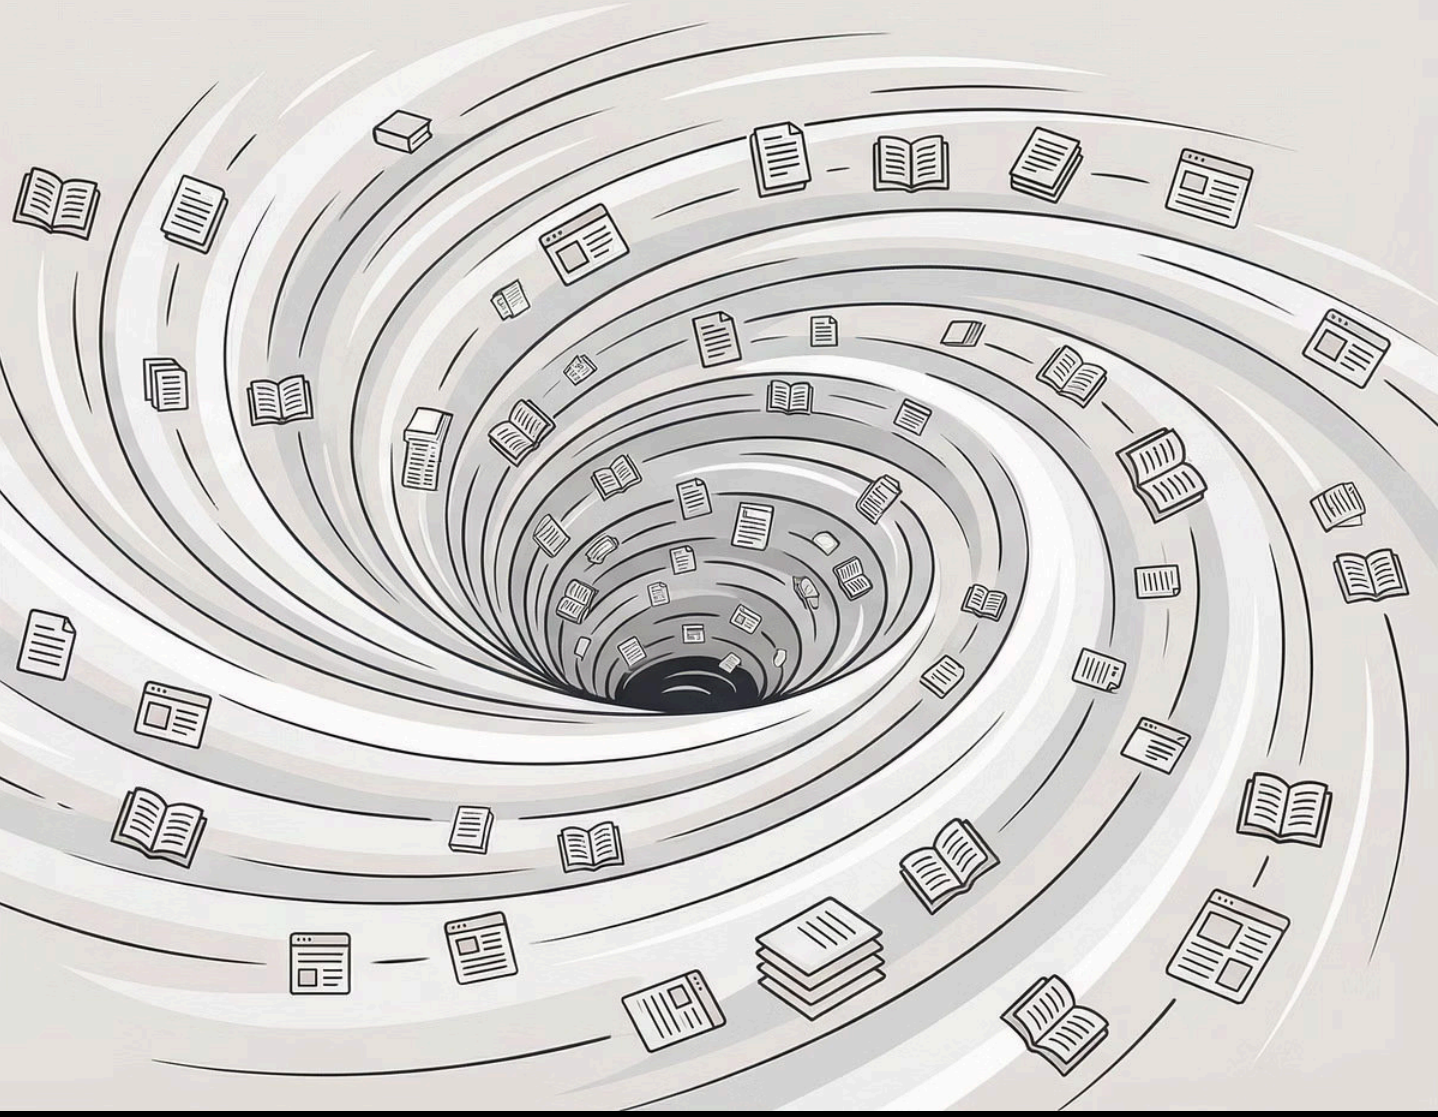
相当于全球维基百科内容的300倍

数据需求

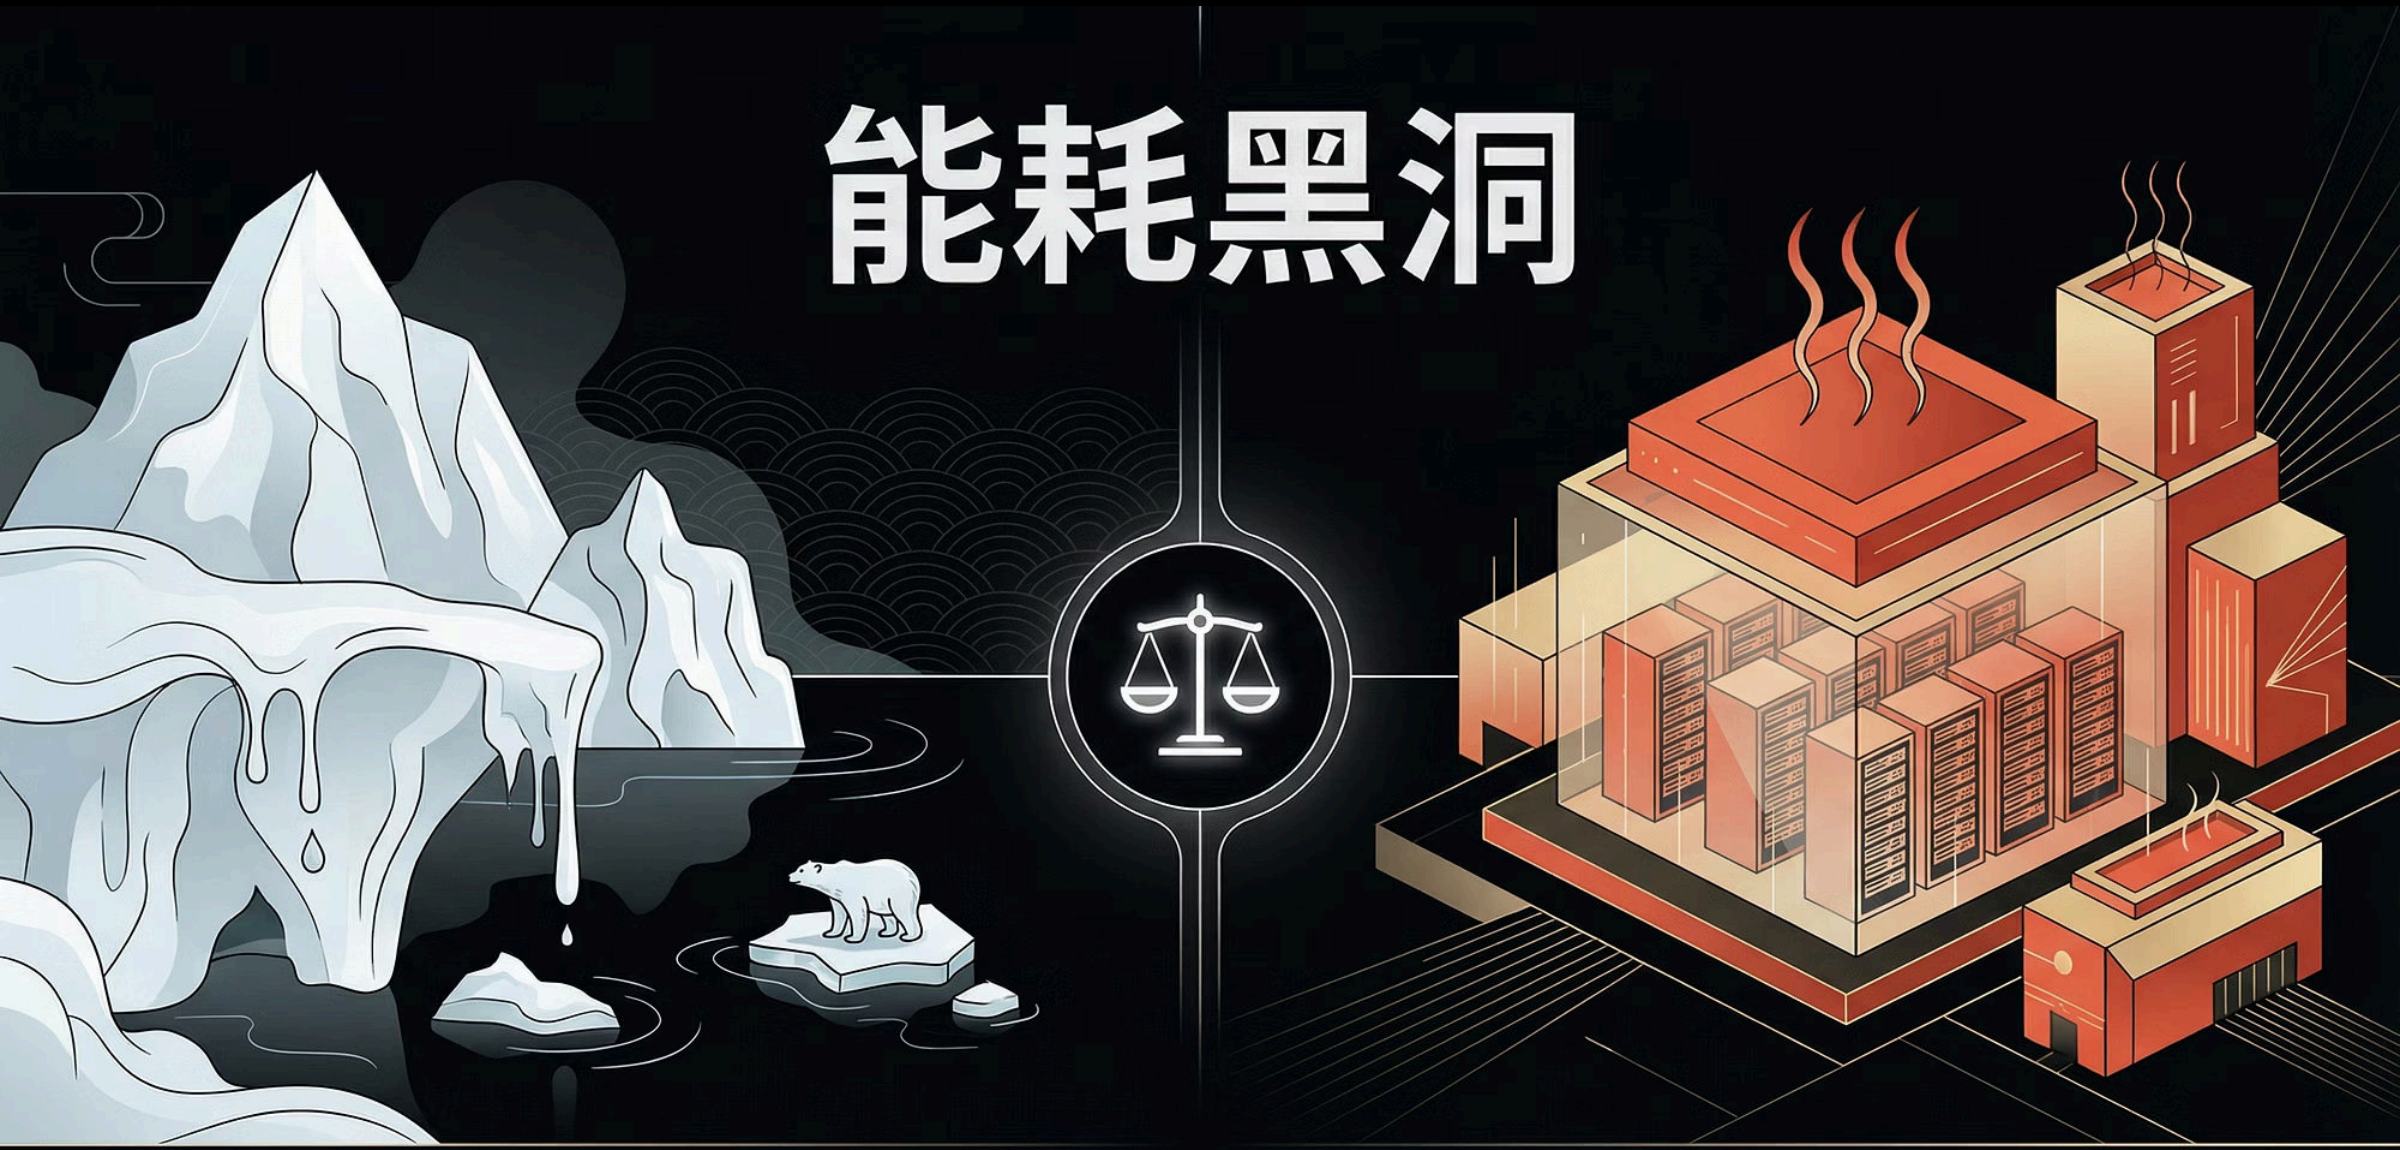
正在逼近人类文本生产的极限

到2026年

可能面临高质量训练数据的全面枯竭



能耗黑洞



训练GPT-4消耗的电力足够供应一个小城市运行半年

AI训练的碳排放量已超过整个航空业

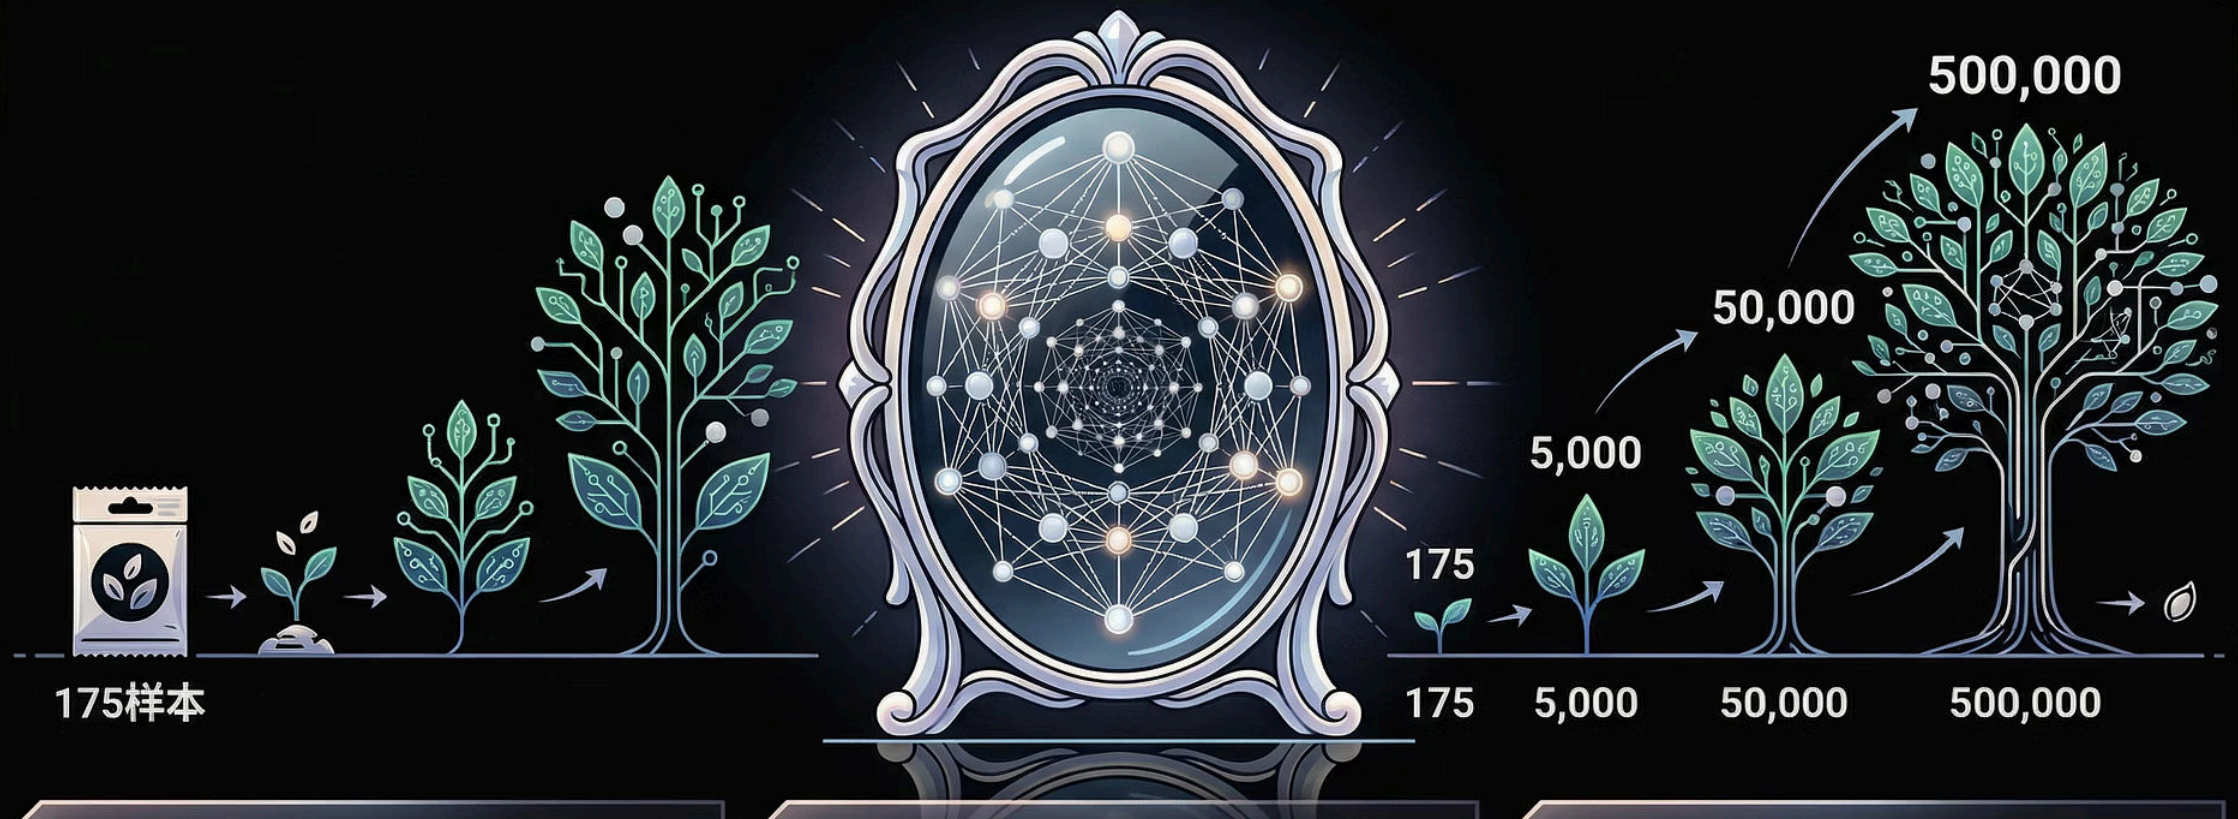
版权争议的风暴

> “我们的创作被未经授权地用于训练AI，这是对创作者权益的侵犯”

艺术家、作家与科技公司之间的激烈辩论，揭示了AI发展中的法律与道德困境



Self-Instruct：数据自我生成革命



让AI成为自己的老师，通过自我指导生成训练数据

仅用175个种子样本就能生成50万个高质量训练实例

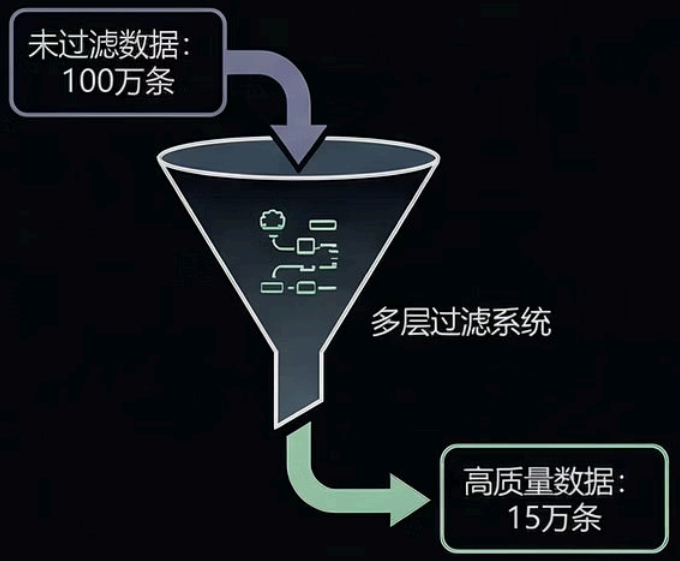
99.9%

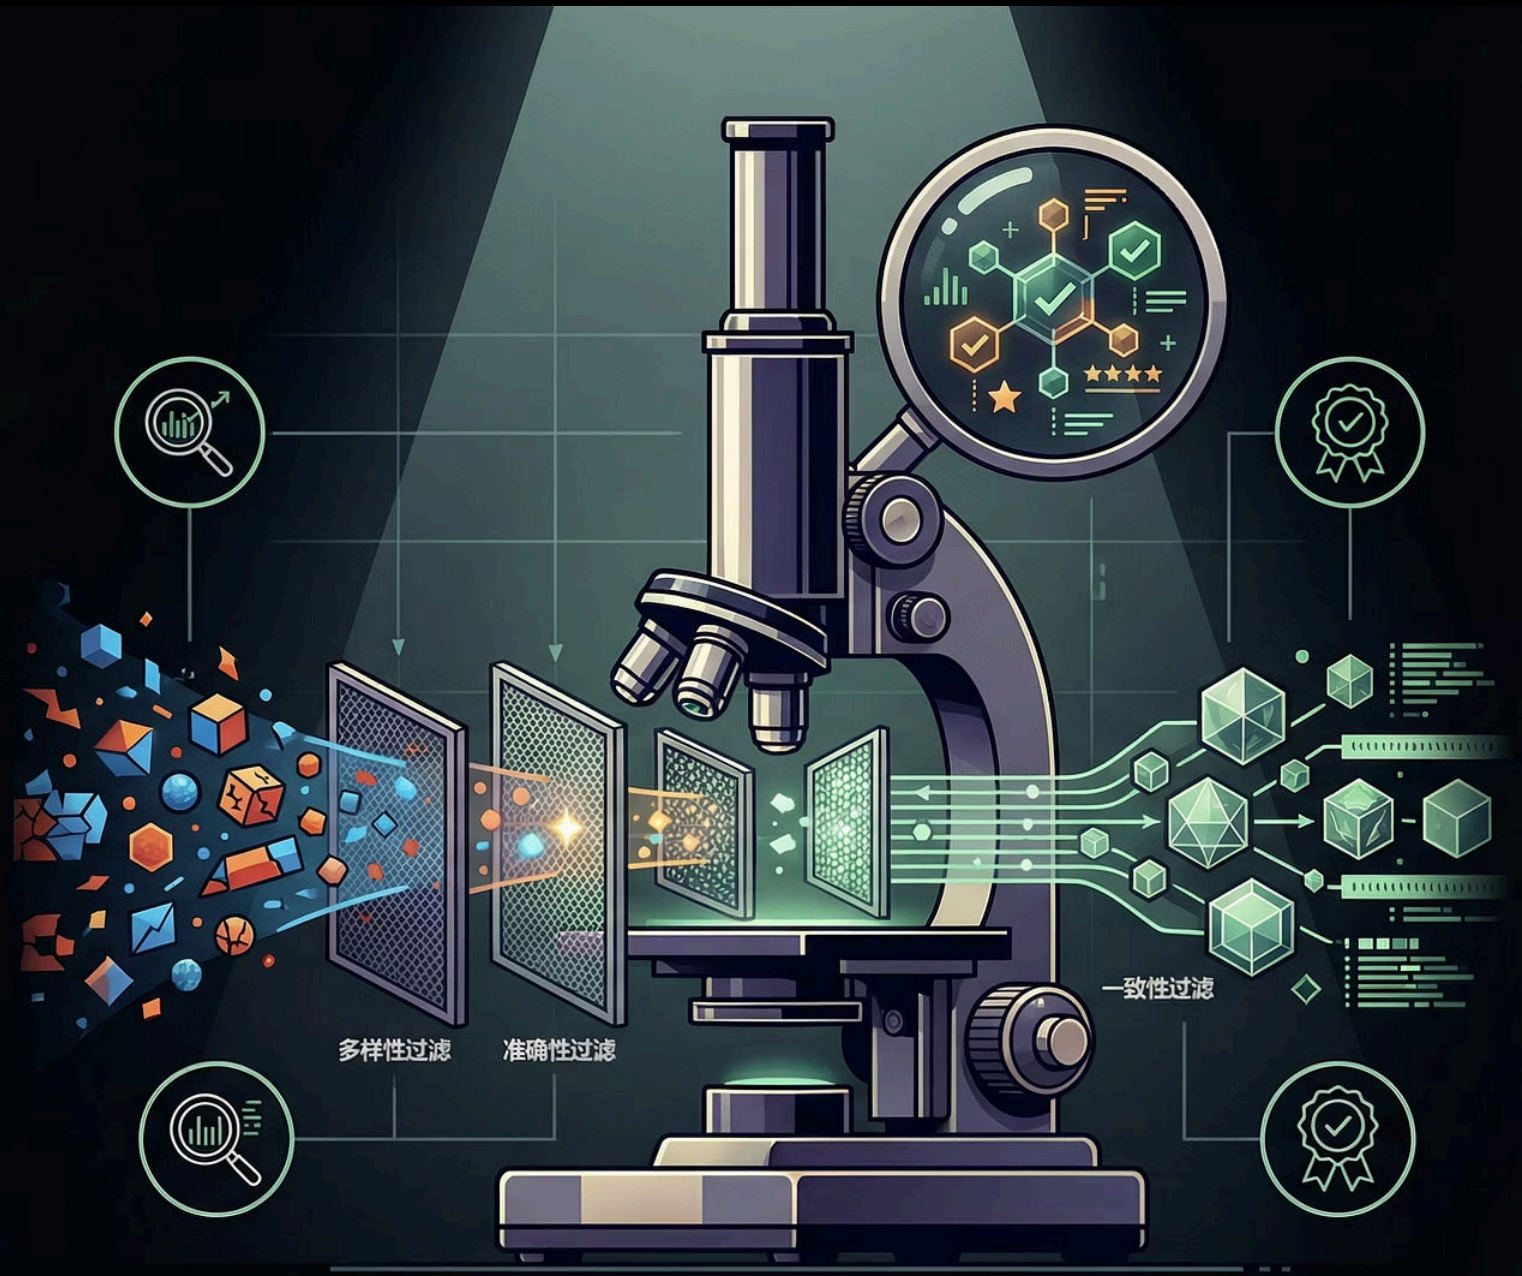
这种方法将数据需求降低了99.9%

质量控制的艺术

并非所有合成数据都是黄金，质量控制是关键环节

开发多层过滤系统，确保生成数据的准确性、一致性和多样性

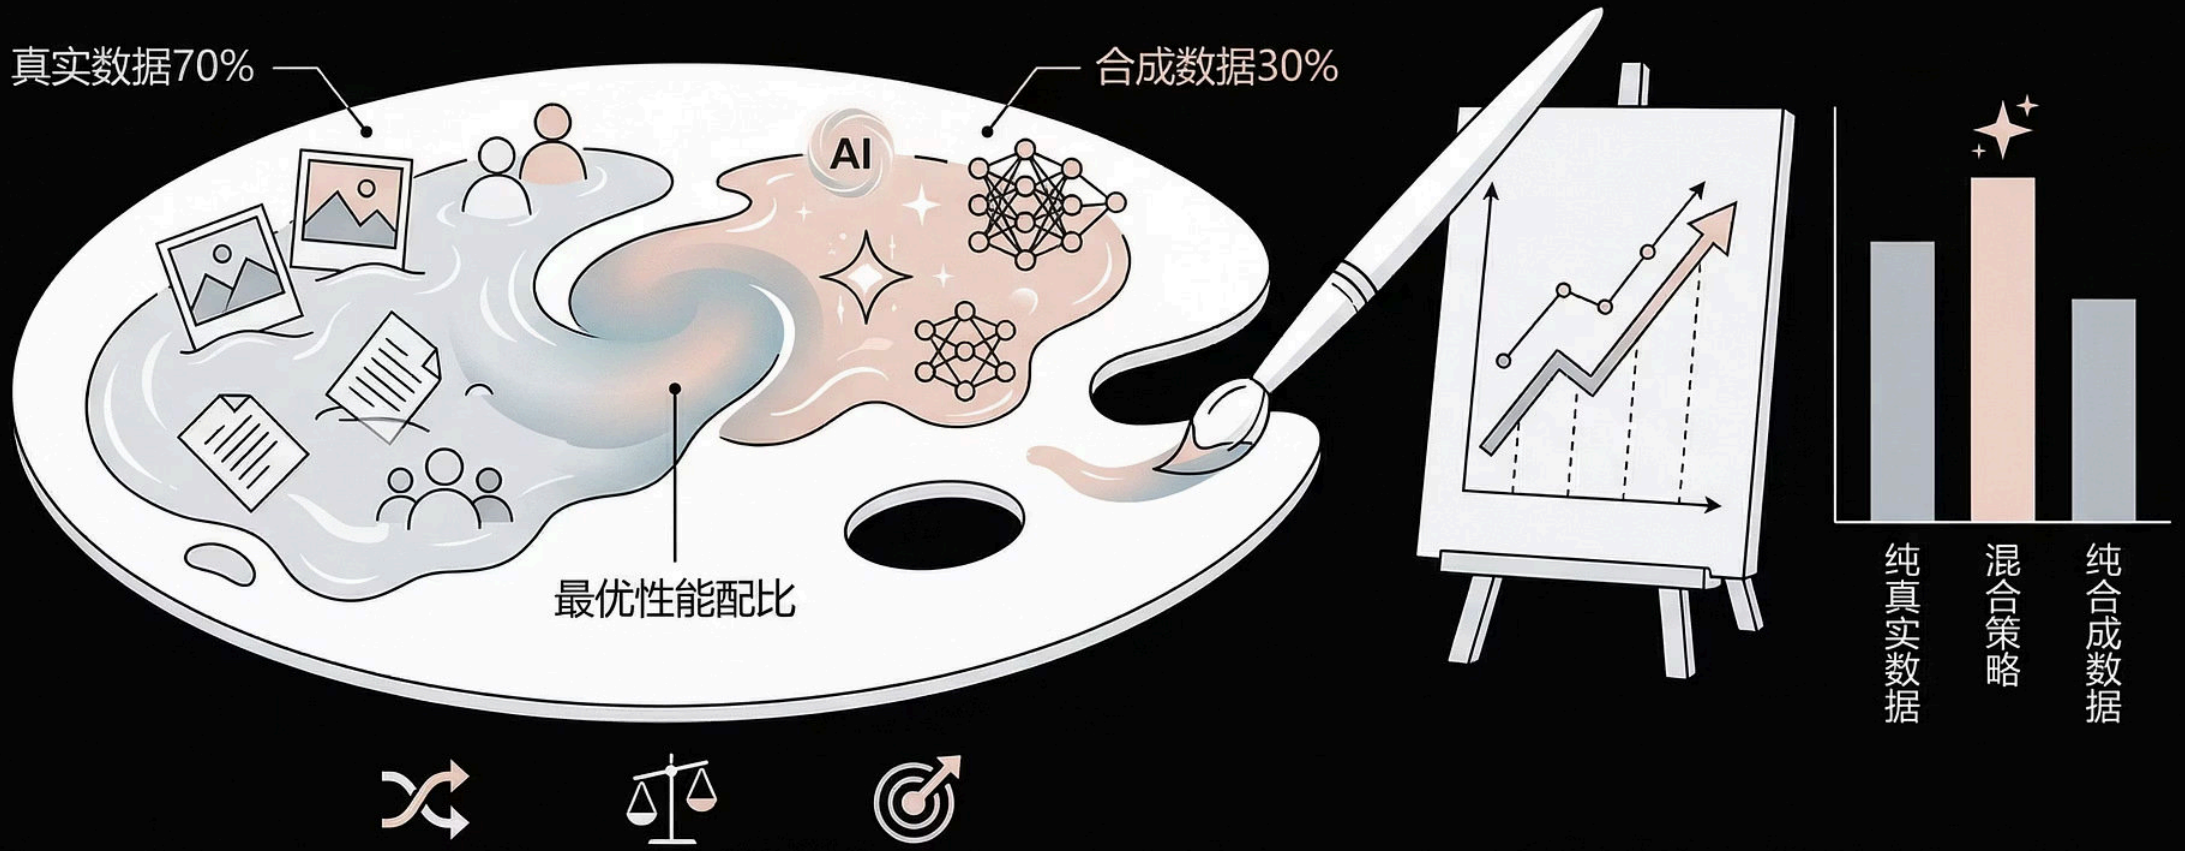




混合数据策略

真实数据与合成数据的完美融合，创造出更强大、更平衡的训练集

结合真实世界复杂性与合成数据规模优势，实现性能与效率的双重提升



模型崩溃的幽灵

Generation 1
第一代

Generation 3
第三代

Generation 5+
第五代以上



当AI只用自己生成的数据训练时，就像近亲繁殖一样危险

模型性能会逐代衰退，最终完全失效

这是AI发展面临的最大科学风险之一

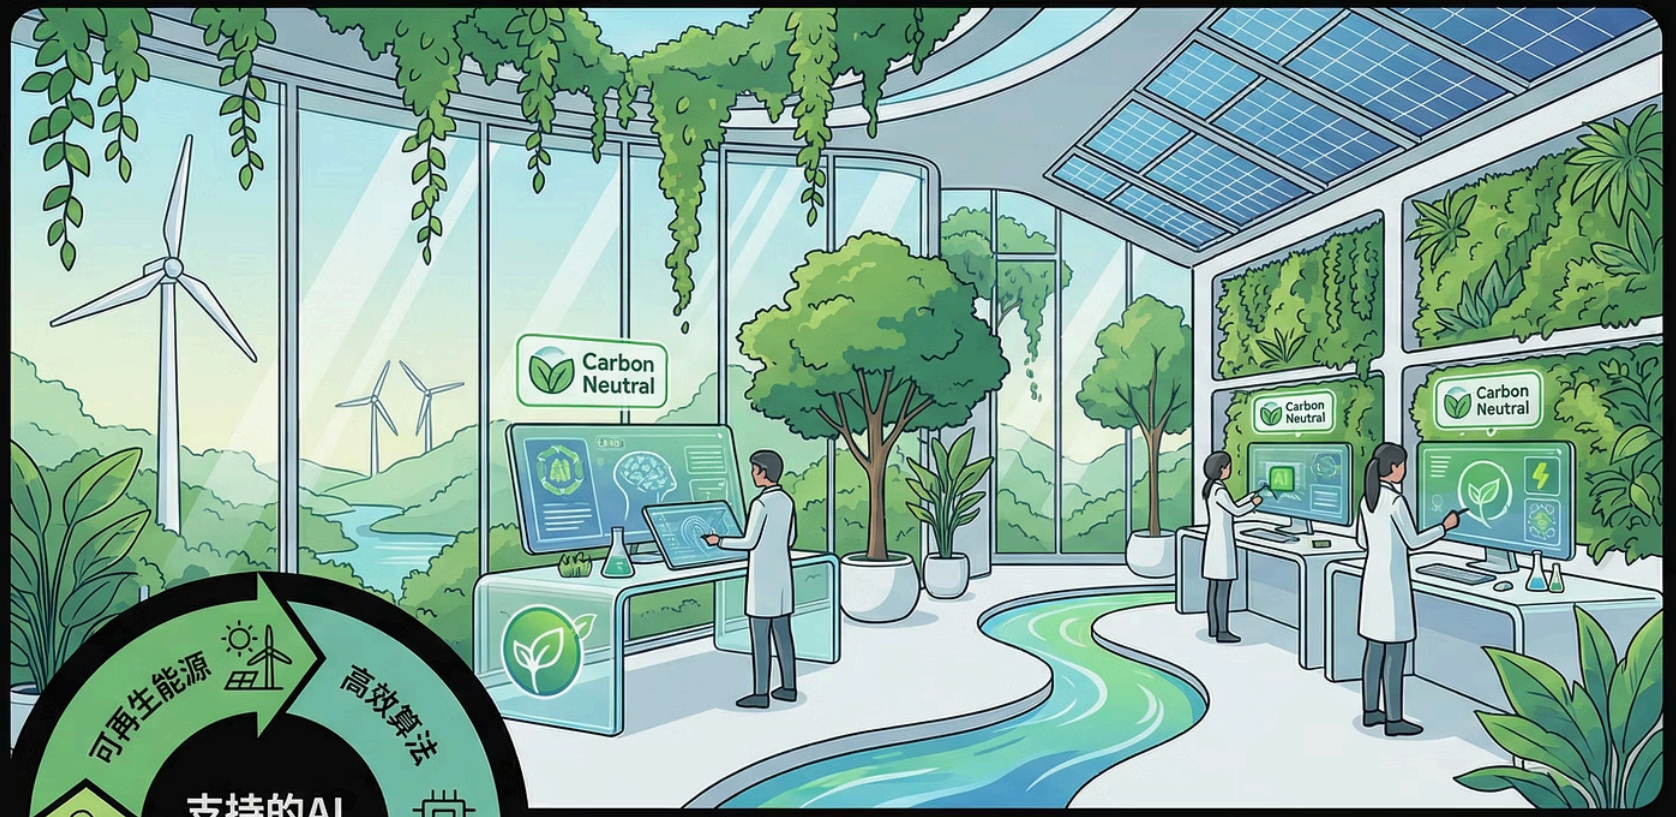
多样性缺失的陷阱

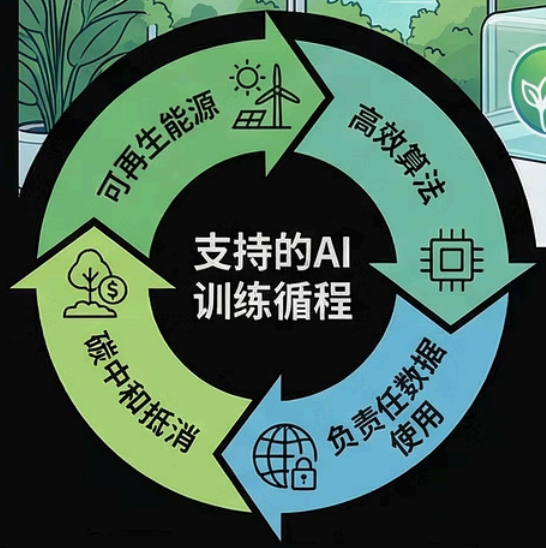


合成数据往往缺乏真实世界的复杂性、边缘情况和细微差异

这可能导致AI系统在面对真实情况时表现不佳，产生意外错误

绿色AI的未来愿景





80%
能耗降低

我们正在开发碳中和的AI训练方法

通过算法优化将训练能耗降低80%

建立AI碳排放标准，推动行业绿色转型

以少胜多的智慧



真正的创新不在于使用更多数据，而在于更智能地使用数据

数据工程师的使命：在技术进步与环境责任之间找到平衡

用最少的资源，创造最大的价值，这是可持续AI发展的核心哲学