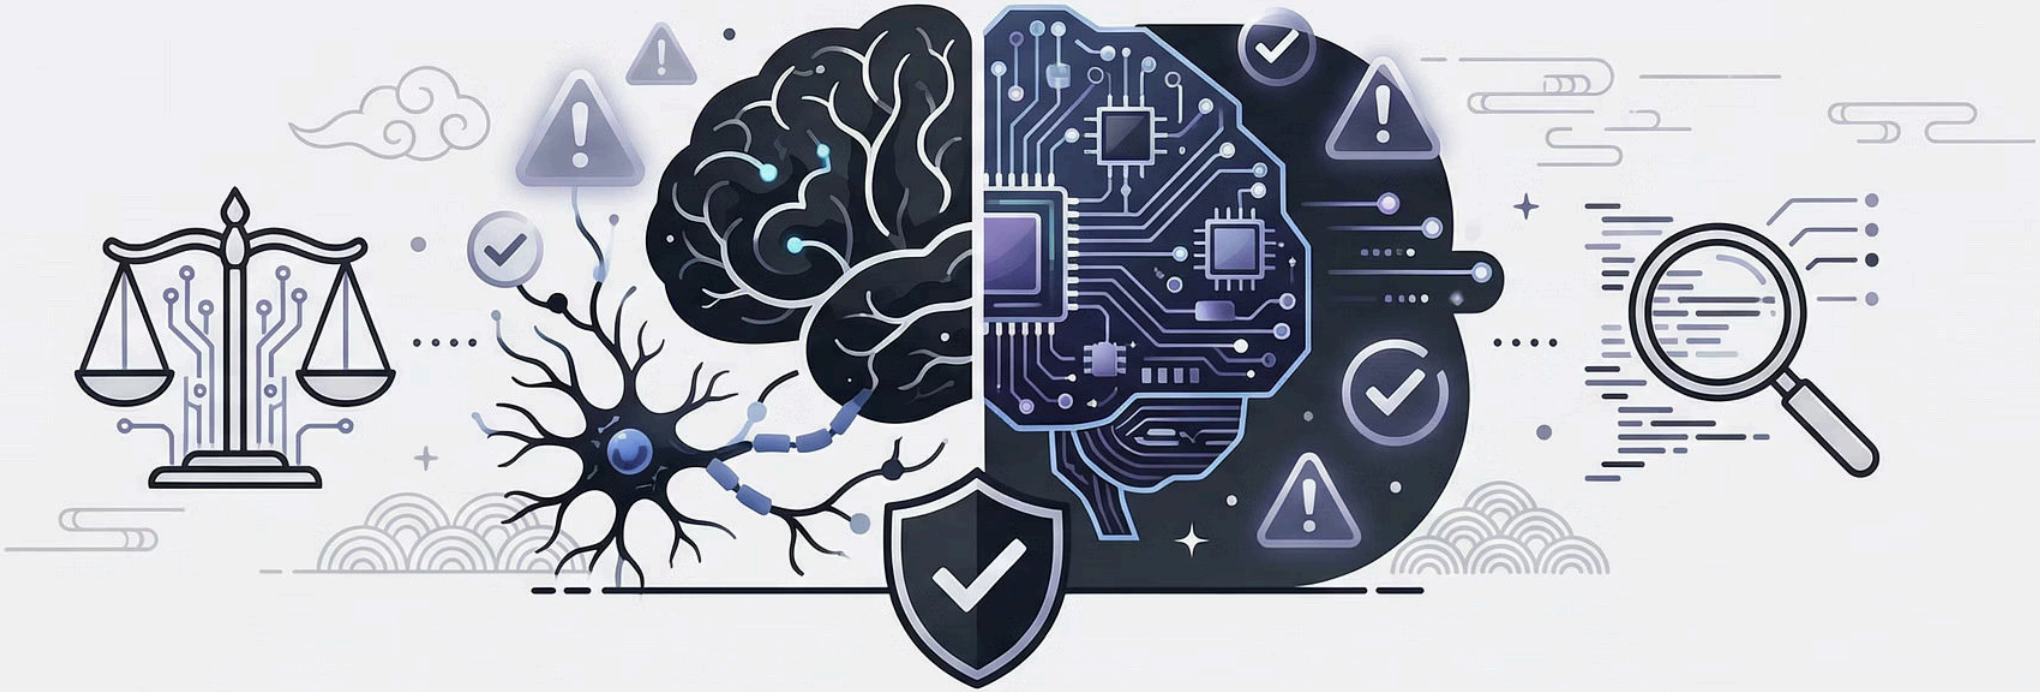
AI幻觉风险控制与伦理责任

构建可信、可控、合规的AI系统



该案例聚焦于AI幻觉（Hallucination）的风险控制与伦理责任，通过从底层剖析概率采样与温度参数的技术成因，深入讲解检索增生成（RAG）、思维链（CoT）及自洽性检查等关键去幻觉技术，并结合《生成式人工智能服务管理暂行办法》与真实法律判例，旨在培养学生构建

什么是AI幻觉?

- AI模型生成看似合理但实际错误或无根据信息的现象
- 就像人类在梦境中产生的虚假记忆和不真实的体验
- 这种现象在大语言模型中尤为常见，可能导致严重后果



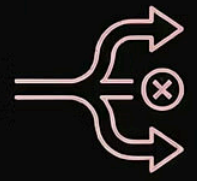
分屏对比：左侧显示AI生成的虚假新闻，右侧显示真实新闻报道

概率采样：幻觉的数学根源

语言模型通过概率分布选择下一个词汇，而非确定性逻辑推理

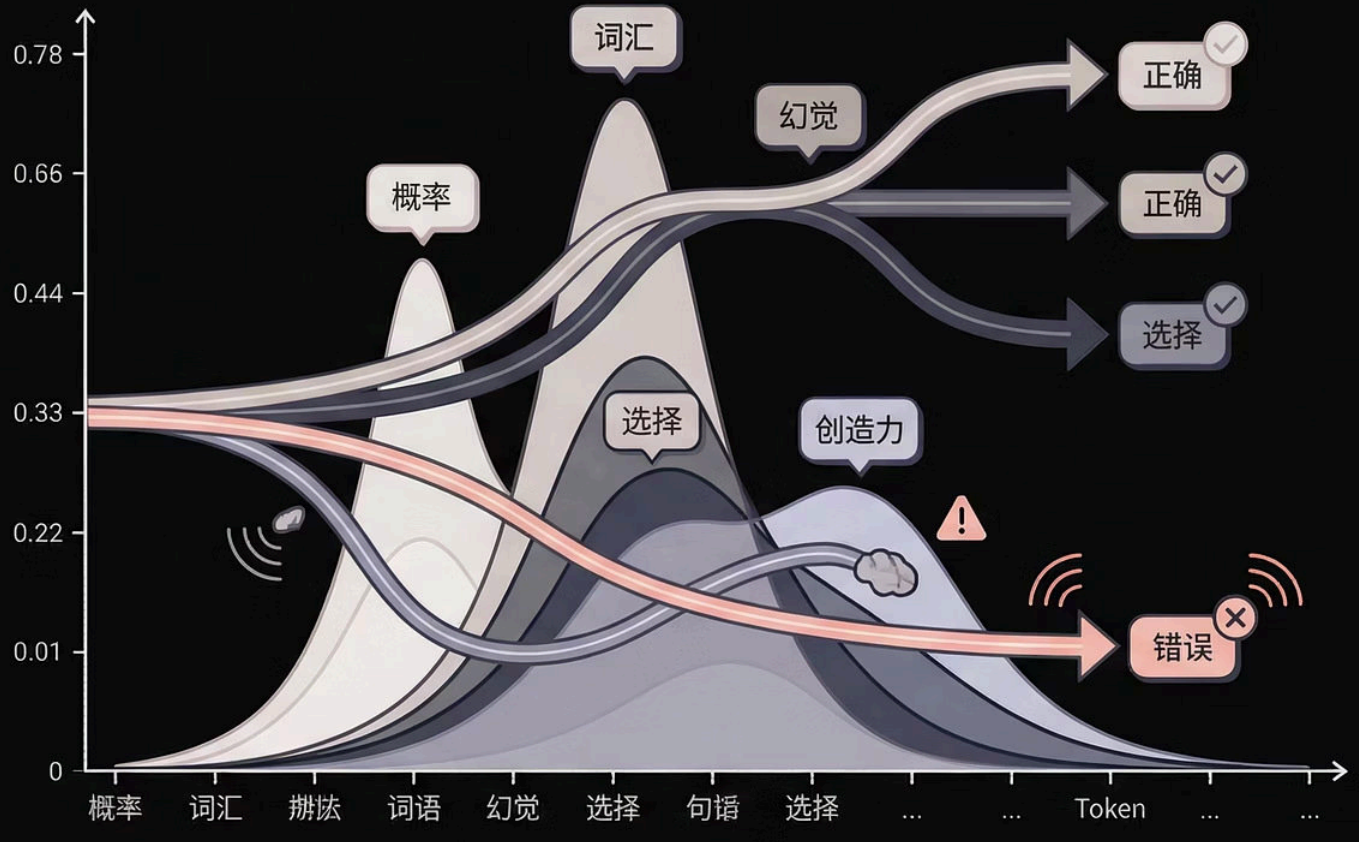
$$f_\theta \rightarrow P(x) \rightarrow \sum \rightarrow p^k \rightarrow P(n)$$

每个词汇都有概率权重，模型可能选择低概率但错误的答案



这种随机性是创造力的源泉，也是幻觉的温床





数学可视化：概率分布图表显示词汇选择过程，突出显示错误选择路径

温度参数的双刃剑效应

温度参数控制模型输出的随机性：0表示完全确定，1表示最大随机

高温度提升创造力但增加幻觉风险，低温度保证准确性但可能过于保守

找到最佳平衡点是控制AI幻觉的关键技术挑战



交互式滑块界面显示温度参数调节，配有不同温度下的输出示例对比

检索增强生成(RAG)：知识锚定

- RAG技术通过外部知识库检索相关信息，为AI生成提供事实依据
- 将模型的内在知识与外部权威数据源相结合，大幅降低幻觉率
- 就像给AI配备了实时的百科全书和事实核查员



技术架构图：用户查询→知识检索→信息融合→生成回答的完整流程

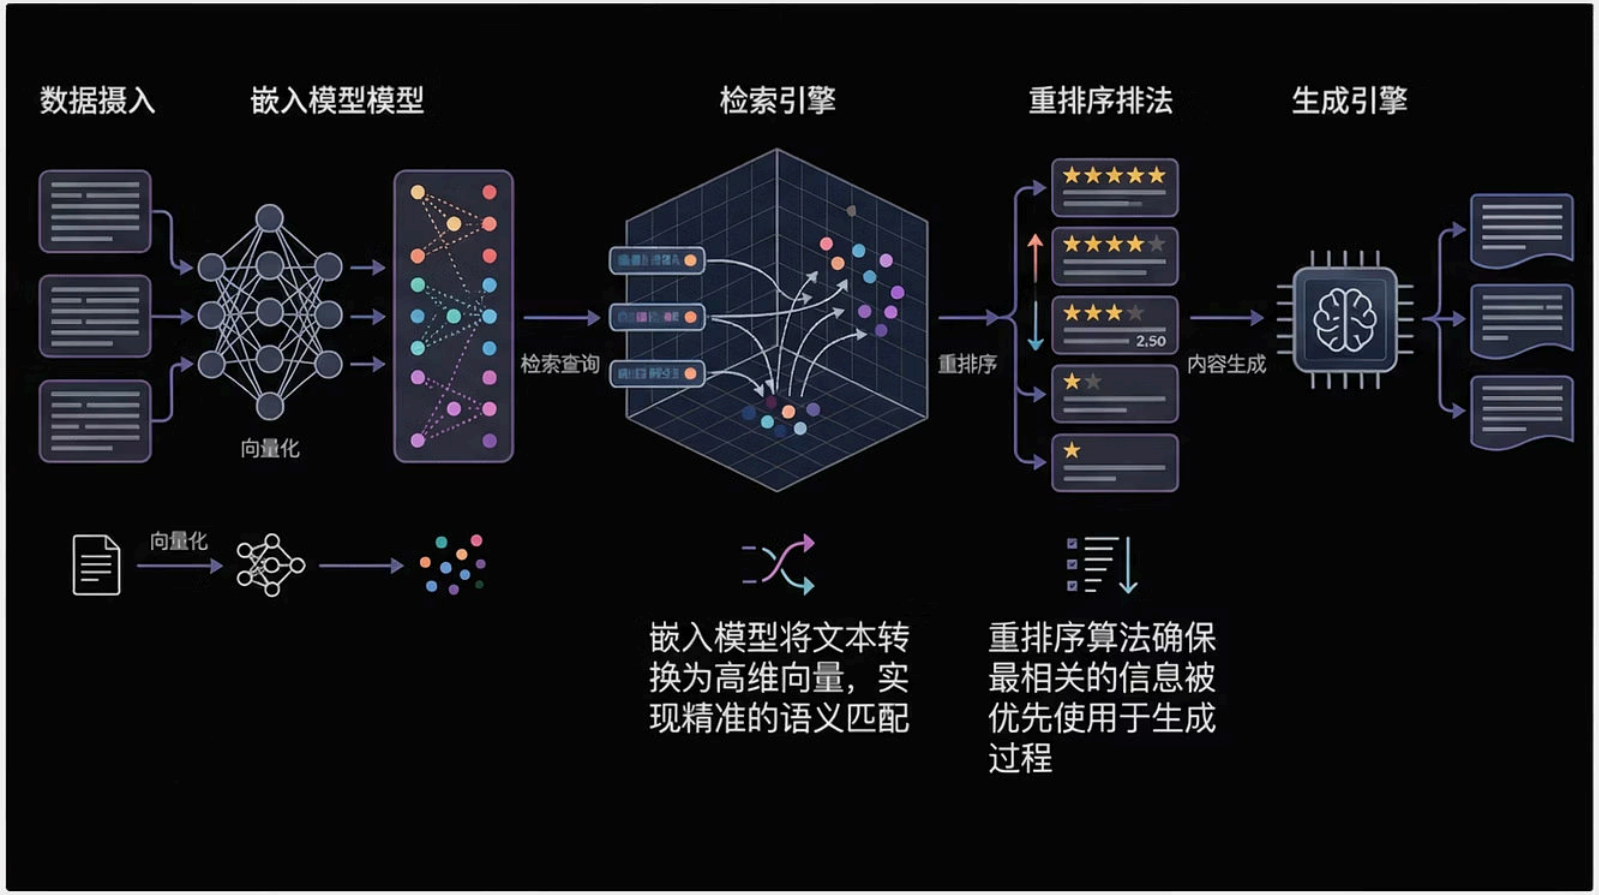
RAG系统的核心组件

向量数据库



向量数据库存储和索引大量结构化知识，支持语义相似性检索

嵌入模型将文本转换为高维向量，实现精准的语义匹配



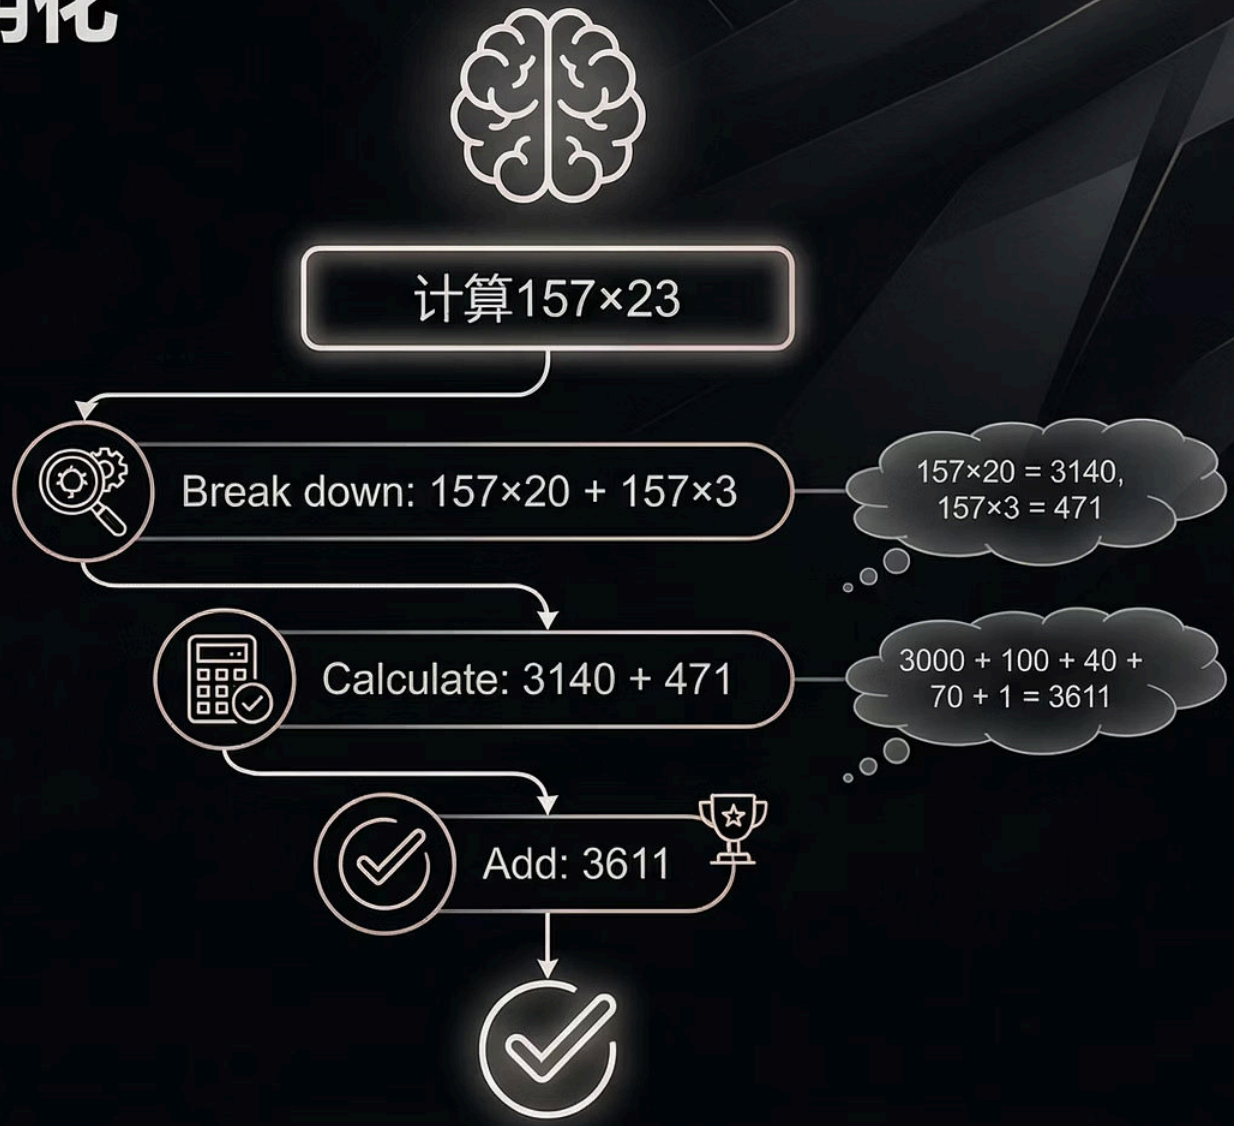
系统架构图显示向量数据库、嵌入层、检索器和生成器的协作关系

思维链(CoT)：推理透明化

CoT技术要求模型逐步展示推理过程，而非直接给出最终答案

通过分解复杂问题为多个子步骤，提高推理的逻辑性和可验证性

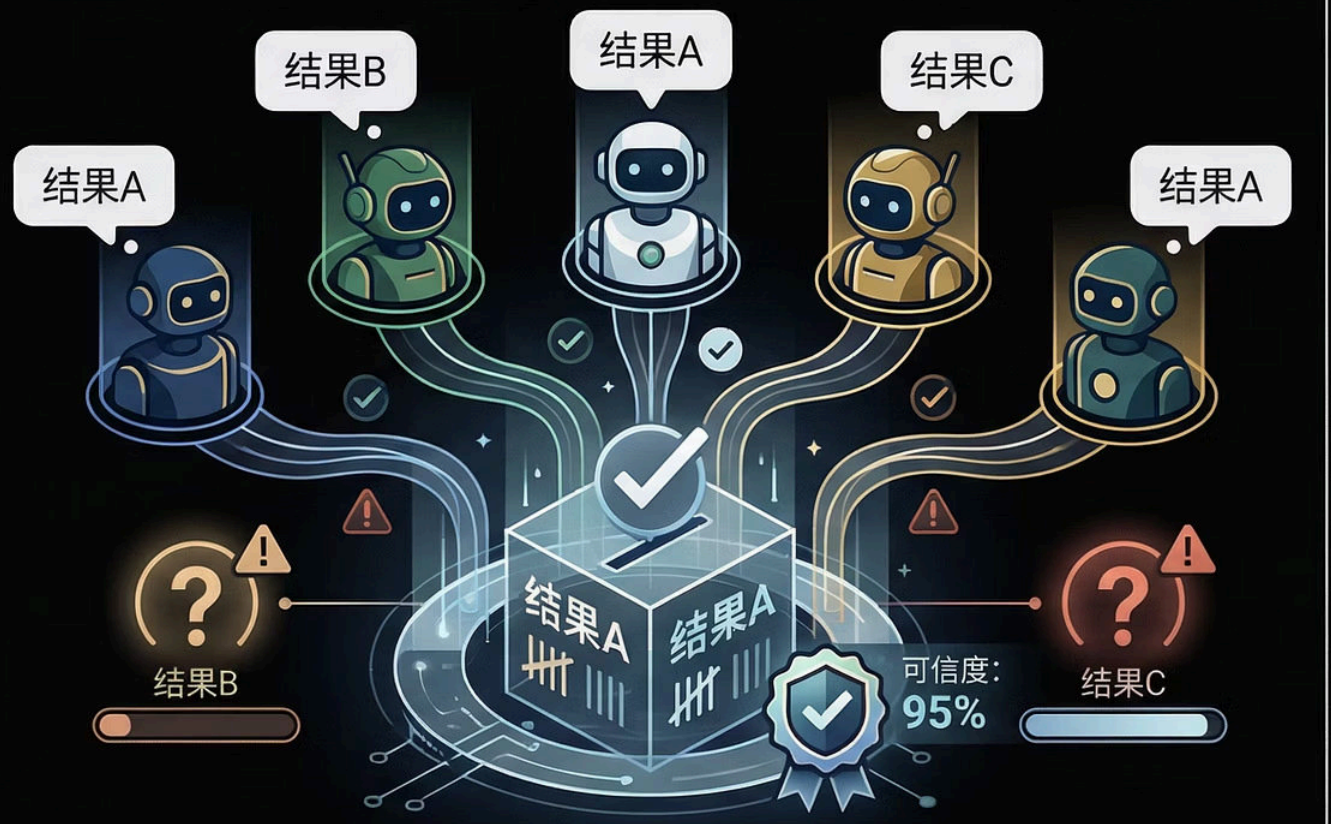
让AI的…



自洽性检查：多重验证机制

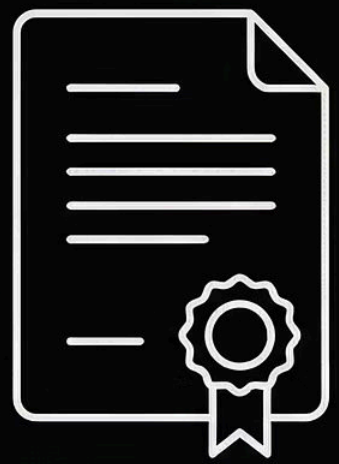
- 通过多次采样生成不同答案，然后比较一致性来识别潜在错误
- 如果多次生成的结果高度一致，则可信度较高；差异较大则需要警惕
- 结合投票机制和置信度评估，构建可靠的质量控制体系

2.5px consistent stroke weight: or #F2F2F3



可视化显示多个AI实例同时工作，输出结果通过投票机制达成共识

《生成式AI服务管理暂行办法》核心要点





第四条

提供生成式AI服务应当遵守法律法规，尊重社会公德和伦理道德



第十条

不得生成虚假信息，应建立健全算法机制和人工审核机制



第十六条

发现违法内容应当立即停止生成，采取消除等处置措施

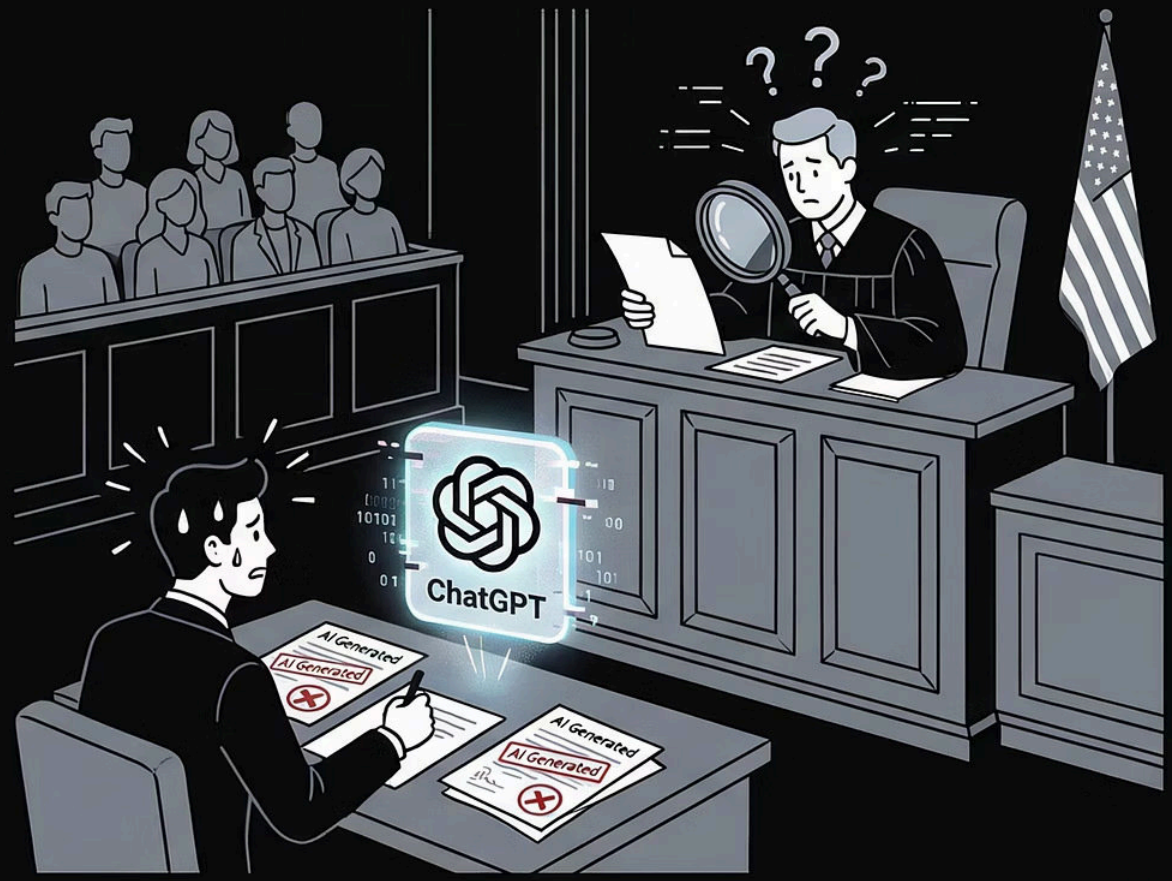
法律条文背景配以天平和法槌的象征性图像，体现法治权威

真实案例：ChatGPT诽谤律师事件

2023年美国律师史蒂文·施瓦茨使用ChatGPT撰写法庭文件

AI生成了六个完全虚构的法律案例，包括假的法官姓名和判决书

法官发现后对律师进行制裁，成为AI幻觉导致法律后果的典型案例



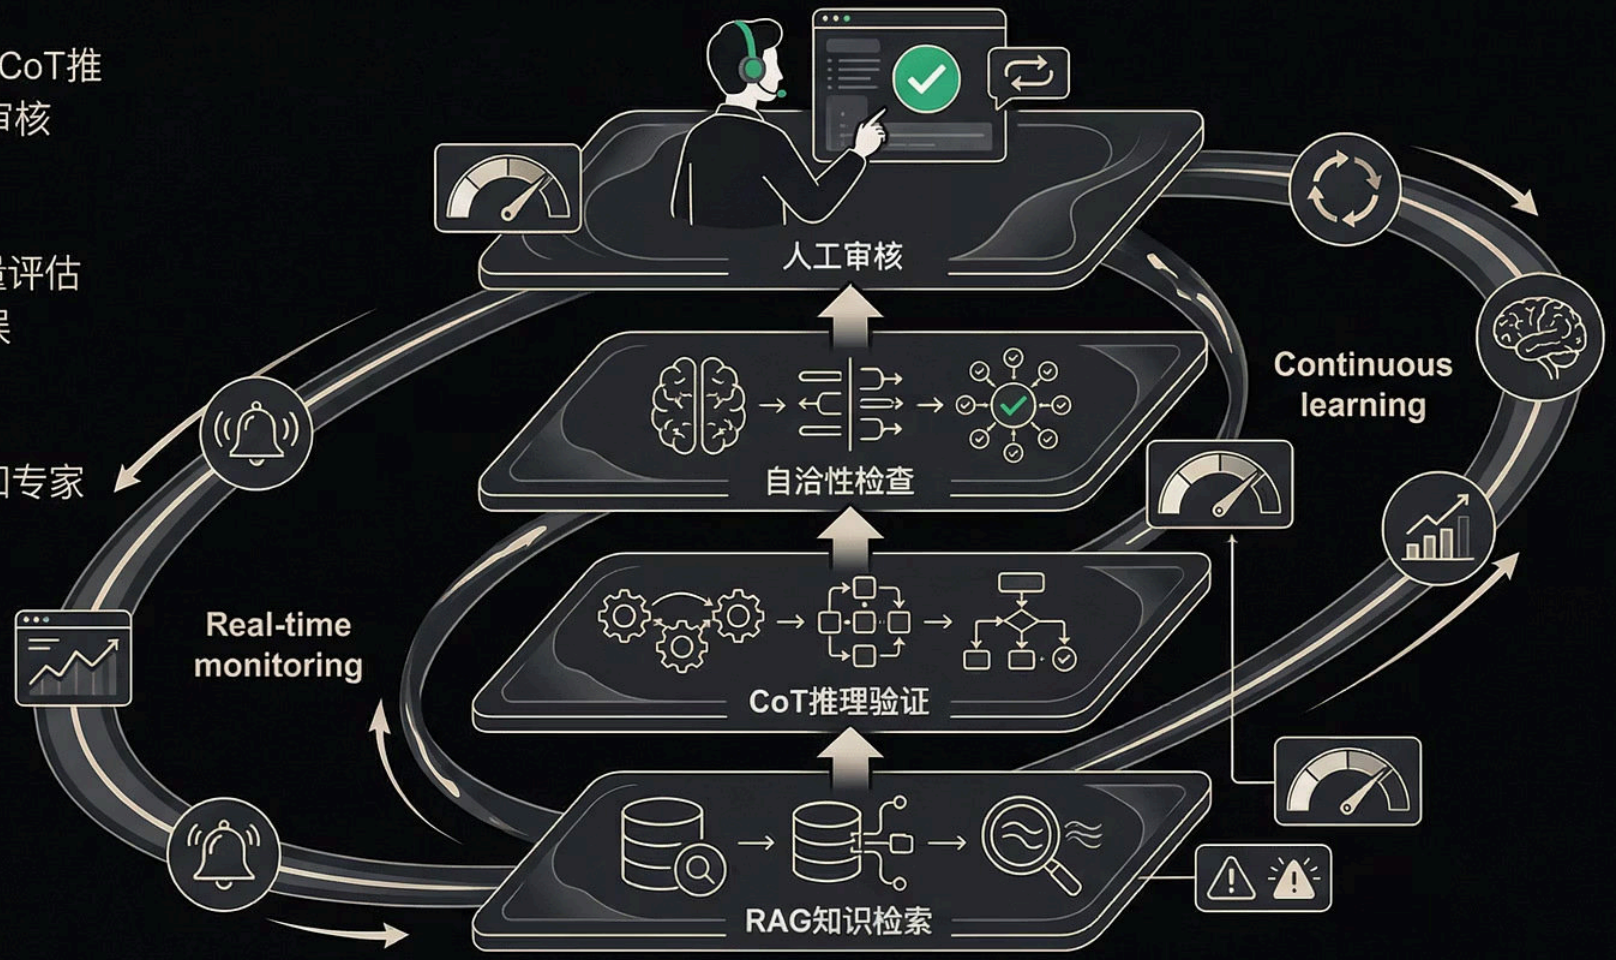
法庭场景：困惑的法官审阅虚假文件，律师席上焦虑的当事律师

构建可信AI的技术框架

多层防护：RAG知识检索+CoT推理验证+自洽性检查+人工审核

实时监控：建立AI输出质量评估体系，及时发现和纠正错误

持续学习：通过用户反馈和专家标注不断优化模型性能



综合技术架构图展示完整的AI可信性保障体系，各个组件相互协作

未来：负责任的AI发展之路

技术创新与伦理责任并重，构建人类可以信赖的智能系统

通过严格的工程实践和法律合规，让AI真正服务于人类福祉



未来科技城市景观，AI与人类和谐共存的美好愿景，突出责任与信任主题