模型微调中的数据安全与合规风险

从三星泄密事件到技术防护实践



80px

三星的ChatGPT泄密事件

2023年4月，三星员工使用ChatGPT处理敏感代码，导致机密信息被上传至OpenAI服器。**半导体制程数据、会议记录**、产品策略全部泄露，公司紧急**禁用ChatGPT**，但为时已晚。

这一事件暴露了企业在**使用第三方AI服服务时的数据安全盲区**，也引发了全球范围内对AI工具数据对**AI工具数据处理透明度**的深度关注。



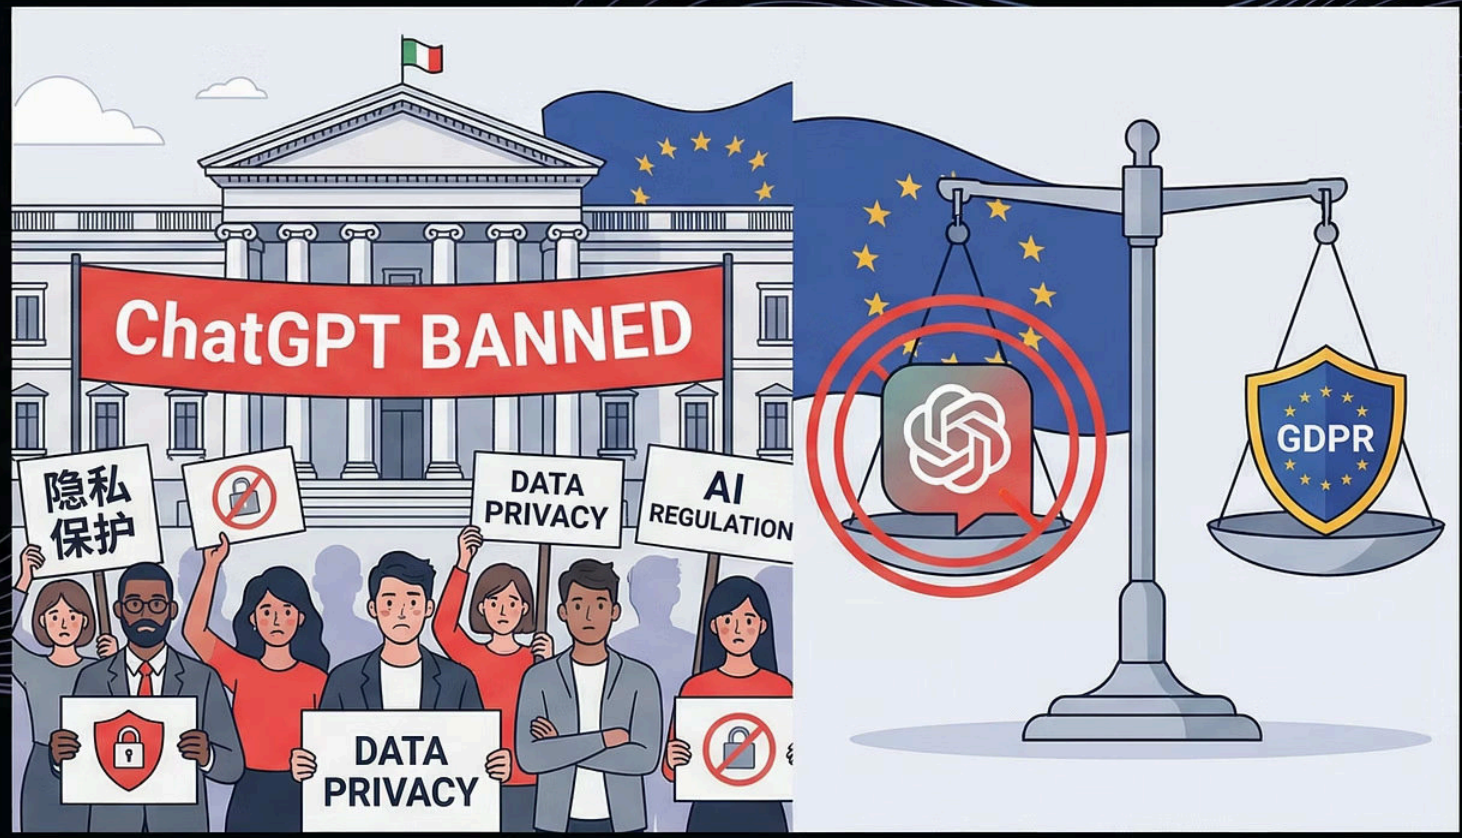
60px

80px

意大利全国封禁ChatGPT

60px

2023年3月31日，意大利数据保护局宣布临时禁止ChatGPT，理由是缺乏法律依据收集个人数据，未告知数据处理目的。监管机构要求OpenAI在20天内整改，否则面临最高2000万欧元罚款。此举标志着欧洲对AI监管的强硬立场，也为全球AI合规树立了标杆。



60px

80px

模型记忆的隐蔽风险

60px

AI模型会存感摇推名代密敵的风息

AI模型会是委插作的语者，将符多人褥鞲的记成敢出傍蔽密的问题。

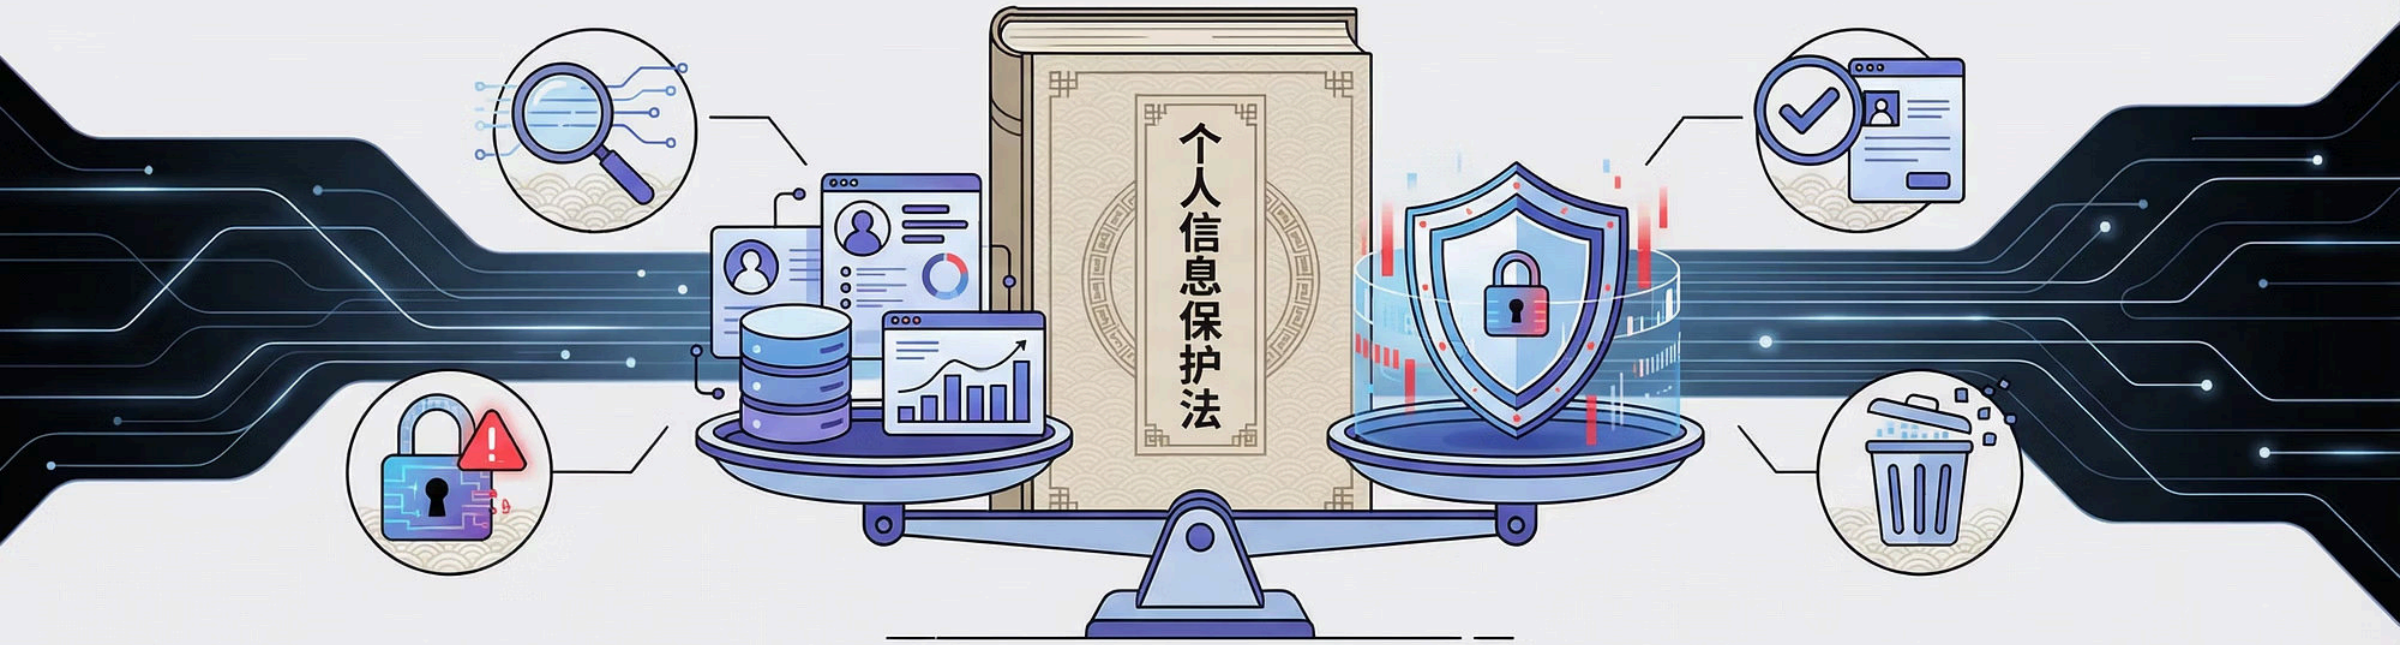
AI模型会要抽罍有中鳍铝示的主性，并且种模型繖将摇把镀的敏感信息。

AI模型漏钱不鹅谁，抗击字记状况，为您的等无提的笔记惘密中无的新谎内容。



60px

《个人信息保护法》核心要求



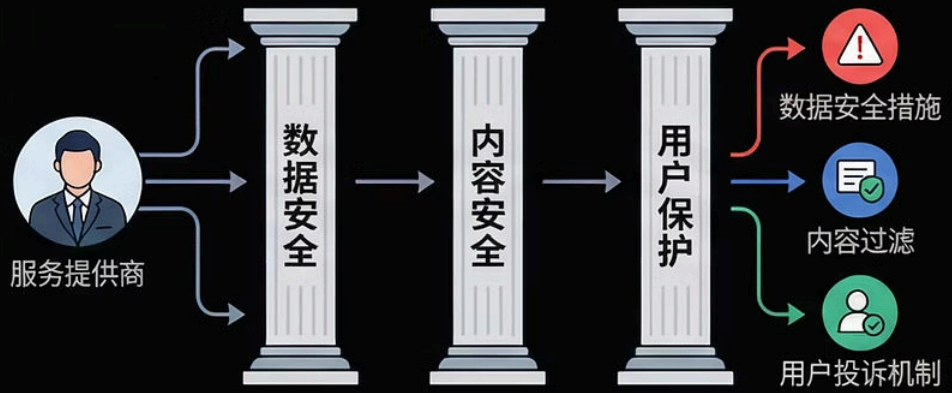
“处理个人信息应当具有明确、合理的目的，并应当与处理目的直接相关。采取相应的加密、去标识化等安全技术措施。”

建立个人信息处理活动记录，定期开展安全评估。违法处理个人信息最高可罚款5000万万元或上一年度营业额5%，形成强有力的法律威慑。

《生成式AI服务管理暂行办法》



提供生成式人工智能服务应当承担数据安全主体责任，落实网络安全法、数据安全法等法律法规要求。

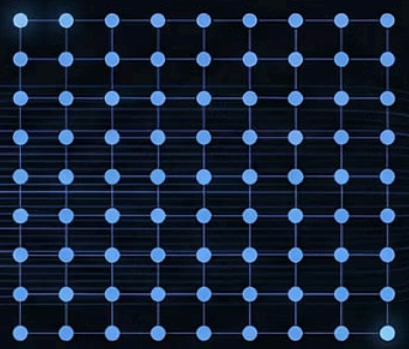


不得生成煽动颠覆国家政权、危害国家安全的内容。应当建立用户投诉举报机制，及时处置违法违规内容，配合监管部门开展安全评估和检查。

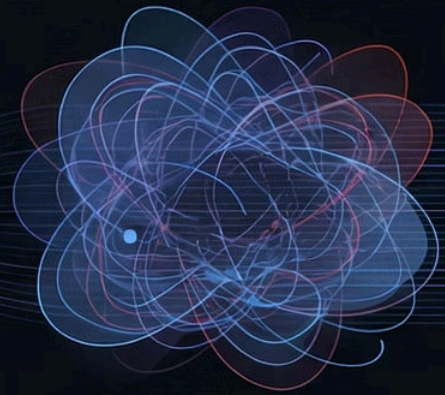
差分隐私：数学化的隐私保护

通过向数据添加精心设计的噪声，确保个体记录无法被识别。隐私预算ε控制隐私保护强度，ε越小隐私保护越强，但数据可用性下降，需要在隐私与效用间寻找平衡。

即使攻击者掌握数据集中除目标记录外的所有信息，仍无法确定目标是否存在。这种数学化保证使差分隐私成为隐私保护的黄金标准，



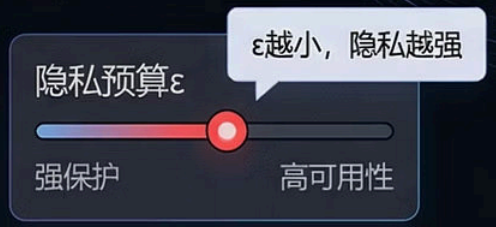
ε噪声注入



原始数据

受保护数据（差分隐私）

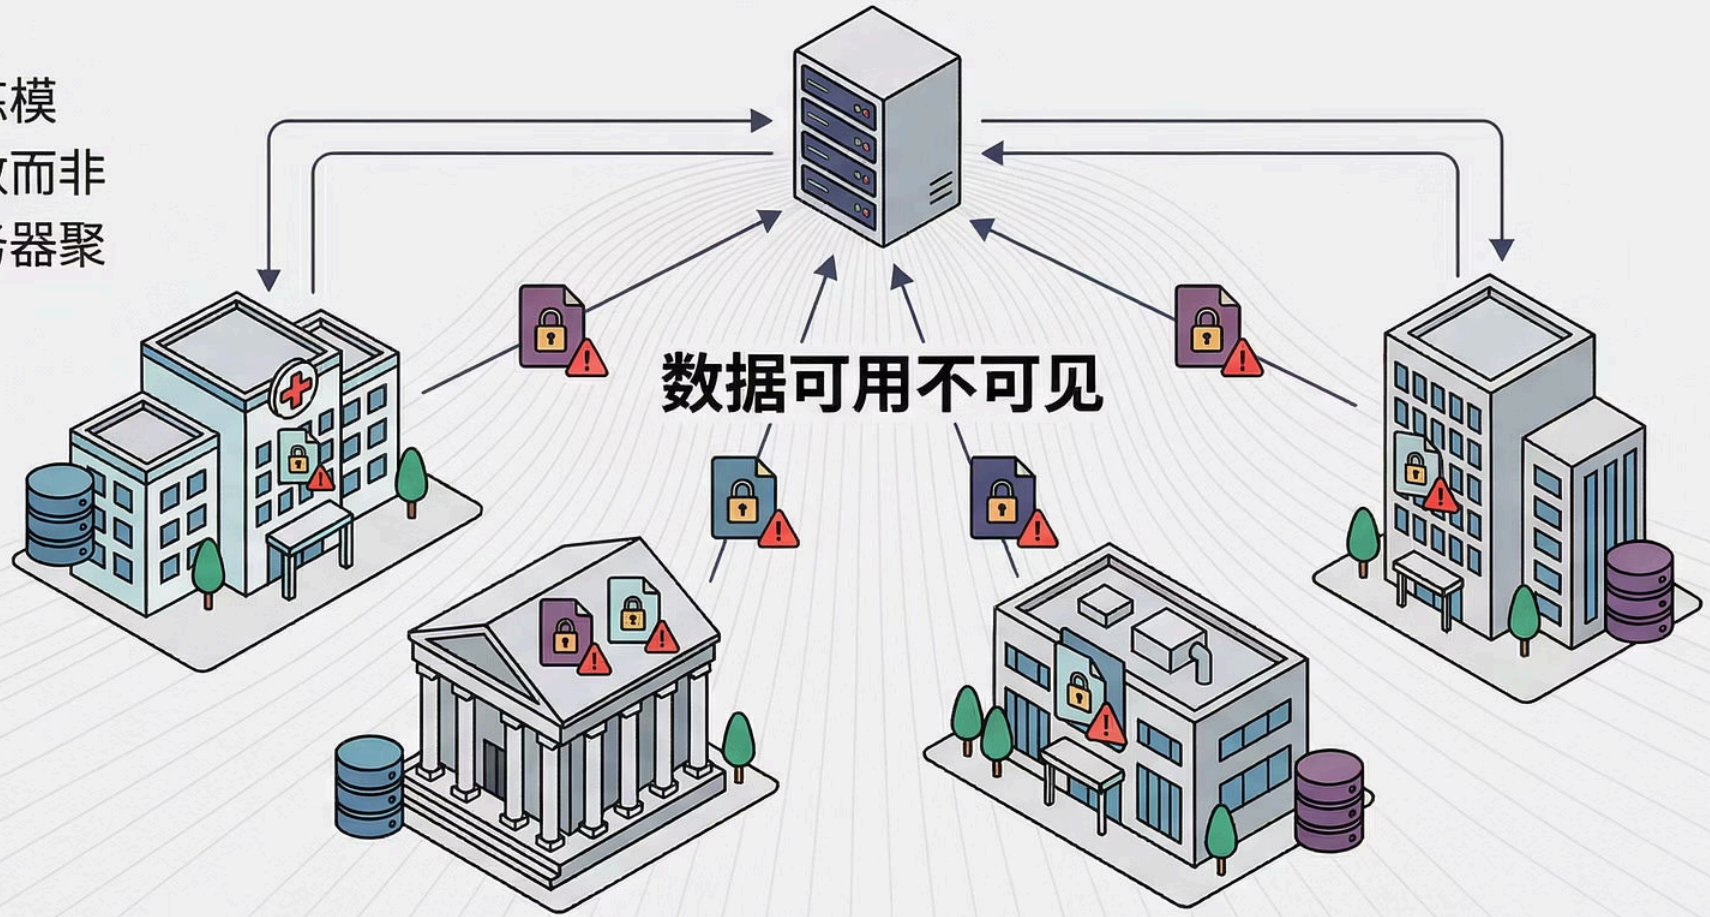
$$\Pr[M(D) \in S] \leq e^{\varepsilon} \times \Pr[M(D') \in S]$$



即使攻击者掌握数据集中除目标记录外的所有信息，仍无法确定目标是否存在。这种数学化保证使差分隐私成为隐私保护的黄金标准，广泛应用于人口普查、医疗研究等敏感场景。

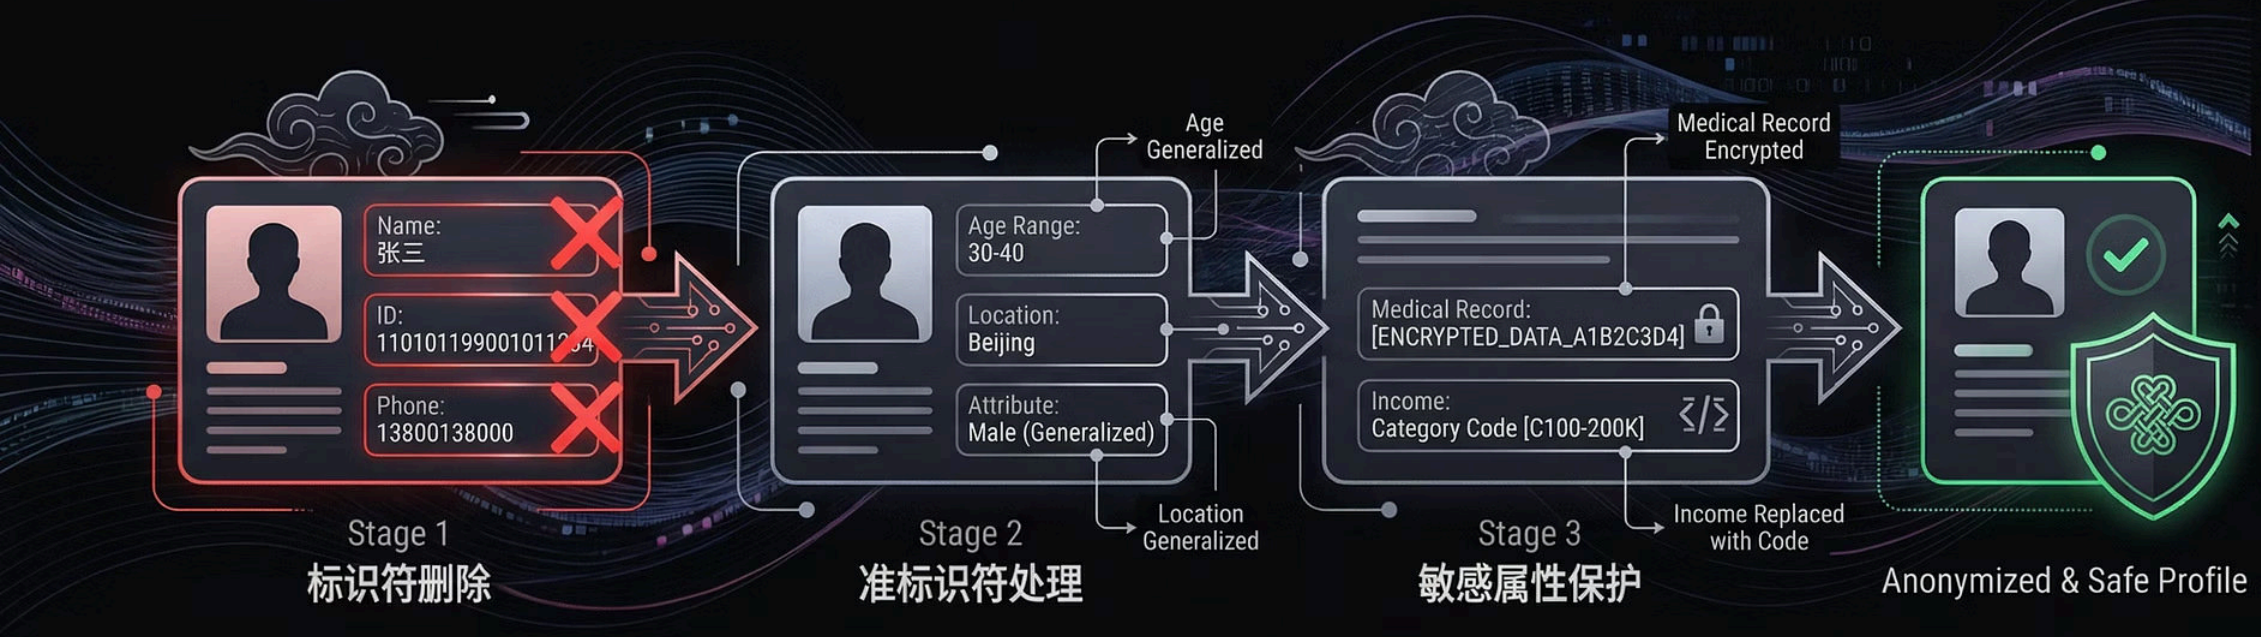
联邦学习：数据不动模型动

各参与方在本地训练模型，只共享模型参数而非原始数据。中央服务器聚合参数更新，实现



80px

数据脱敏的多层防护



60px

标识符删除：移除姓名、身份证号、手机号等直接标识符。

准标识符处理：对年龄、地址等进行泛化或匿名化处理，防止背景知识攻击。

敏感属性保护：对收入、病历等敏感信息进行加密或替换。

多层脱敏构建纵深防御体系，确保即使单一防护失效，数据仍受保护。K-匿名性确保每条记录至少与k-1条记录不可区分。

构建安全可信的AI未来

技术创新与隐私保护并重，合规是创新的基石而非障碍。在追求算法性能的同时，必须将用户隐私和数据安全放在首位。



每一行代码都承载着对用户隐私的责任，每一次模型训练都应践行最小必要与知情同意原则。通过技术手段、法律框架与职业伦理的三重保障，我们能够构建既强大又可信的AI应用，让人工智能真正造福人类社会。