AI评估的科学性与公正性

构建可信的人工智能评估体系

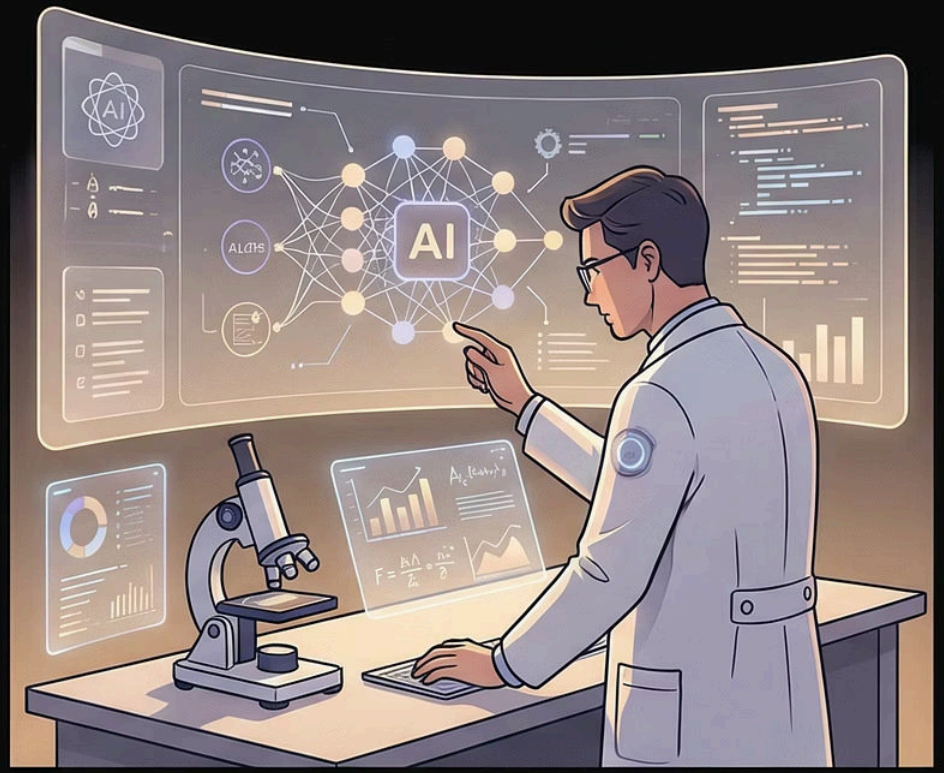


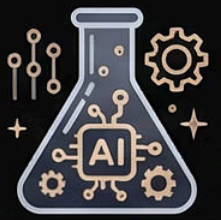
AI评估：科学发展的基石

> 没有科学的评估，就没有可信的AI发展

> 评估不仅是技术问题，更是道德责任

> 公正的评估是AI行业健康发展的根本保障







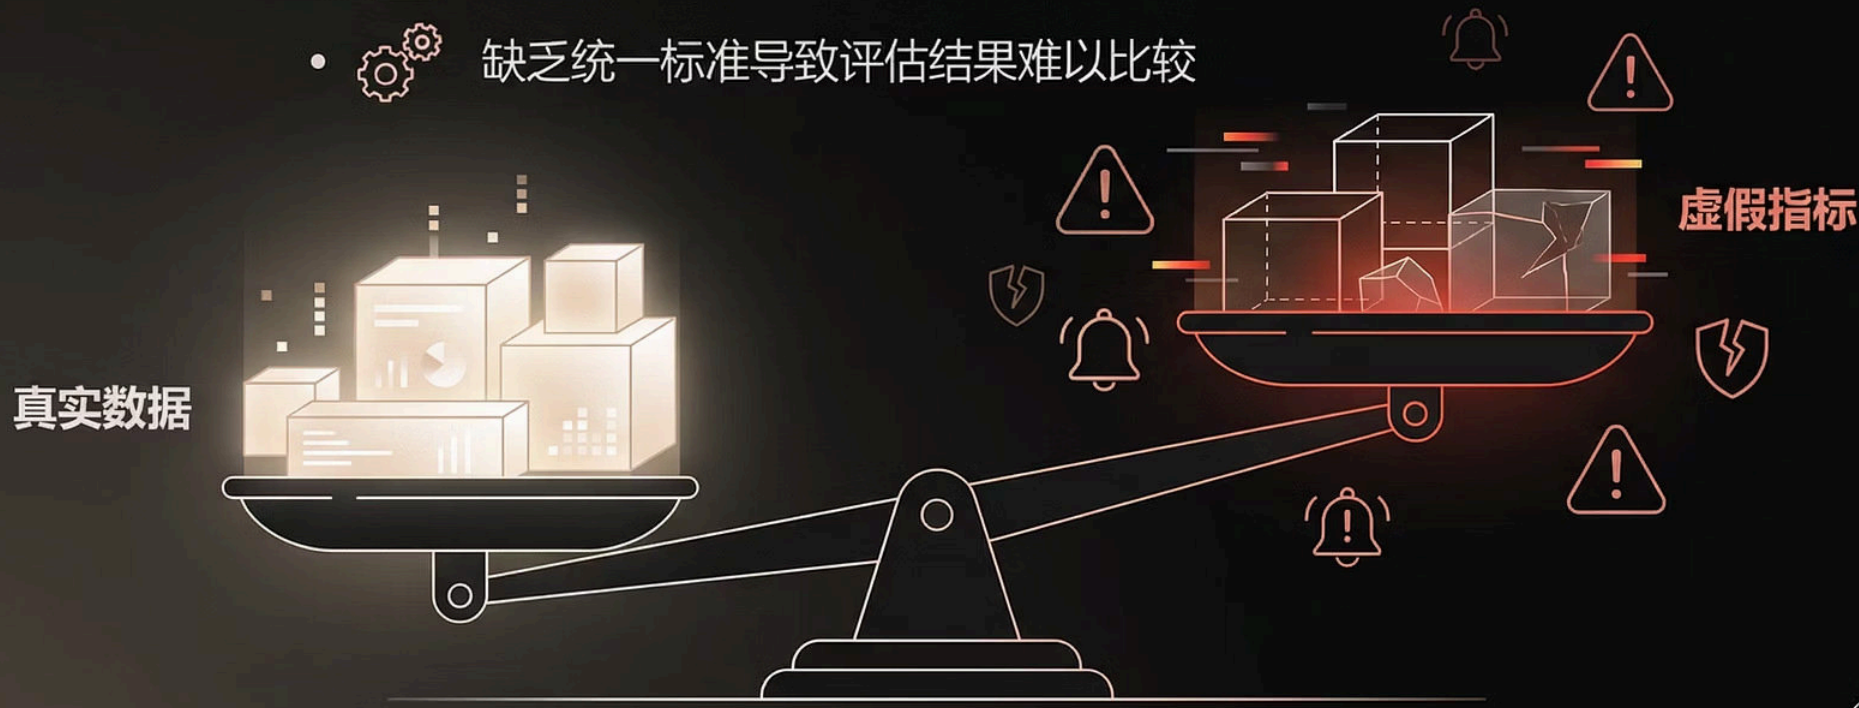


科学家在实验室中严谨测试AI模型，显微镜下观察数据，体现科学精神

科学家在实验室中严谨测试AI模型，显微镜下观察数据，体现科学精神

当前AI评估面临的挑战

- 评估偏见无处不在：长度偏见、位置偏见、风格偏见
- 刷榜现象严重损害了评估体系的公信力
- 缺乏统一标准导致评估结果难以比较



天平失衡的视觉隐喻，一边是真实数据，一边是虚假指标

精确匹配（Exact Match）：最直观的评估

精确匹配要求模型输出与标准答案完全一致

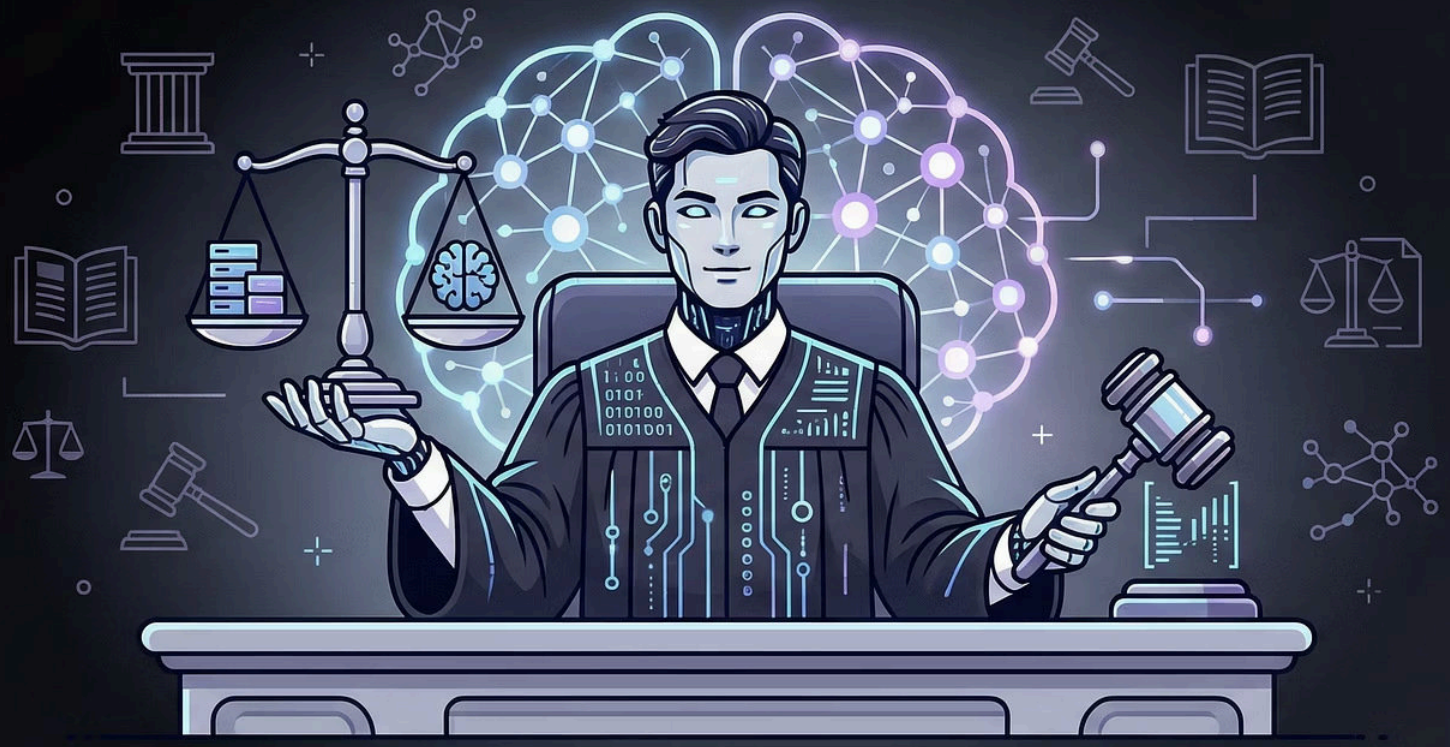
优点：简单直观，无主观性；
缺点：过于严格，无法处理语义等价

适用场景：数学计算、代码生成等有明确答案的任务



代码编辑器界面显示绿色的完全匹配和红色的不匹配结果

AI裁判（LLM-as-a-Judge）：智能化评估的突破



使用大语言模型作为评判者，模拟人类专家评估

能够理解语义、评估创造性和逻辑性

但存在评估者偏见和不稳定性问题

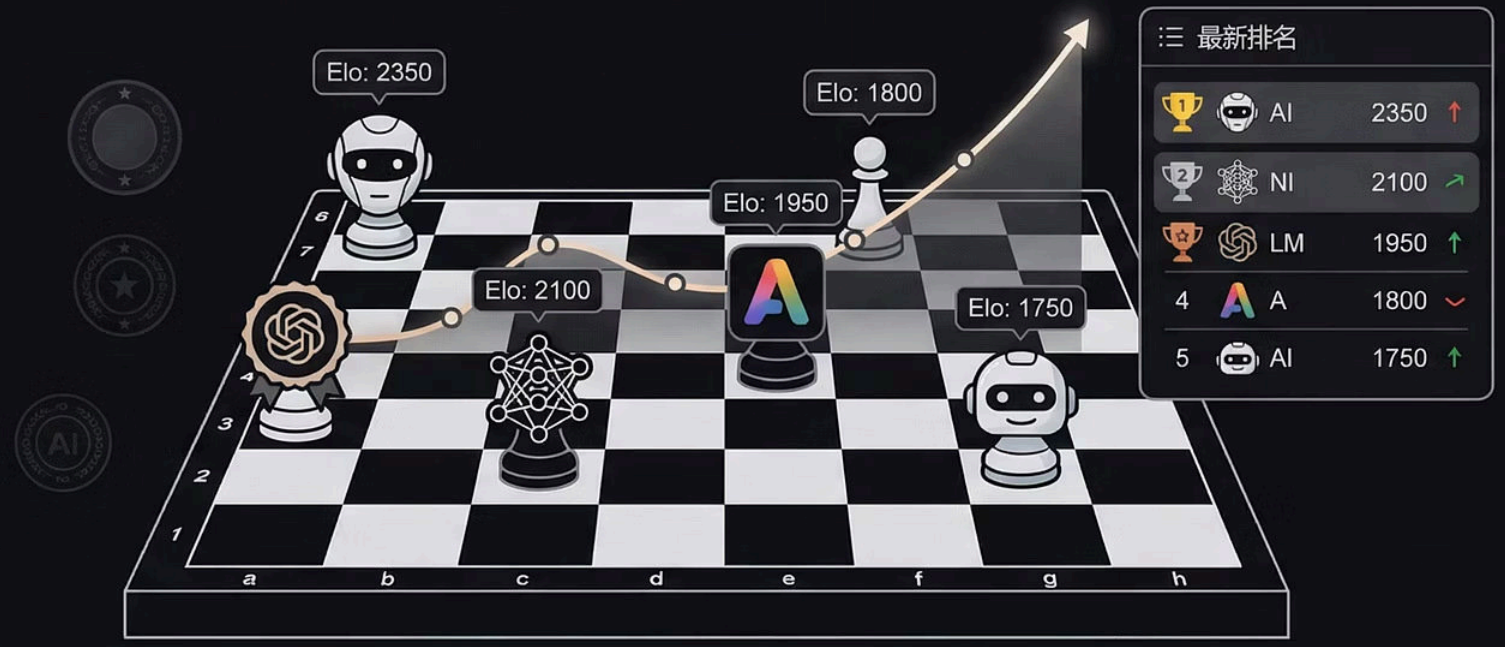
AI法官形象坐在法庭上，手持天平，背景是复杂的神经网络结构

Elo评分系统：竞技化的评估方式

借鉴国际象棋评分系统，通过两两对战确定模型排名

动态调整分数，反映模型真实水平

ChatBot Arena等平台的核心评估机制



象棋棋盘上放置不同的AI模型标识，显示Elo分数变化曲线

长度偏见：更长不等于更好

- 评估者往往偏好更长、更详细的回答
- 这导致模型学会'废话连篇'而非精准回答
- 真正的智能应该体现在简洁而准确的表达



对比图：简洁精准的短答案vs冗长空洞的长答案，天平倾向错误一边

刷榜现象：学术诚信的沦陷



针对特定基准过度优化，牺牲泛化能力

数据污染和测试集泄露问题严重

追求排名而忽视真实应用价值

被操纵的排行榜，虚假的第一名奖杯，背景是真实用户的失望表情

中国信通院评估标准：权威性与本土化



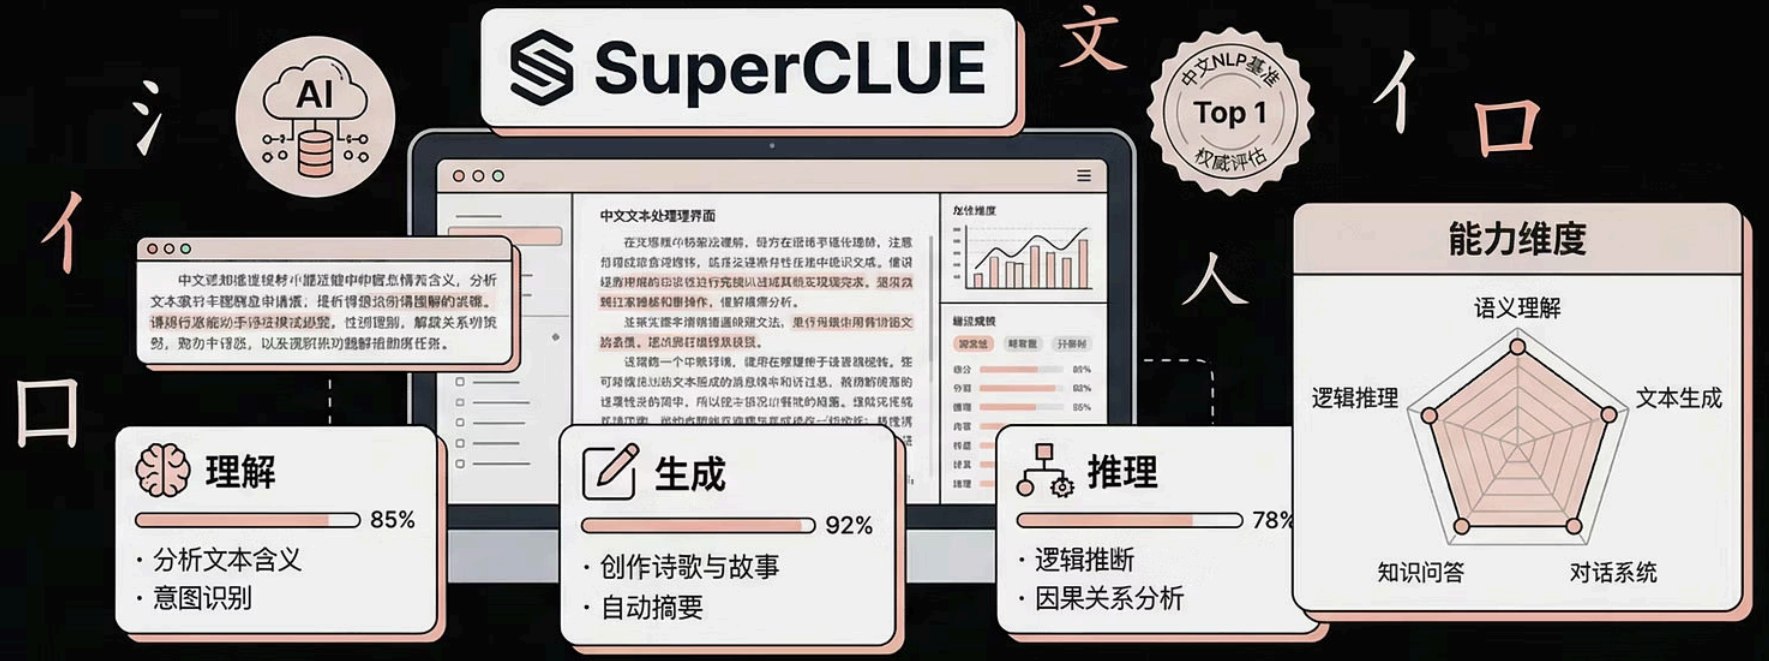


- 制定符合中国国情的AI评估标准体系
- 涵盖技术性能、安全性、公平性等多个维度
- 为国产AI模型发展提供科学指导

中国信通院标志，严肃的专家团队在制定标准，中文评估文档

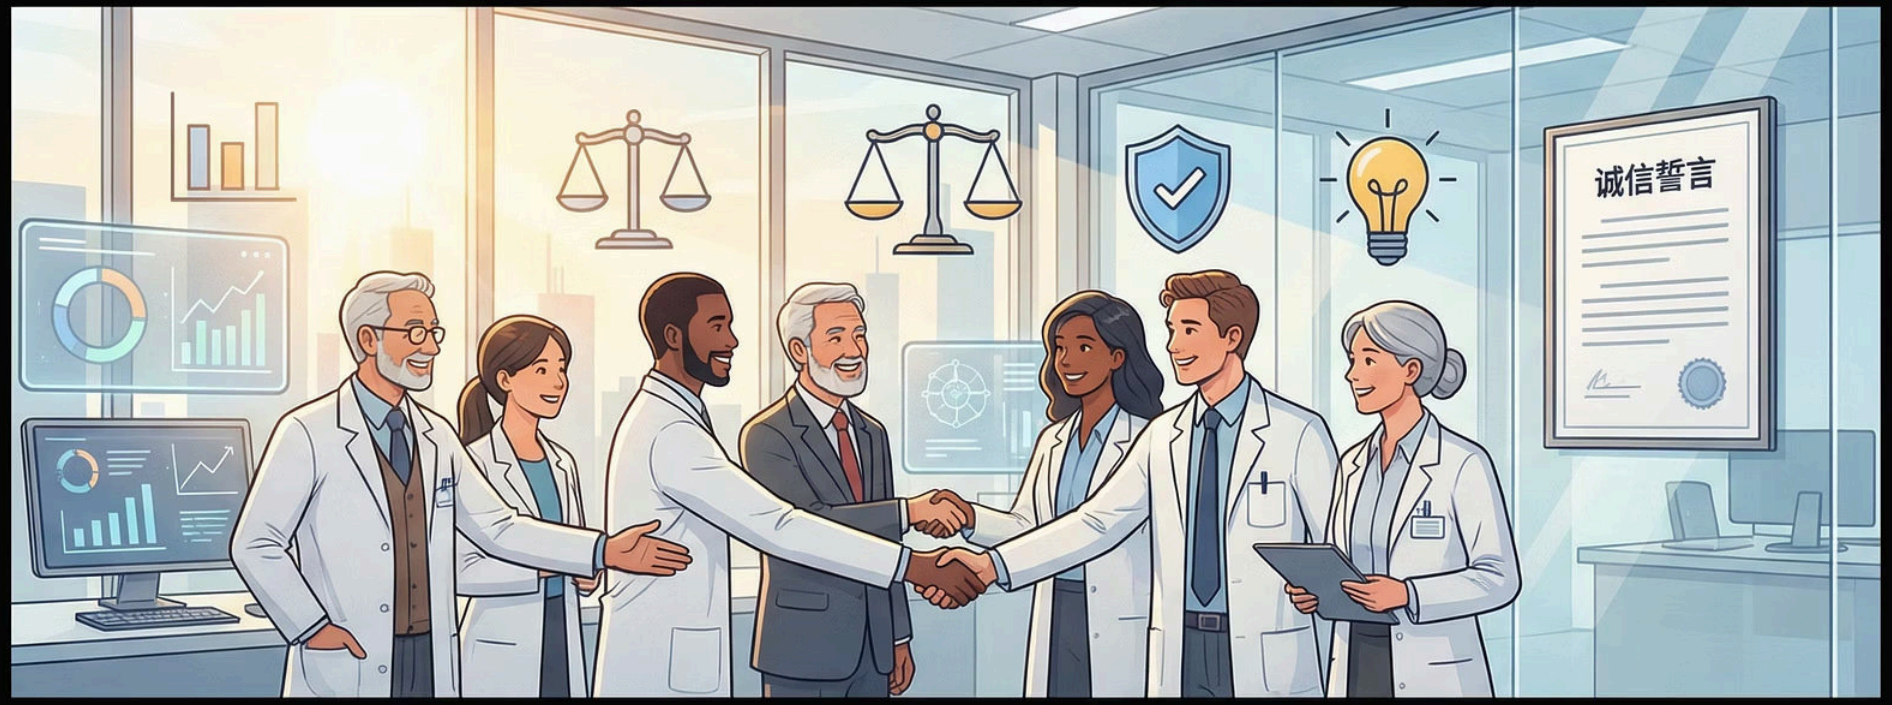
SuperCLUE：中文AI评估的里程碑

专门针对中文语言模型的综合评估基准
包含理解、生成、推理等多项能力测试
推动中文AI技术发展和应用落地



SuperCLUE标志，中文文本处理界面，显示各种中文NLP任务

构建可信AI评估体系：我们的使命



坚持科学严谨的评估态度

拒绝数据造假和指标操纵

建设公平透明的评估环境

为AI技术健康发展贡献力量

握手的科学家们，背景是透明的AI评估实验室，阳光透过窗户洒在诚信誓言上