

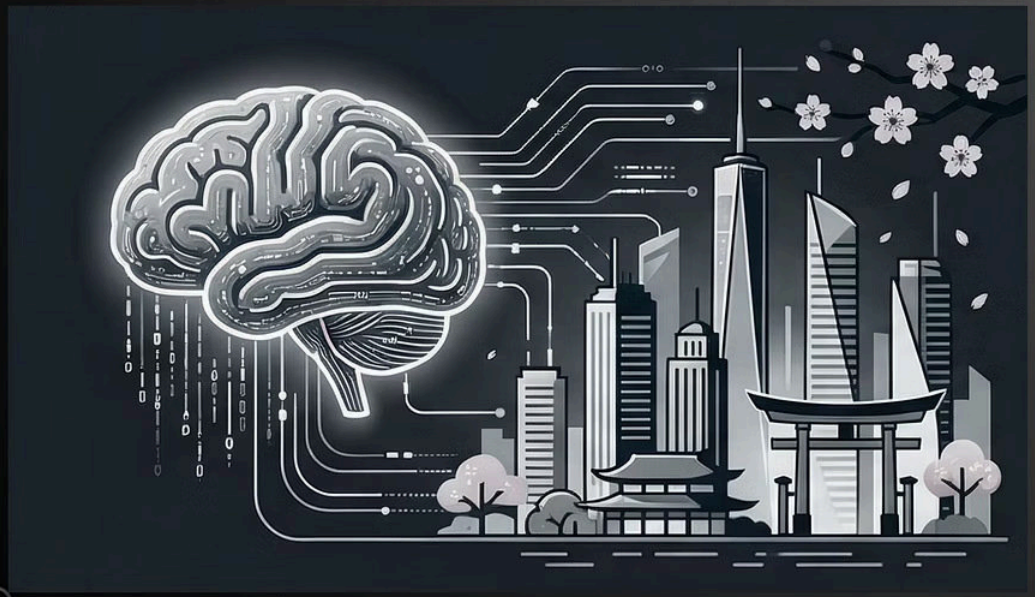
AI算力普惠：用技术突破封锁的使命

推理优化与算力民主化的技术革命

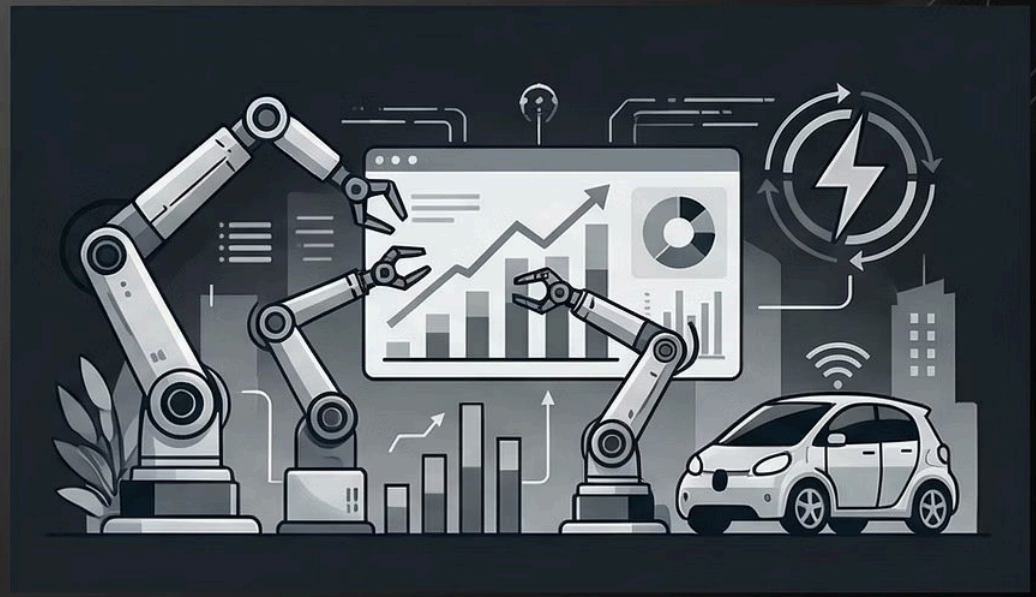


AI时代的

Innovation & Future



AI drives global transformation, optimizing industries and enhancing human capability.
智能互联，创新未来。



Applications include smart automation, predictive analytics, and sustainable development.
数据驱动，高效智能。

硬件封锁的铁幕



2022年10月，美国对华实施最严厉的AI芯片出口管制

A100、H100等高端GPU被全面禁售，试图从根源掐断中国AI发展

受限芯片参数：算力 > 4800 TOPS，显存带宽 > 600 GB/s

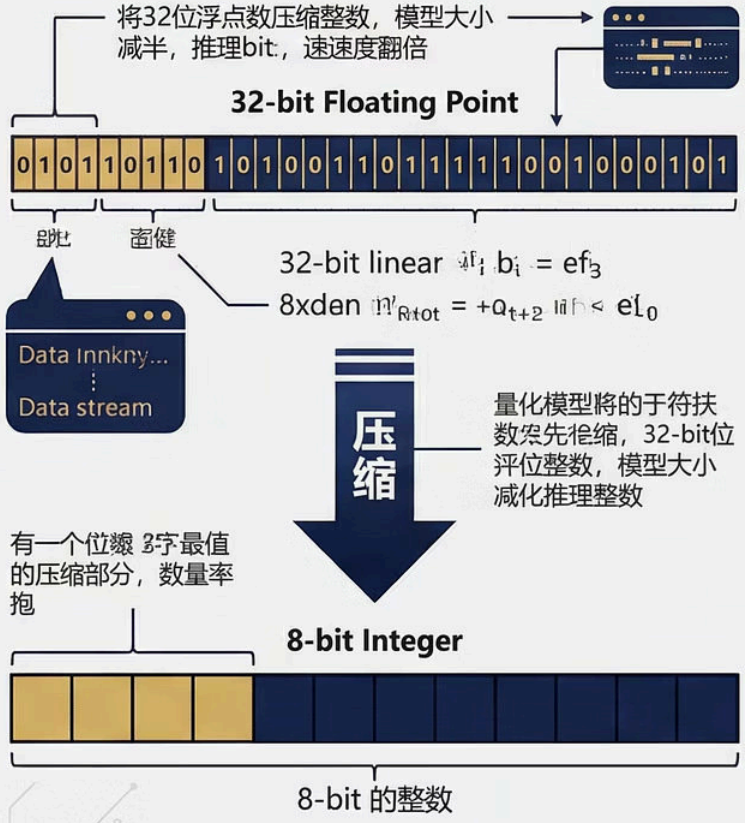
绝境中的思考

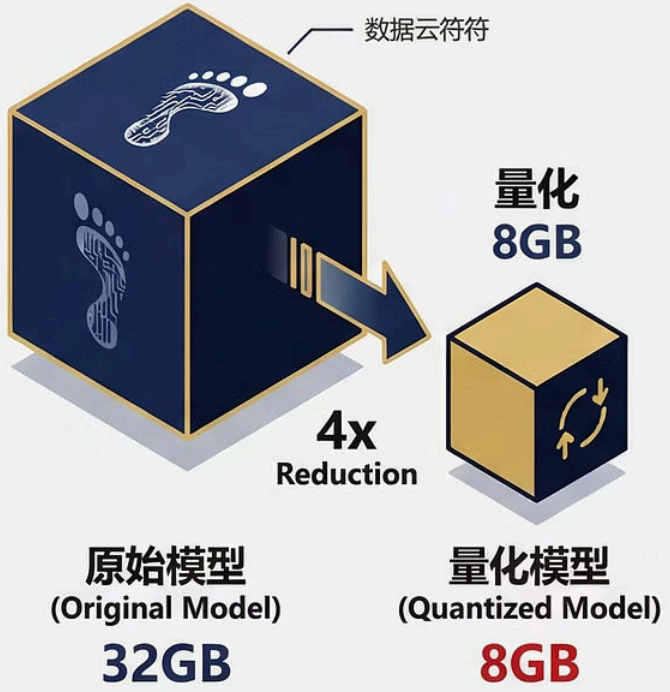
中国AI研究者深夜在实验室思考，墙上贴满算法公式



窗外是被封锁的港口，
室内是闪烁的代码屏幕

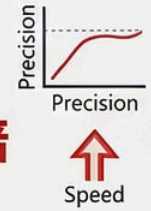
量化技术：压缩的艺术

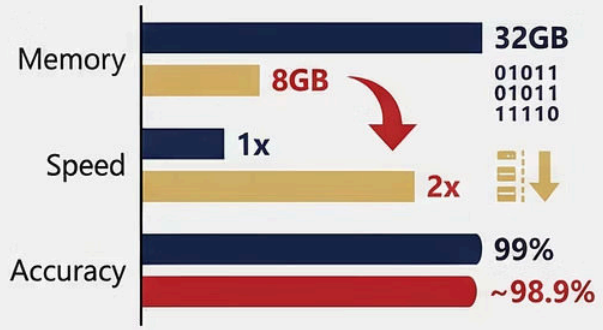




将32位浮点数压缩到8位整数，模型大小减半，推理速度翻倍

精度损失不到1%，算力需求降低4-8倍



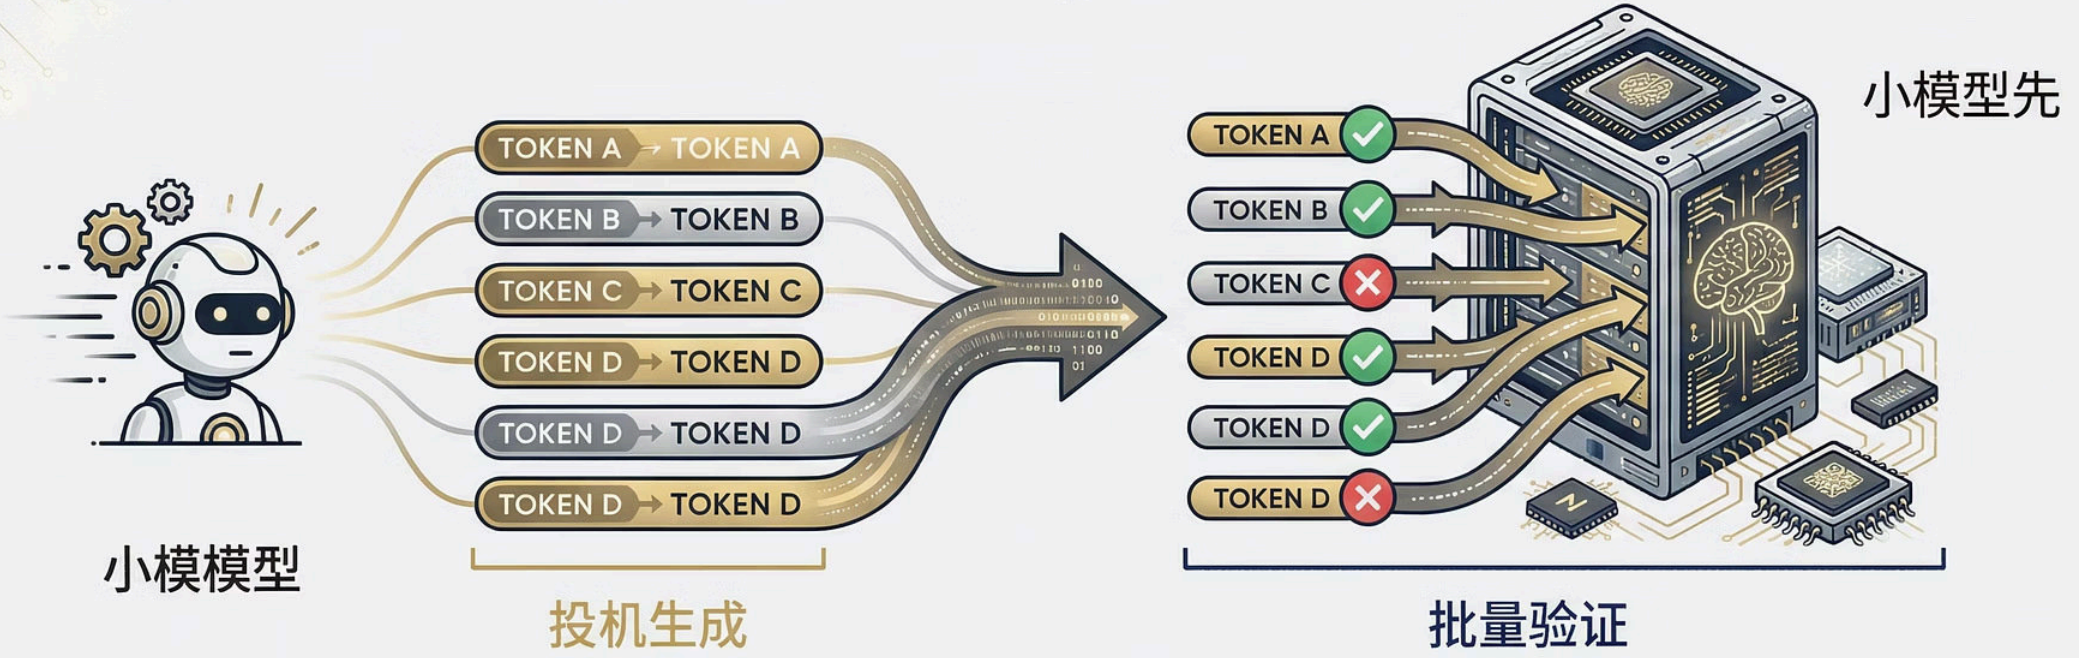


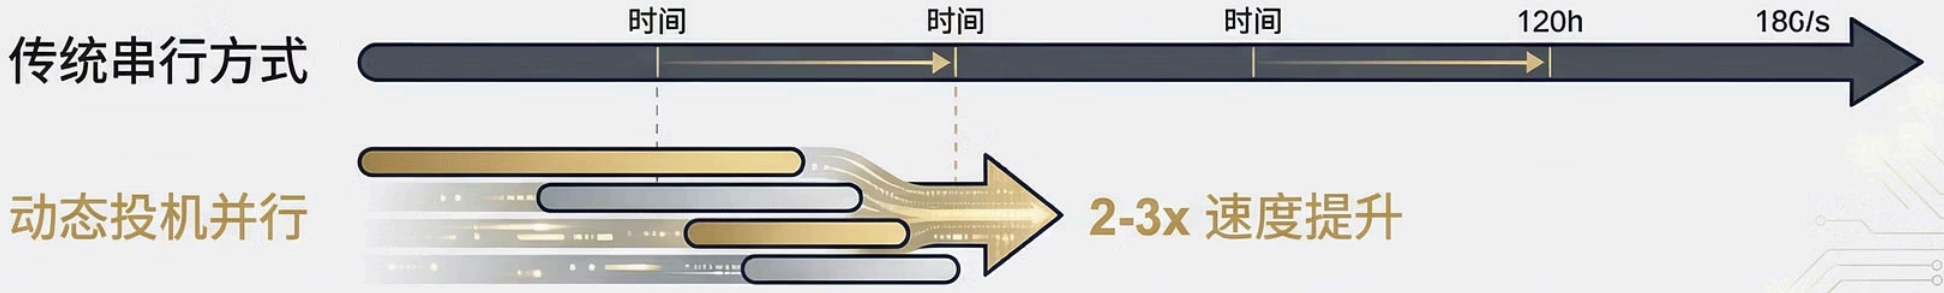
量化实战：四行代码的奇迹



这四行代码展示了利用预训练模型进行量化实战的核心。通过简洁的调用，即可实现复杂的语言模型加载与应用。

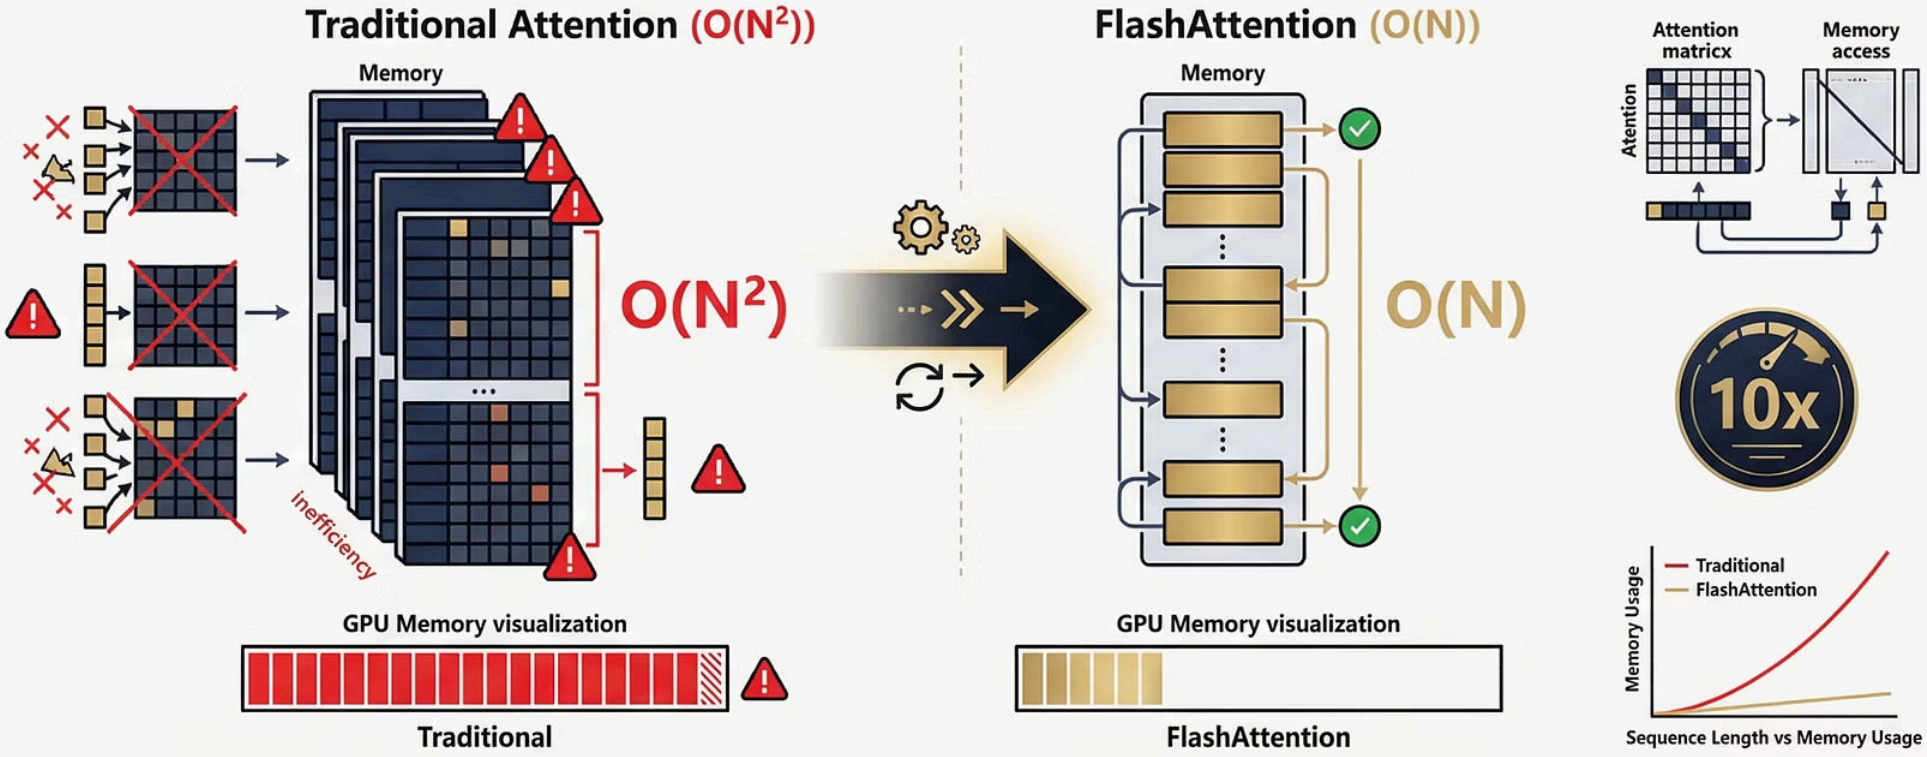
投机采样：预测未来的智慧





FlashAttention：注意力的革命

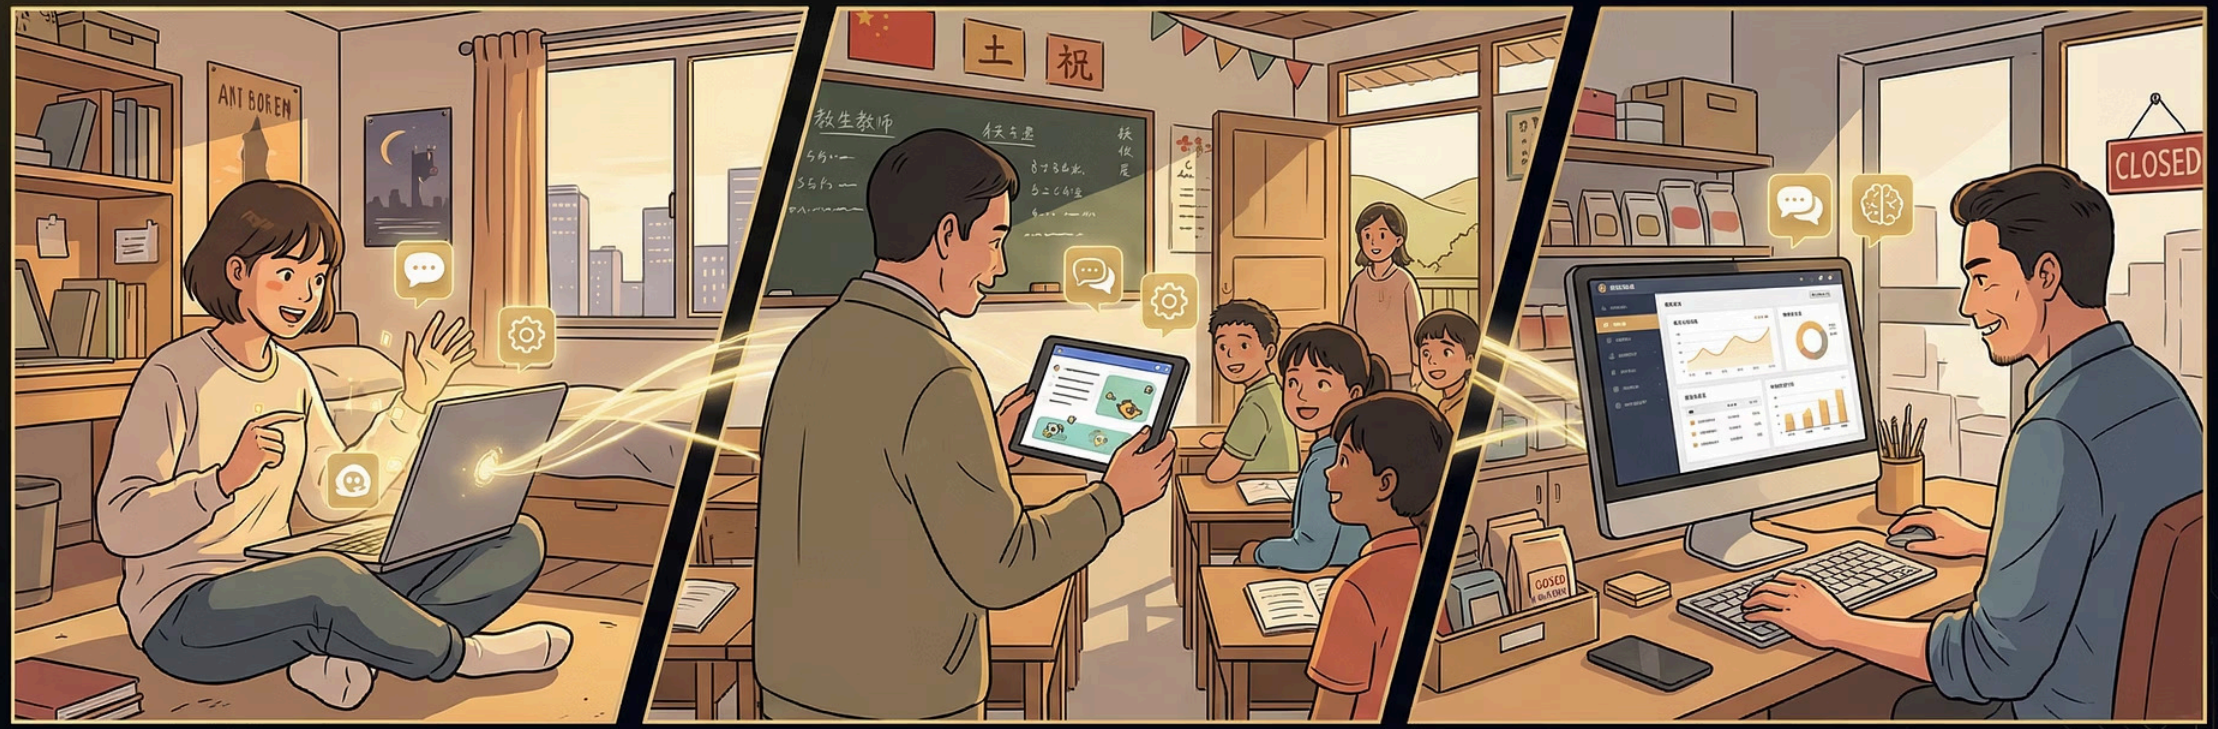
重新设计注意力计算，显存使用降低到O(N)，长文本处理速度提升10倍



不是硬件不够强，是算法不够巧

普惠AI的星星之火

从清华学生宿舍到偏远山区学校，人人都能用上AI助手



算力门槛降低90%，让技术创新不再是特权

90%成本降低 ↓

自主可控的智能生态

面对封锁，我们用算法
优化突破硬件限制



代码改变世界的力量

一行代码优化，
可能影响千万开发者
的创新能力



技术无国界，
但技术人有祖国，
有责任让AI技术
真正服务人民

1,000,000+ 开发者受益

未来：算力普惠的中国梦



万家灯火的城市夜景，每盏灯光都代表一个AI应用在运行。
从算力稀缺到算力普惠，从技术封锁到自主创新的完美蜕变。