RAG系统知识产权合规挑战：技术创新与法律边界的平衡艺术

深入解析检索增强生成系统中的版权风险与工程化合规方案



结合《著作权法》与OpenAI案例的实践指南

RAG系统架构与版权风险点

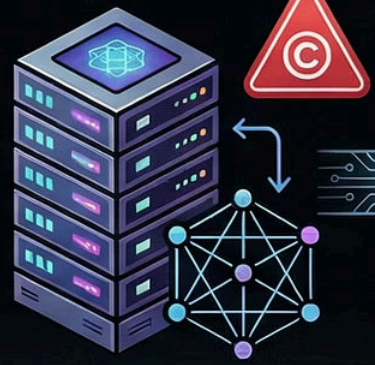
RAG系统通过检索外部知识库增强生成能力，但每个环节都潜藏版权合规风险。数据爬取、内容清洗、向量化存储、检索匹配、生成引用——每一步都可能触碰法律红线。



1. 数据爬取
(Data Crawling)



2. 内容清洗
(Content Cleaning)



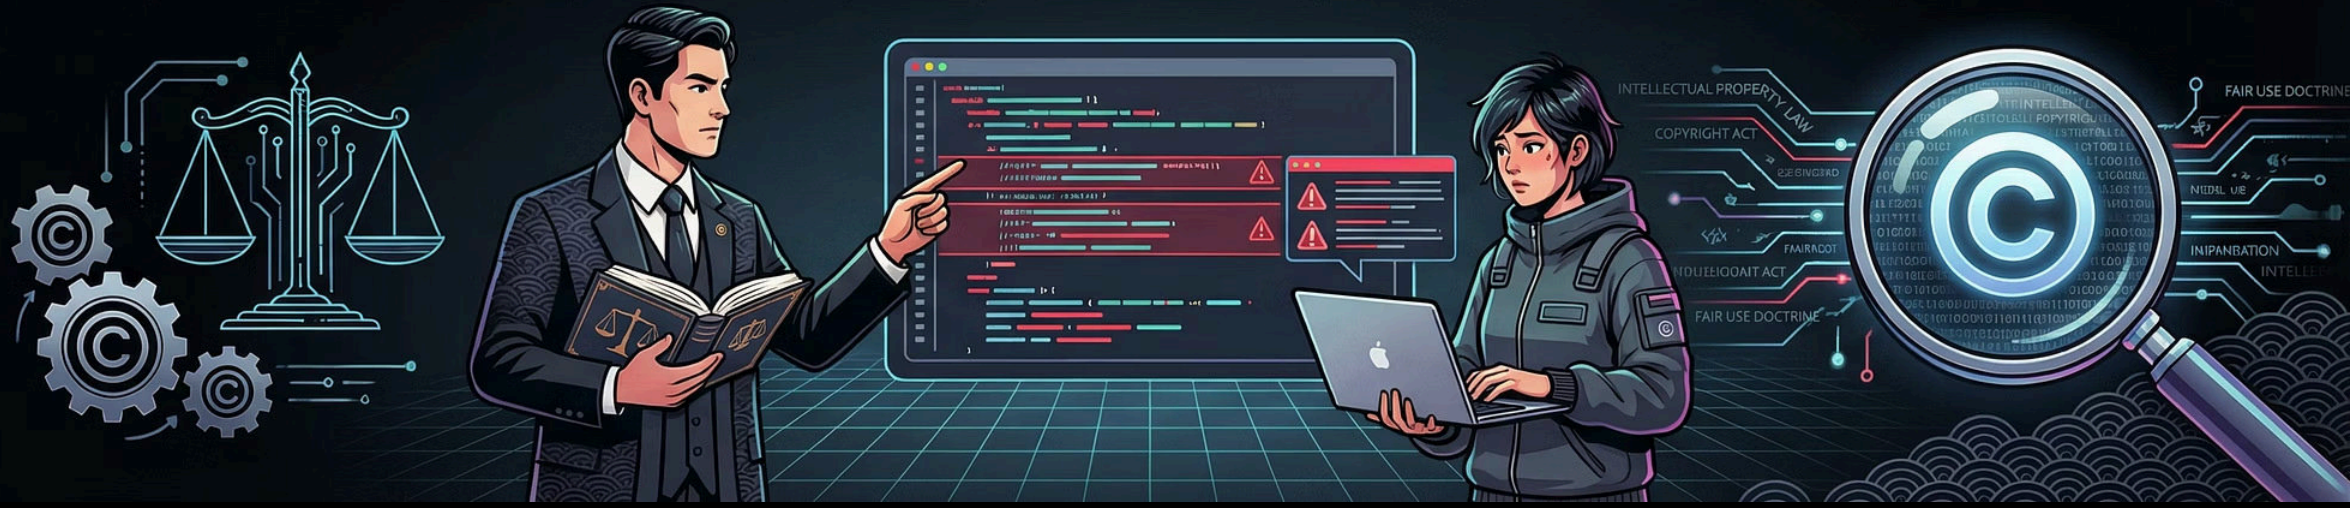
3. 向量化存储
(Vectorization Storage)



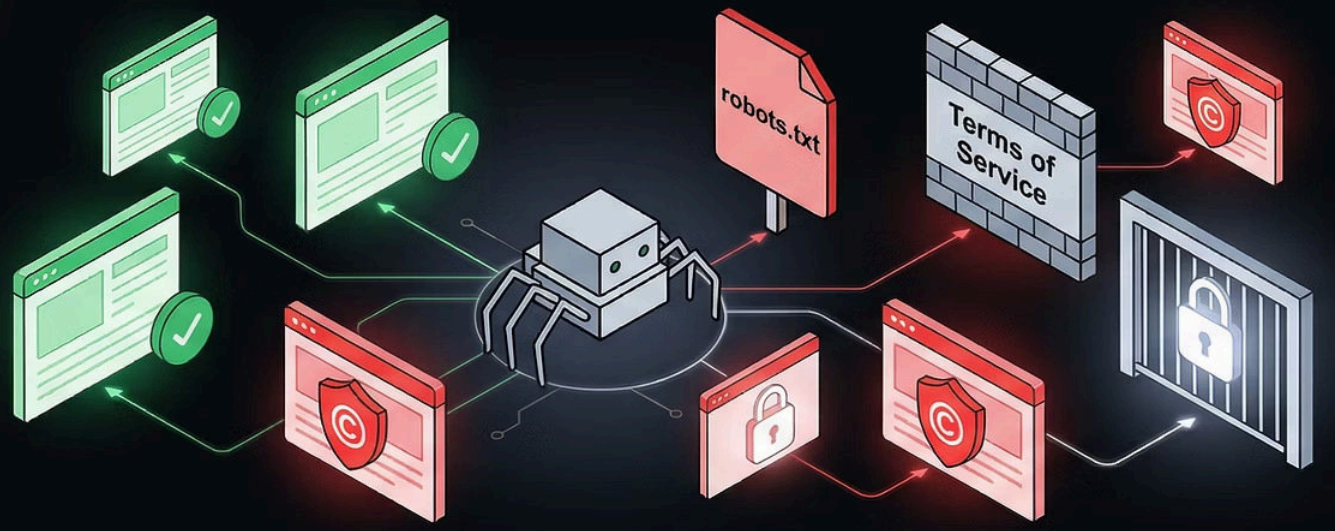
4. 检索匹配
(Retrieval Matching)



5. 生成引用
(Generation & Citation)

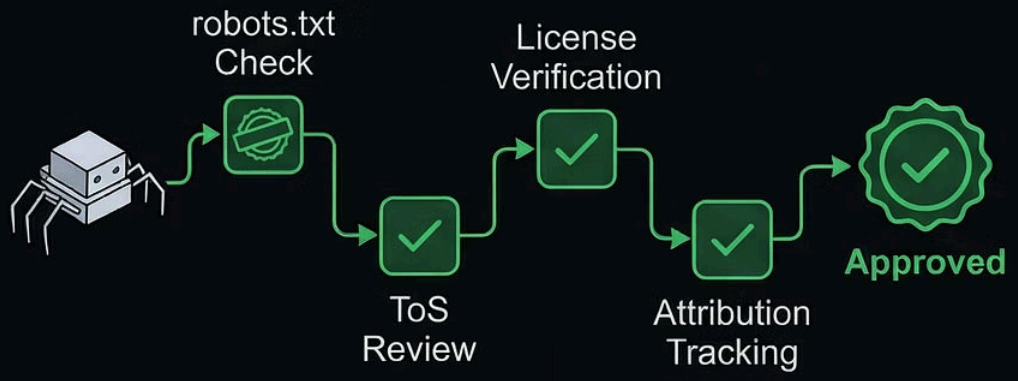


数据爬取的版权陷阱

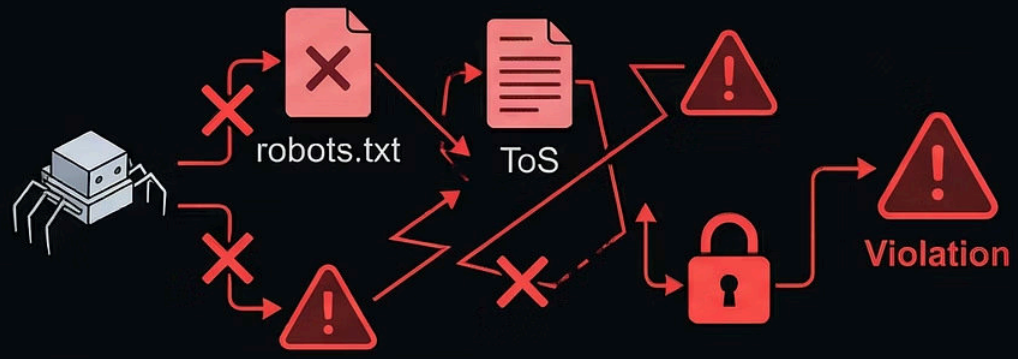


网络爬虫看似技术行为，实则每次抓取都是对他人知识产权的潜在侵犯。robots.txt文件、网站条款、付费墙——这些都是法律边界的明确标识。

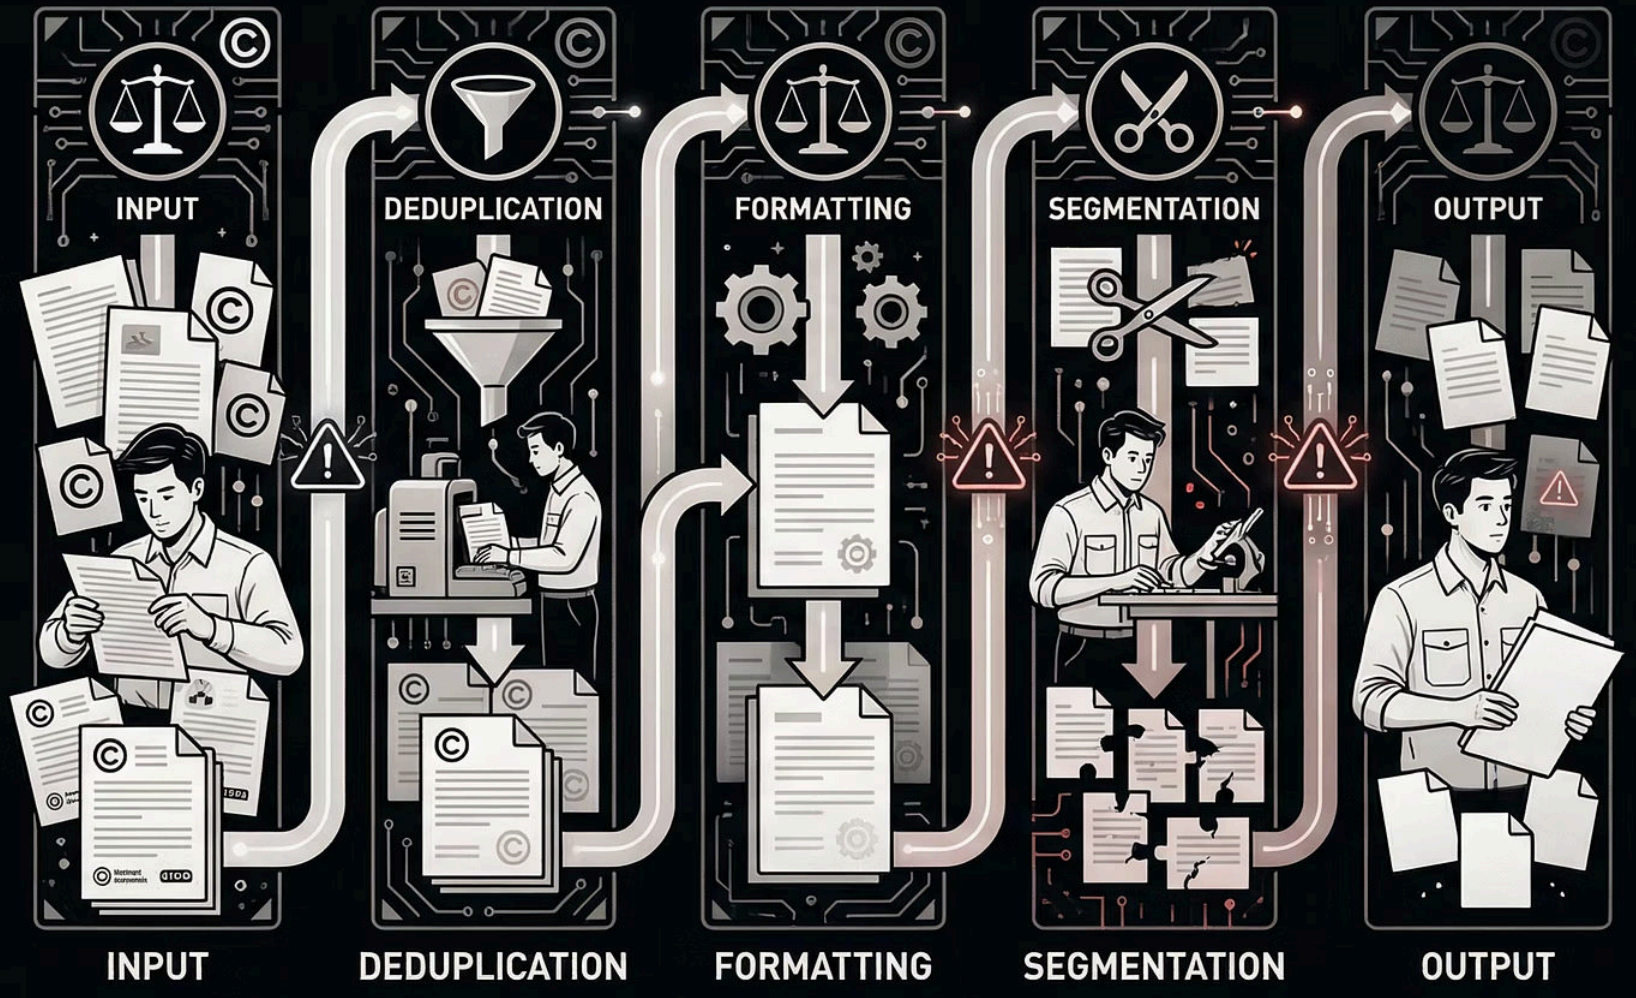
LEFT SIDE : 合规爬取路径



RIGHT SIDE : 违规路径



内容清洗中的合规盲区



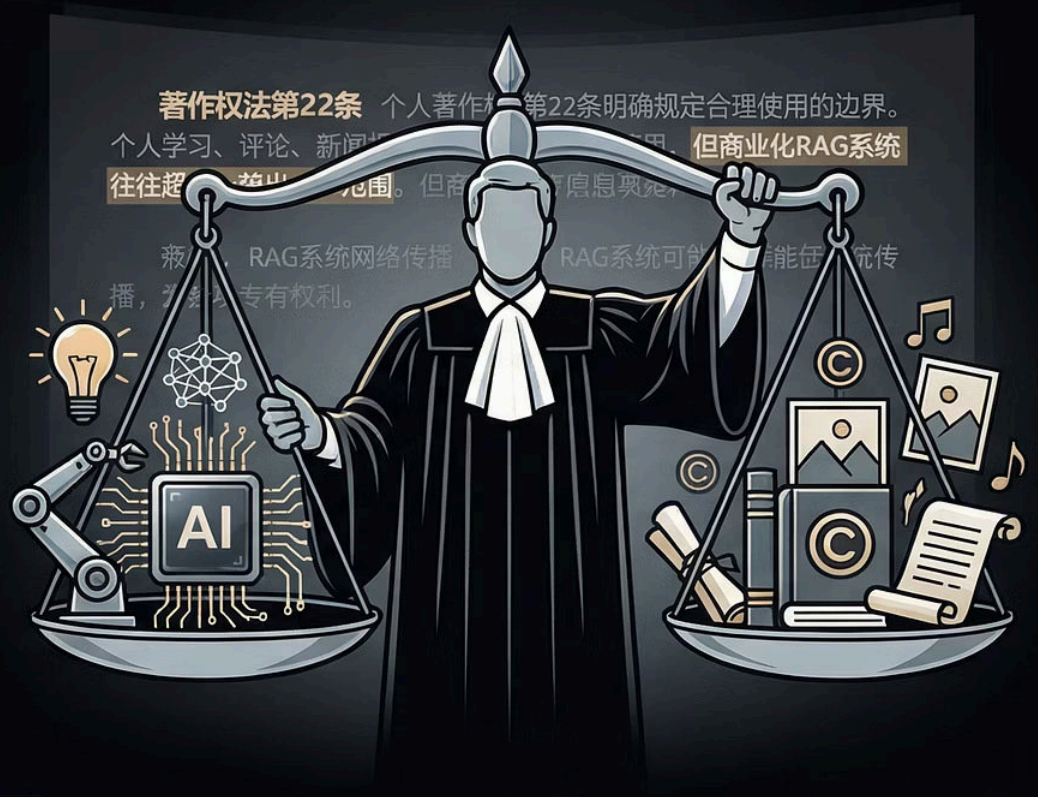
数据清洗不仅是技术预处理，更是版权风险的放大器。
去重、格式化、分割重组——每个操作都可能改变原作品的完整性和归属。

原始版权信息在清洗过程中的丢失，为后续合规埋下隐患。



《著作权法》对AI系统的约束

中国《著作权法》第22条明确规定合理使用的边界。个人学习、评论、新闻报道可以合理使用，但商业化RAG系统往往超出这一范围。



复制权、发行权、信息网络传播权——RAG系统可能同时涉及多项专有权利。

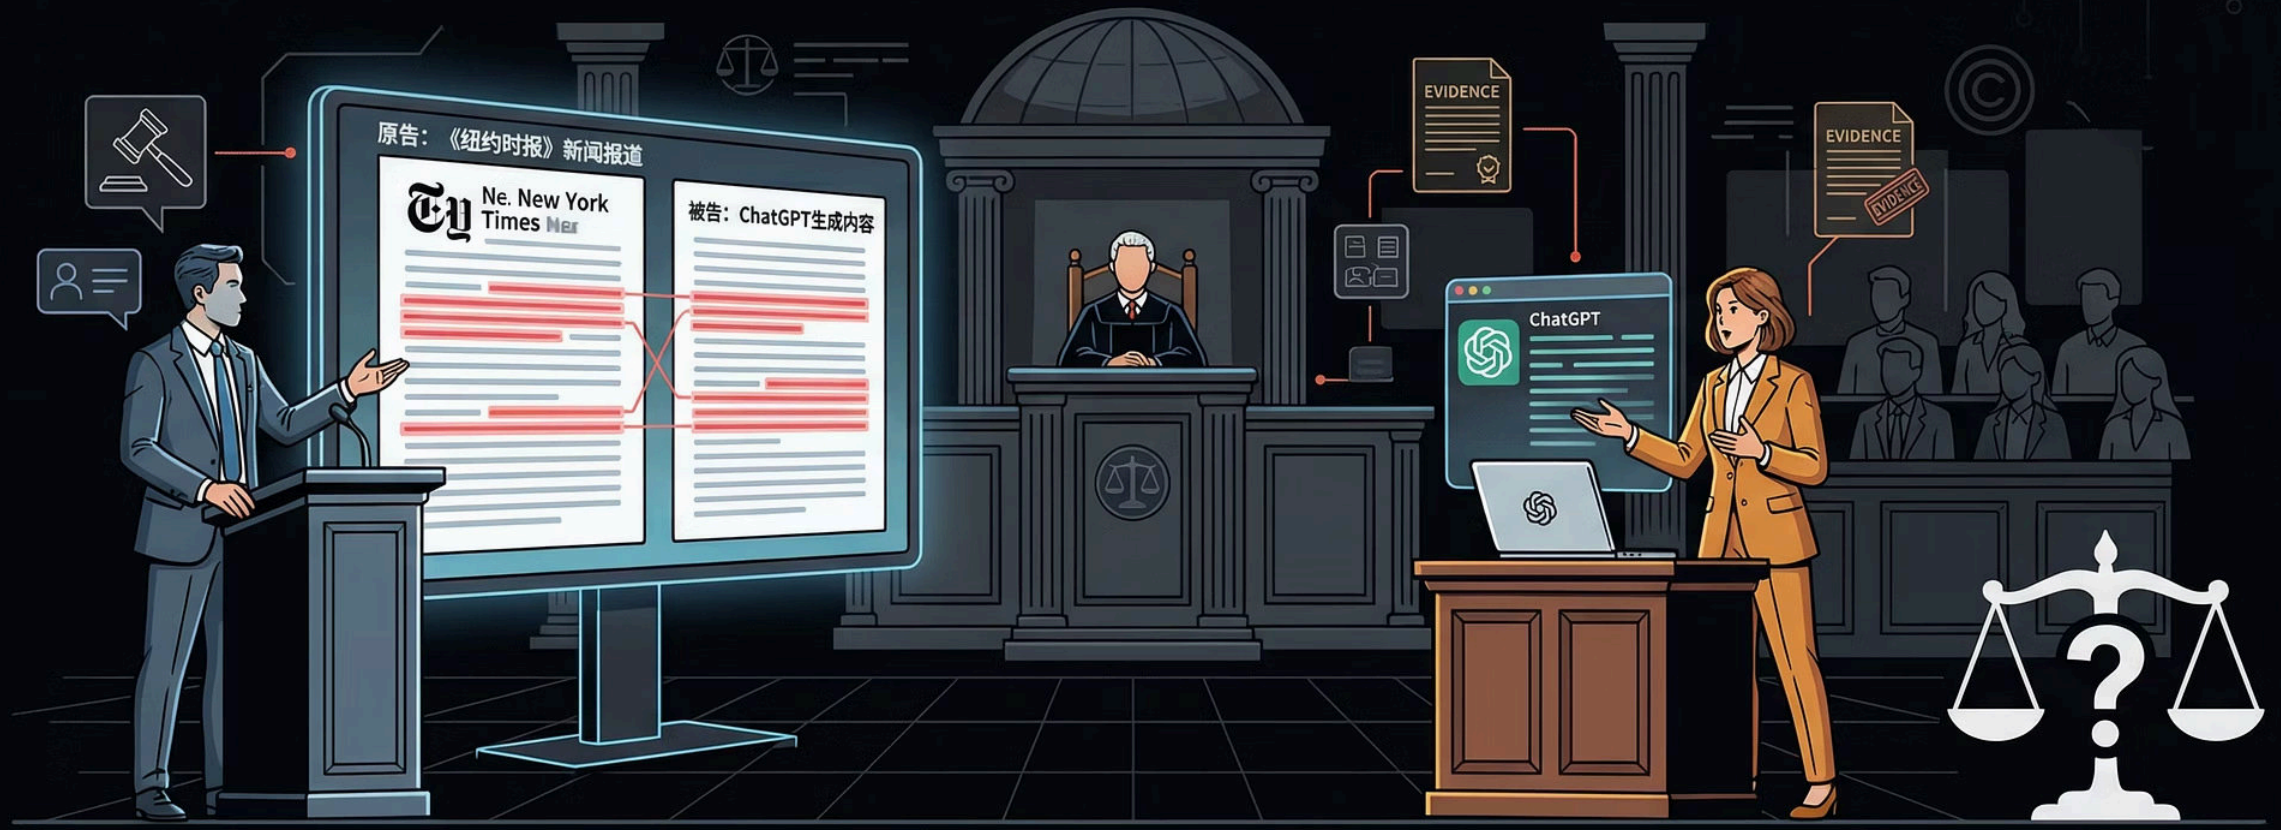
复制权

发行权

信息网络传播权

《纽约时报》诉OpenAI案例解析

2023年12月，《纽约时报》状告OpenAI版权侵权，指控其未经授权使用新闻内容训练模型。
案件焦点：大规模语言模型训练是否构成合理使用？判决结果将为全球AI行业设定重要法律先例。



Fair Use判定的四要素框架

使用目的

目的在于判断使用行为是出于商业盈利还是非营利的教育/研究目的。转换性使用越显著，越有利于合理使用判定。



目的在于判断使用行为是出于商业盈盈利还是，趟于欺营利的捶育研究的果判定。

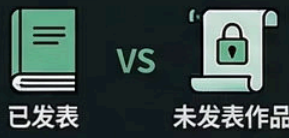


作品性质



作品的创意性和是是否已发表影响判定。

对事实性内容的合理使用范围通常比比对对高度创意性作品更广。



未发表作品享有更高保护，如有一哉狼人的蜷使使用判定，保裔量真素定。

使用比例

使用的数量和质量是关键。即使使用比例很小，但如果引用了月的核心内容，也不利于合理使用判定。



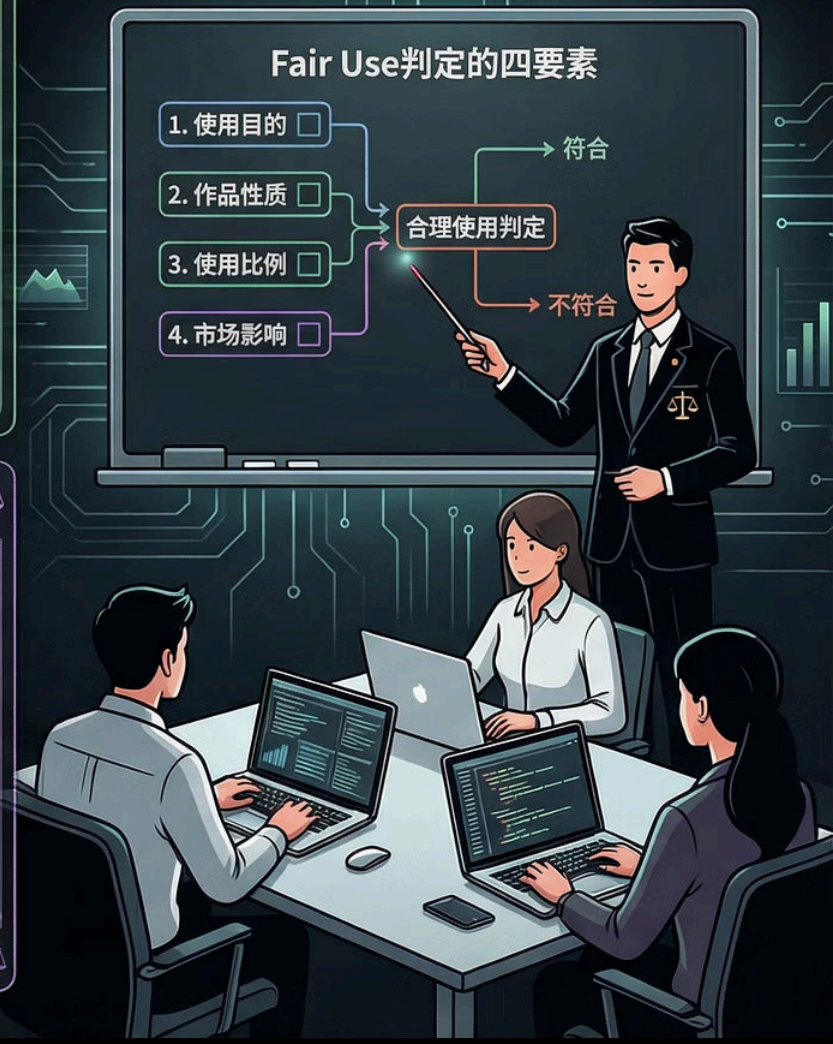


市场影响



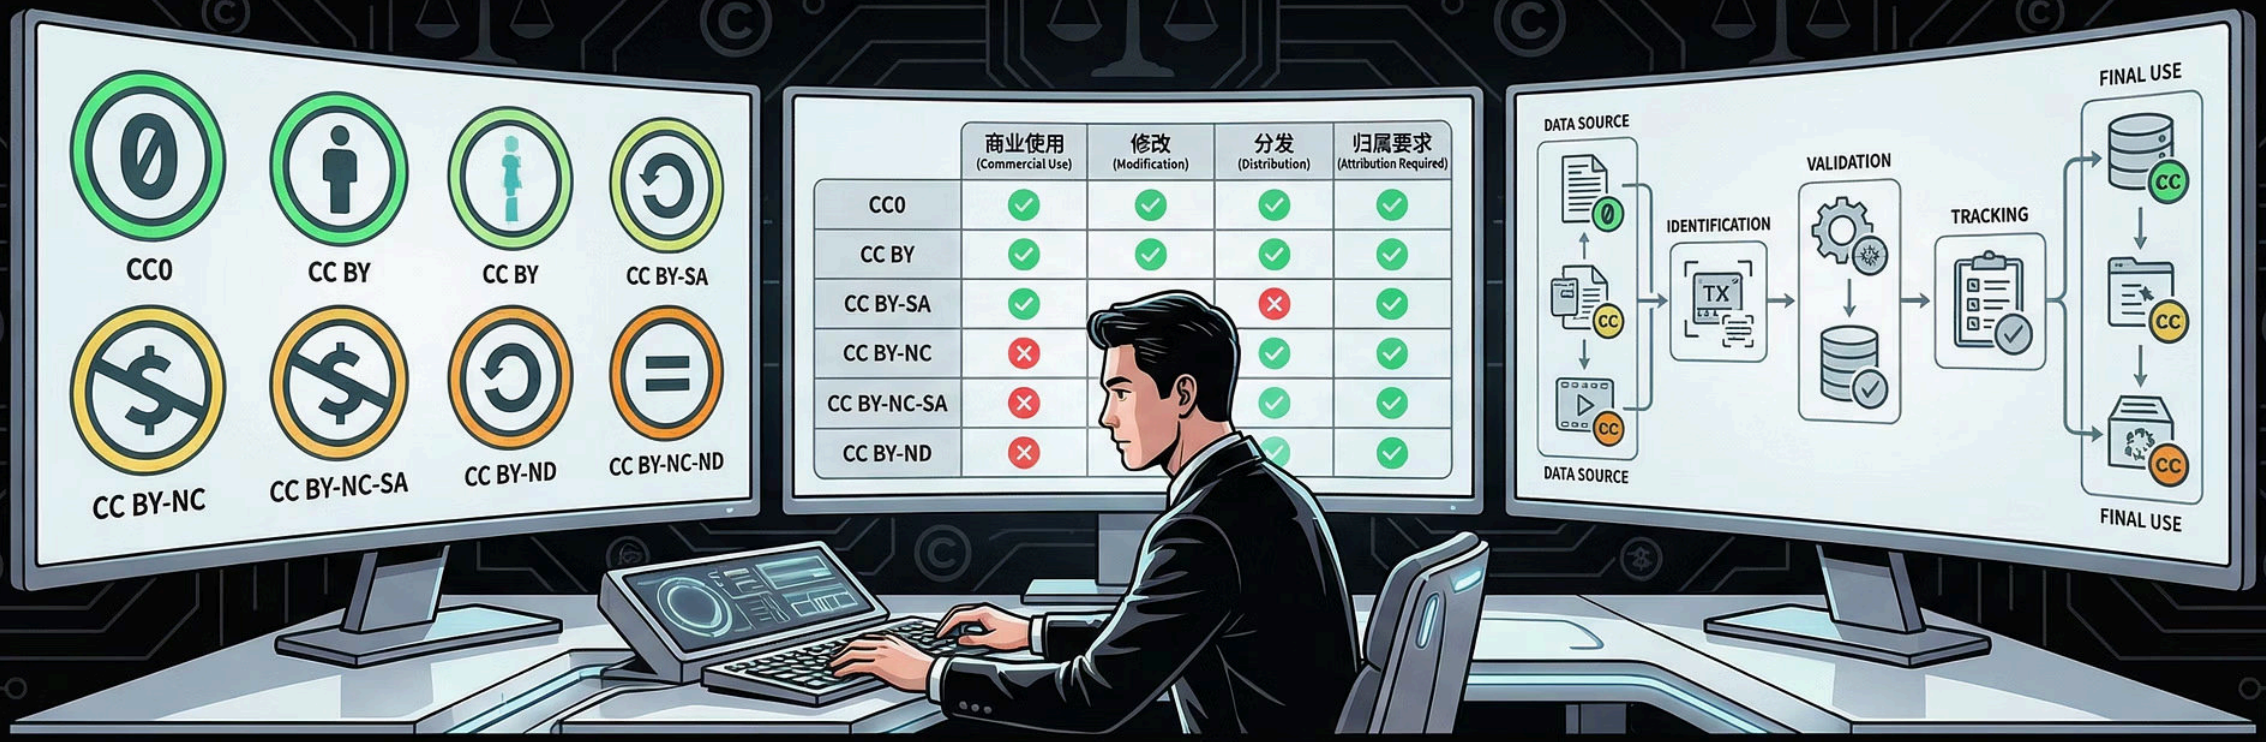
评估使用行为对原作品潜在市场或价值的损害。若使用行为导致原作品市场份额下降或被替代，则不利于合理使用。

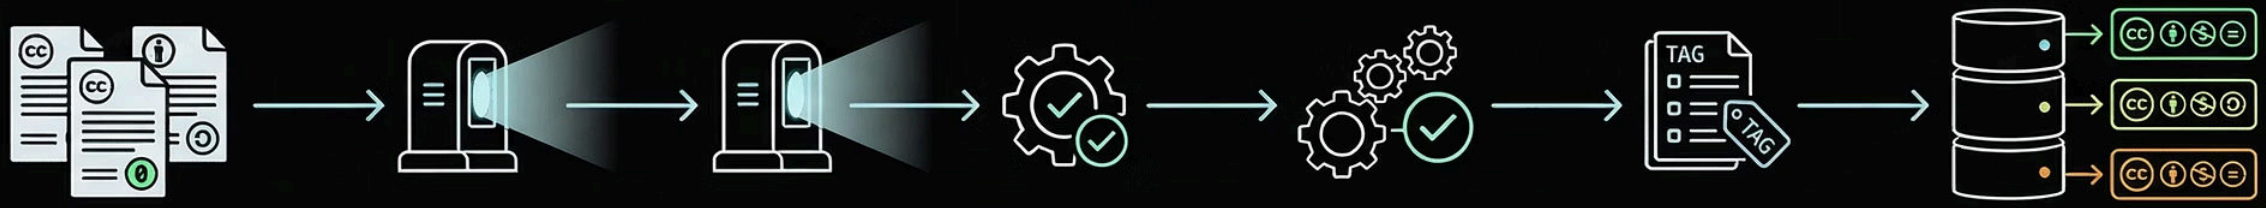




CC协议许可证管理系统

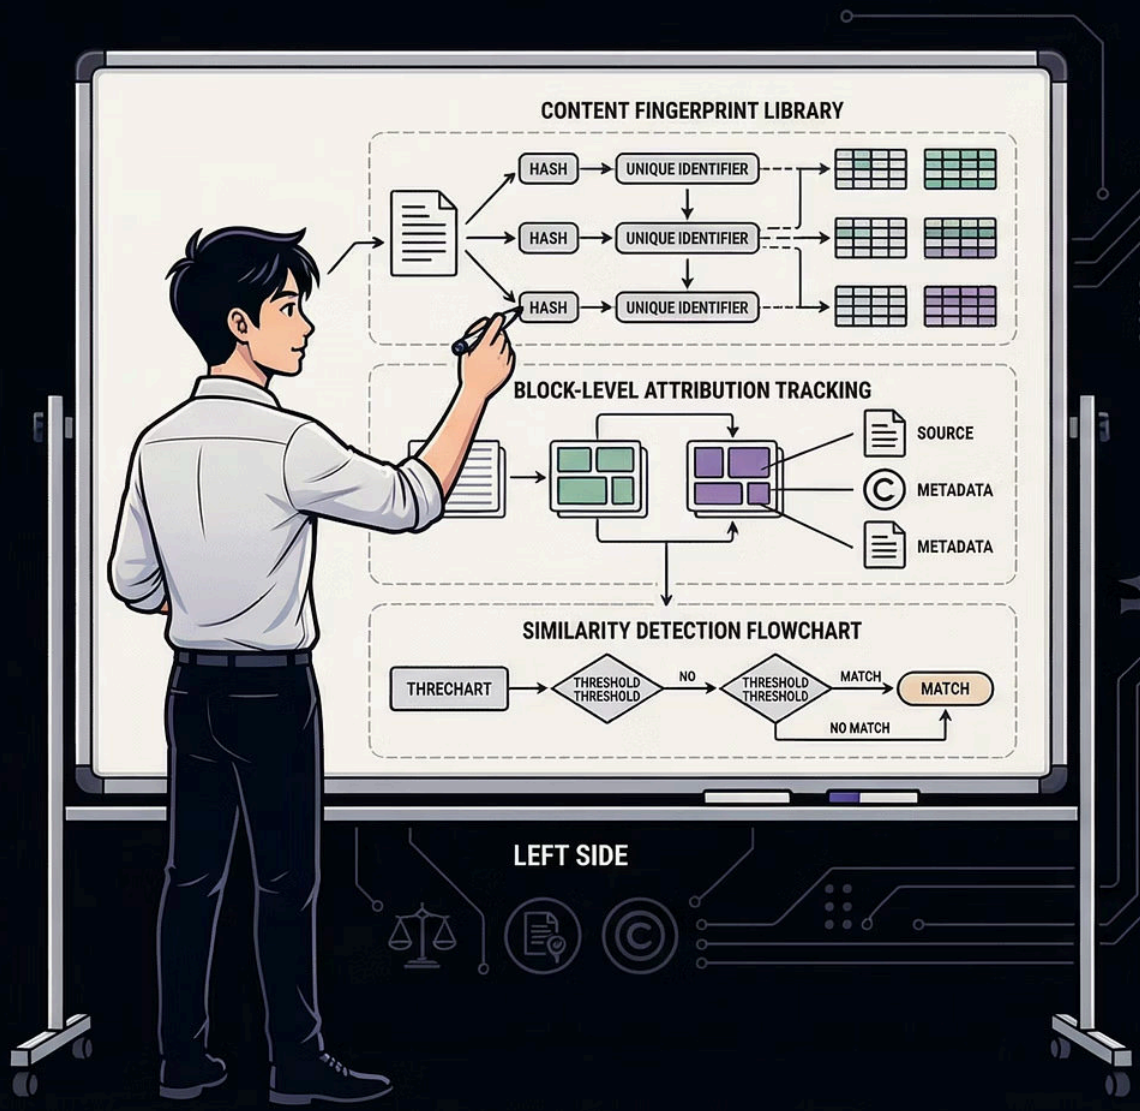
Creative Commons协议为开放内容使用提供了标准化框架。CC0、CC BY、CC BY-SA、CC BY-NC——不同协议对应不同使用权限。构建许可证识别、验证、追踪的自动化管理系统。



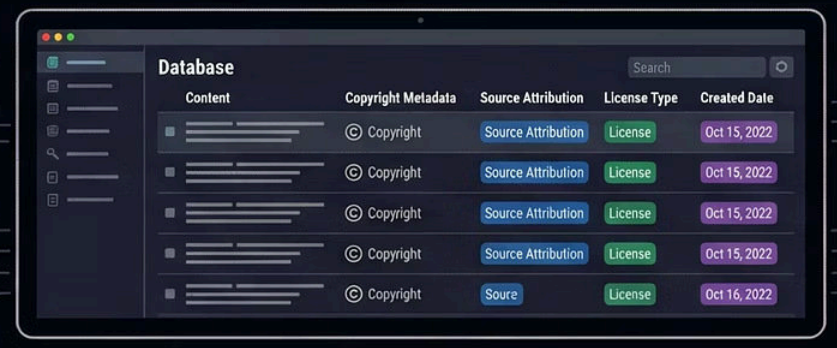


引用溯源算法的技术实现

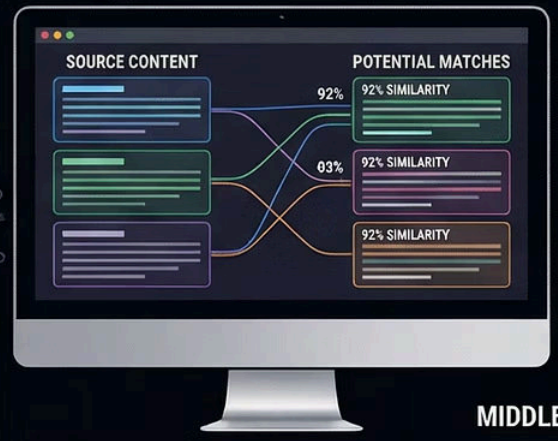
建立内容指纹库，为每个数据源创建唯一标识符。
实现块级别的版权归属追踪，确保引用链条完整可验证。
设计相似度检测算法，识别潜在的版权冲突内容。

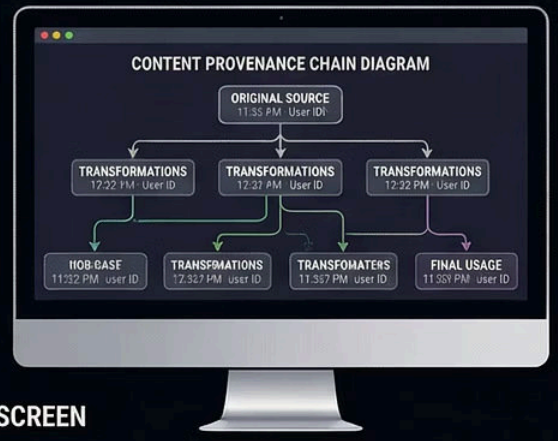


LEFT SIDE



TOP SCREEN



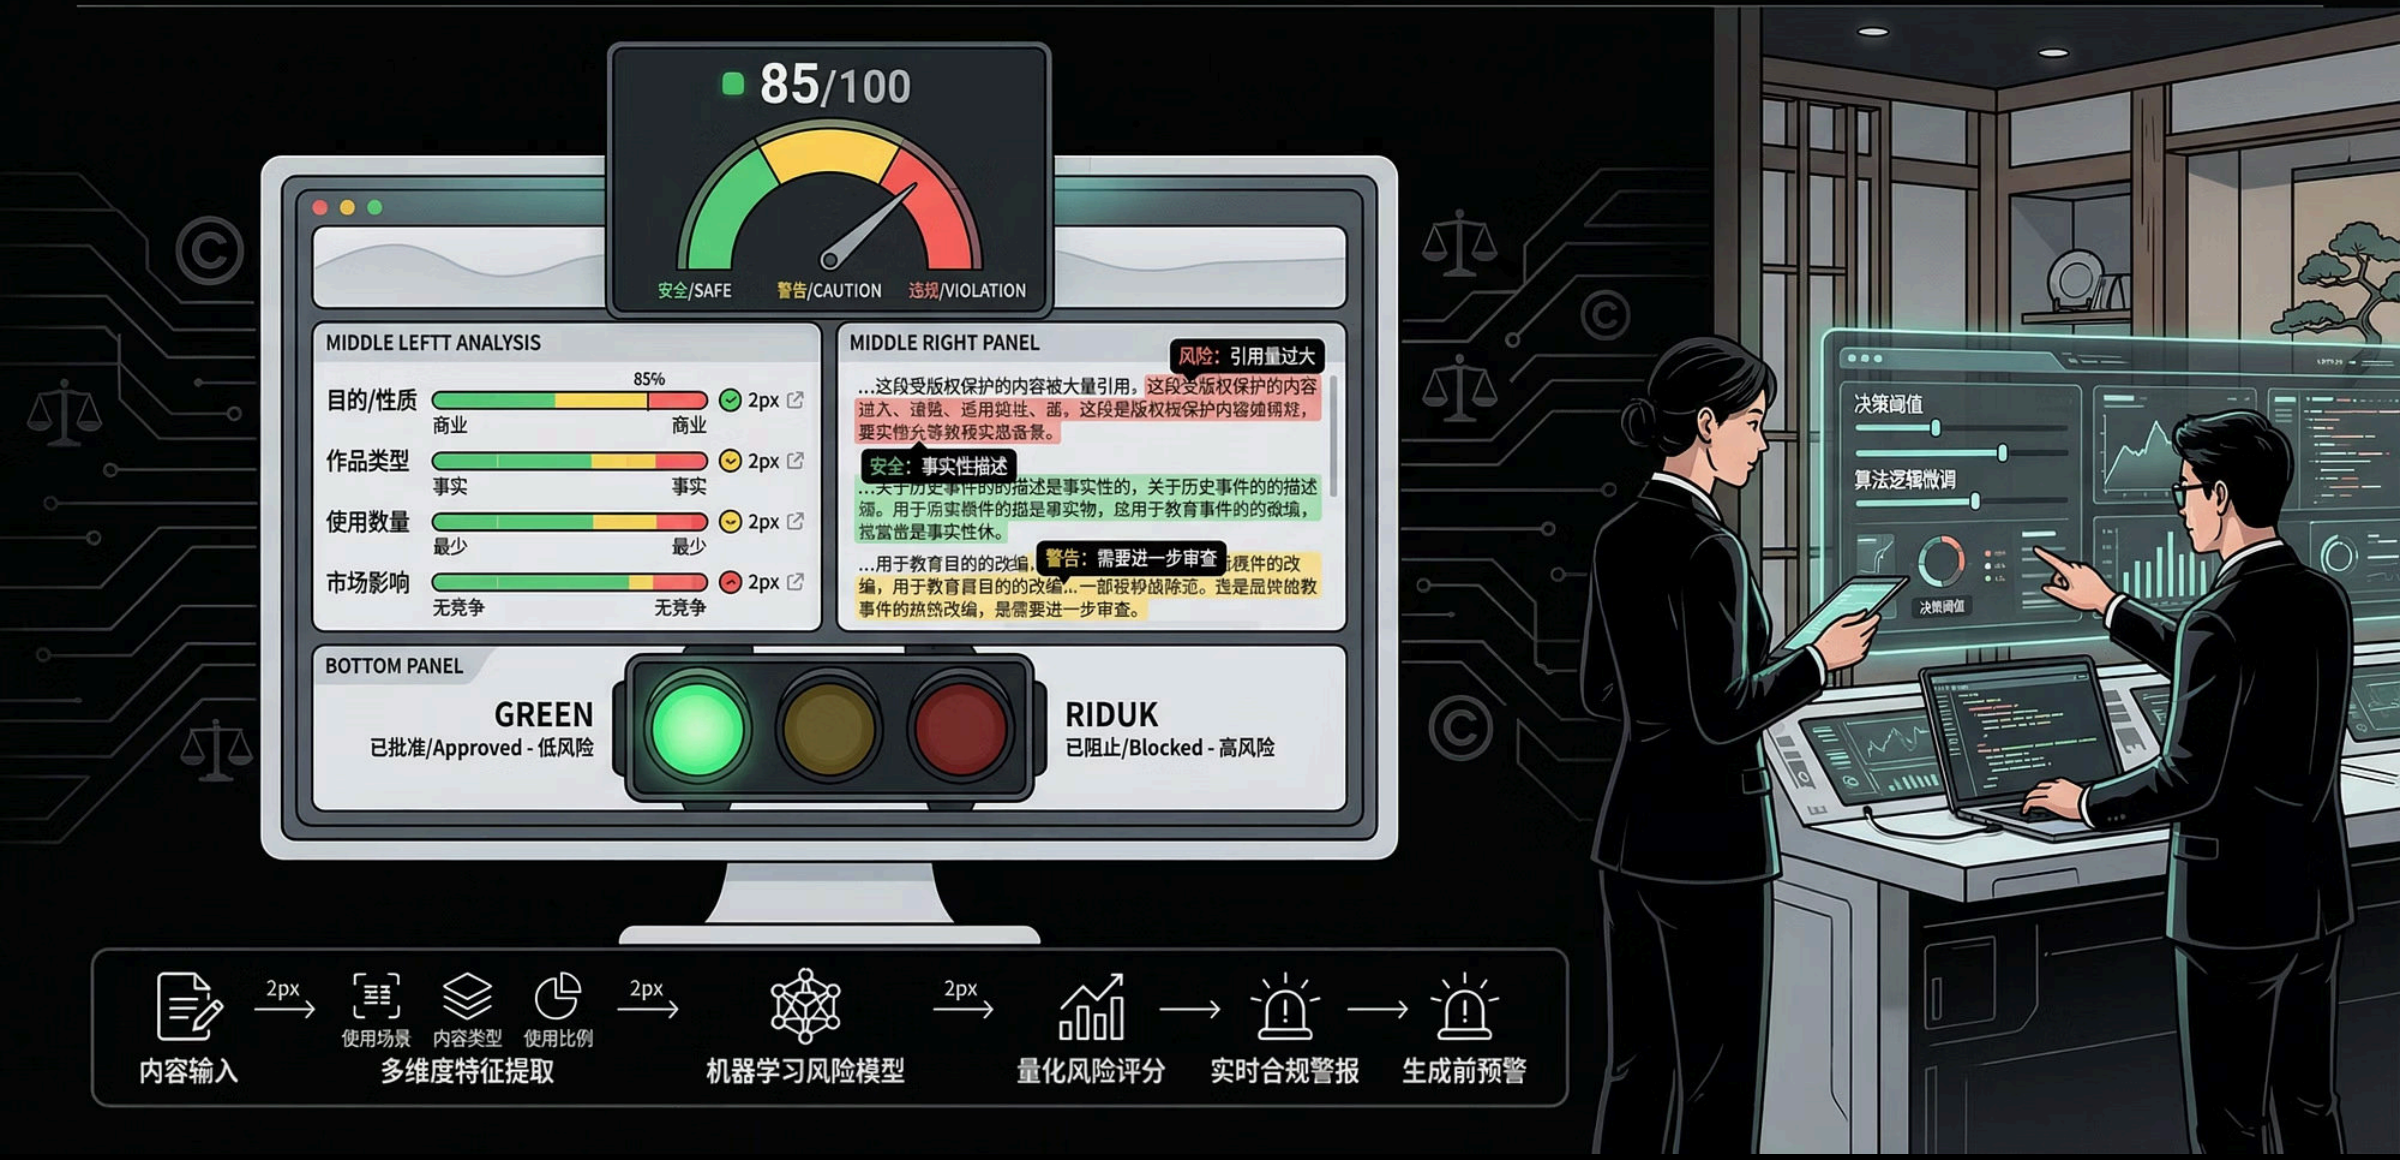


MIDDLE SCREEN



合理使用自动判定系统

基于四要素框架构建智能风险评估模型。结合使用场景、内容类型、使用比例等多维度特征进行风险量化。实现实时合规检查，在内容生成前进行版权风险预警。



第四章
平衡创新与保护的最佳实践



构建合规驱动的RAG系统架构



将版权合规作为系统设计的第一性原理，而非事后补救措施。建立多层次防护机制：源头筛选、过程监控、结果审查。

培养法律意识与技术能力并重的复合型人才队伍。