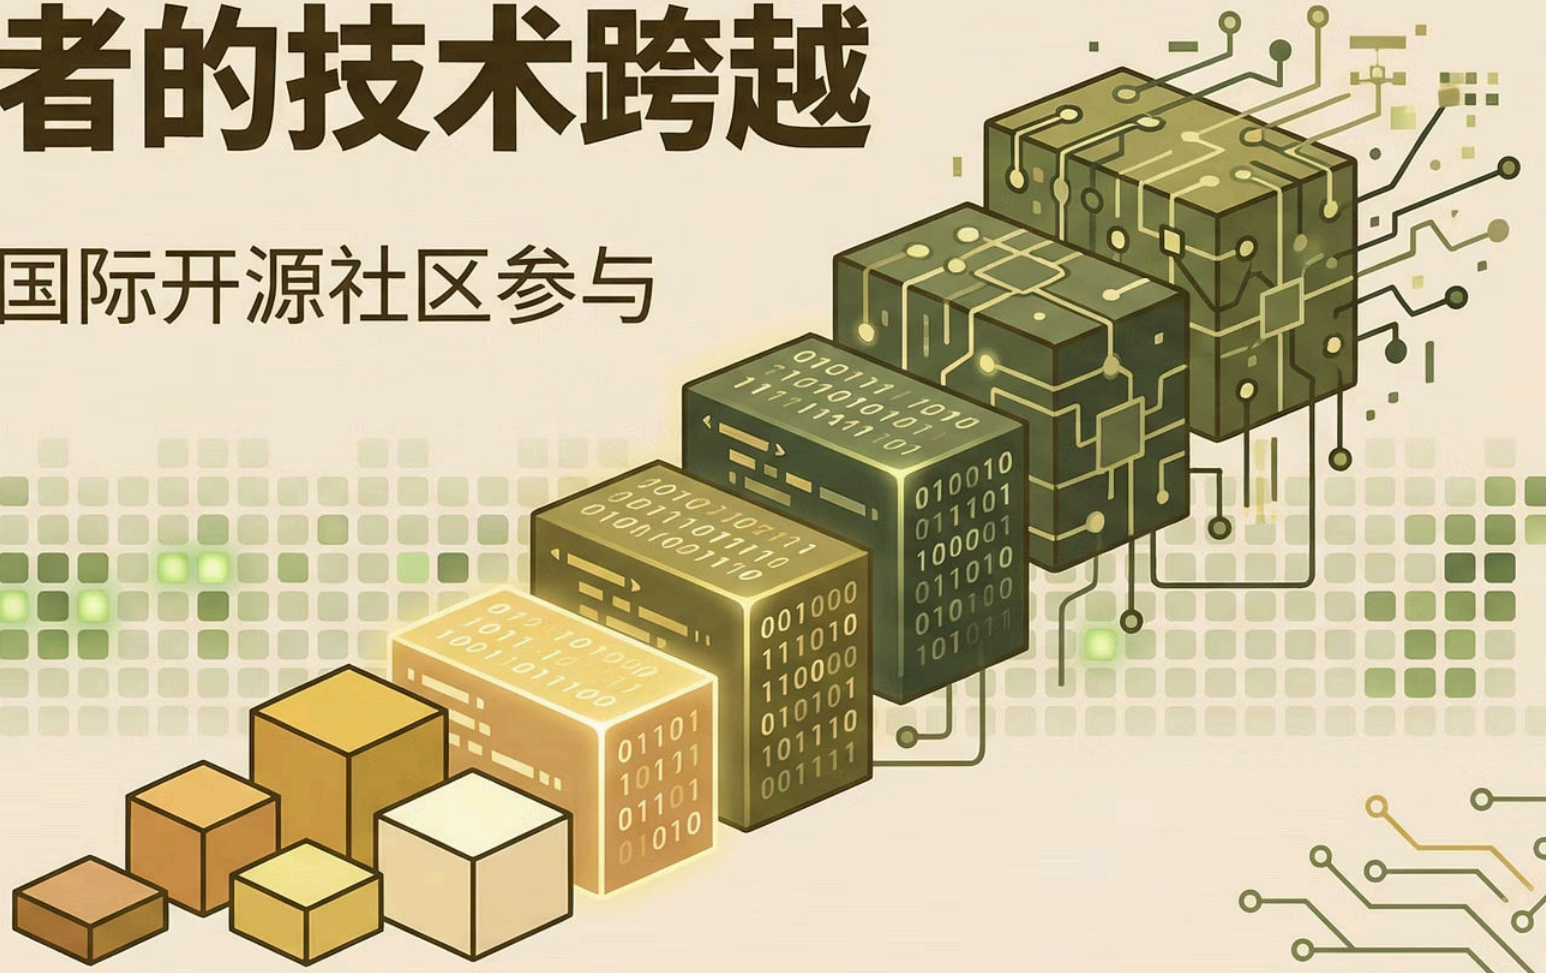
开源共建与自主创新：从学习者到贡献者的技术跨越

深度技术教育与国际开源社区参与





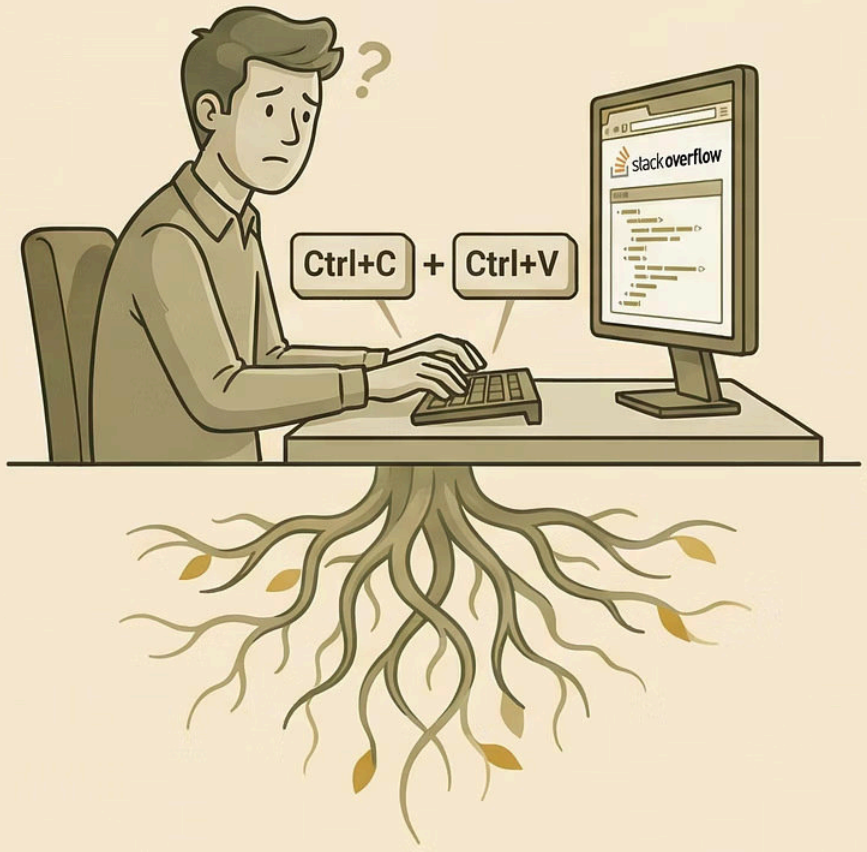
开源：学习的阶梯，而非止步的终点

- 持续参与，积累经验
- 贡献代码，拓展视野



拒绝

表面使用



深度理解

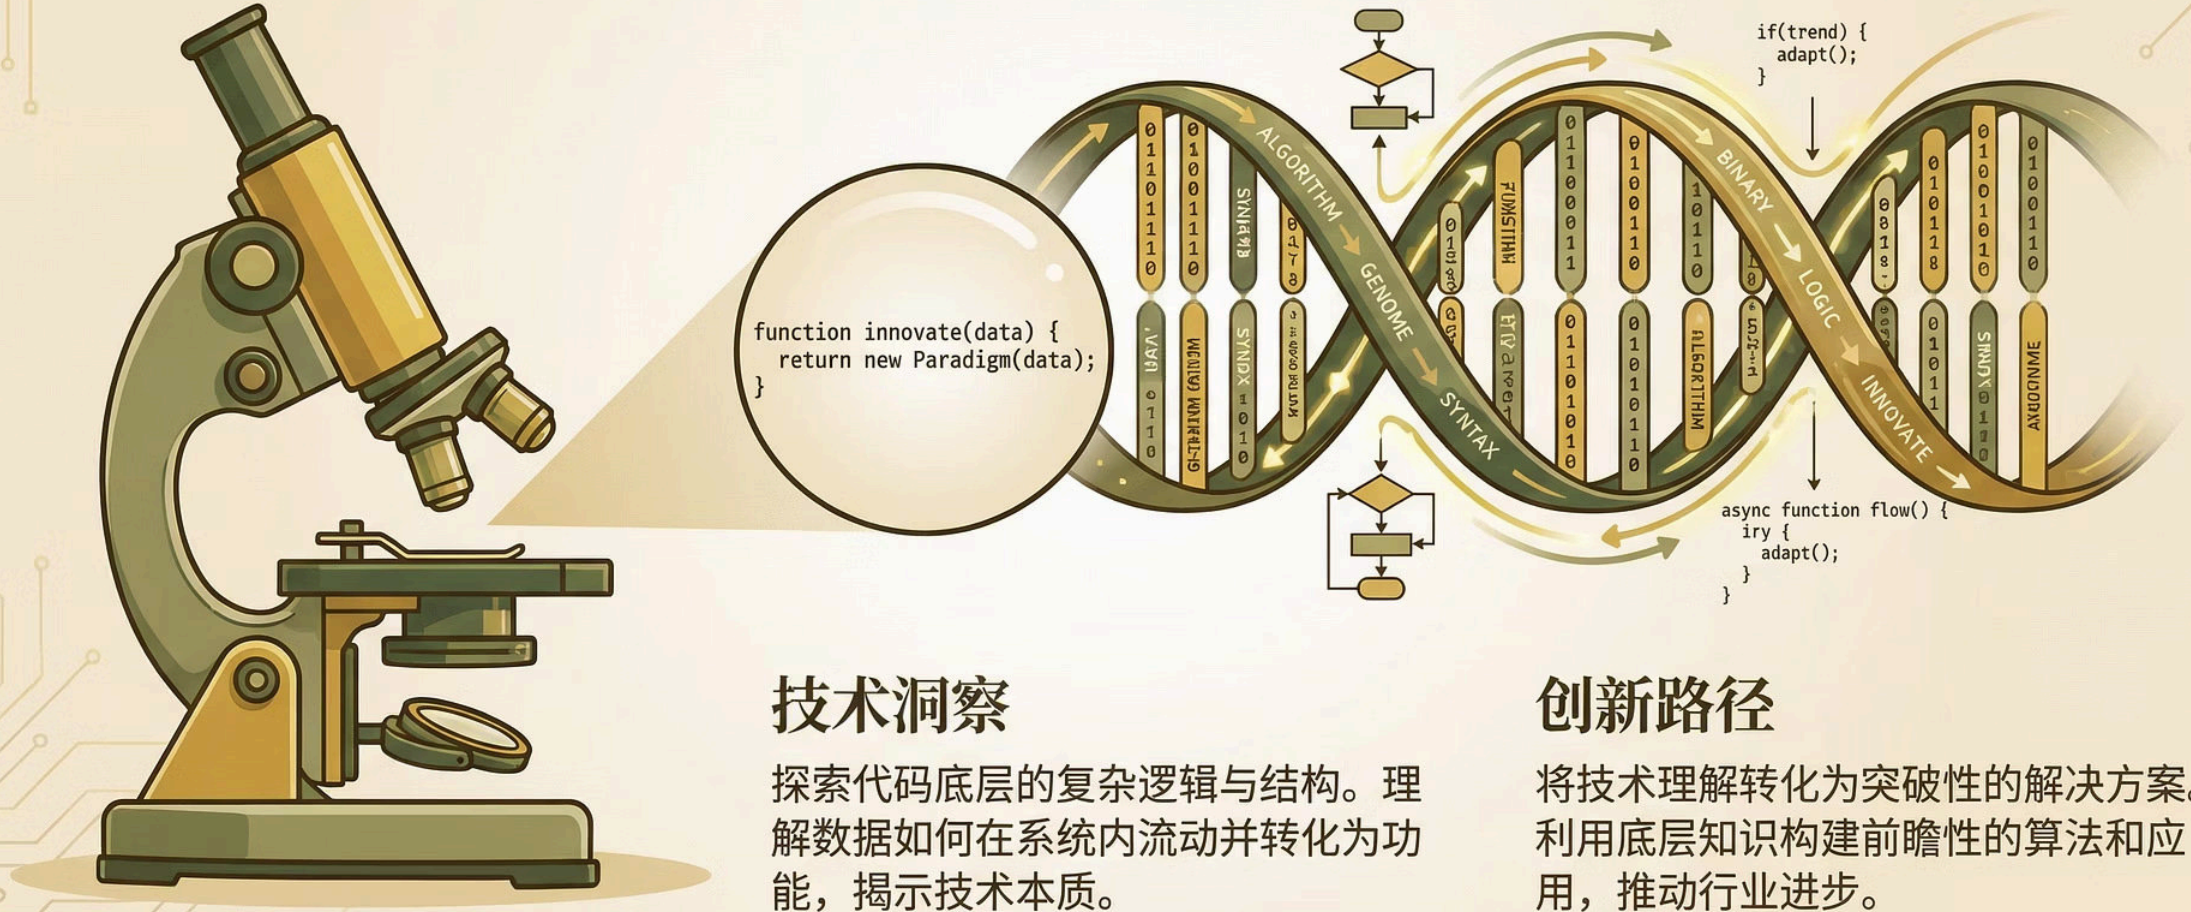


提升中国在国际开源社区的话语权

促进技术贡献，参与规则制定，深化合作交流。
建立信任，扩大影响力，共享全球创新成果。



深入技术肌理：创新的前提



技术洞察

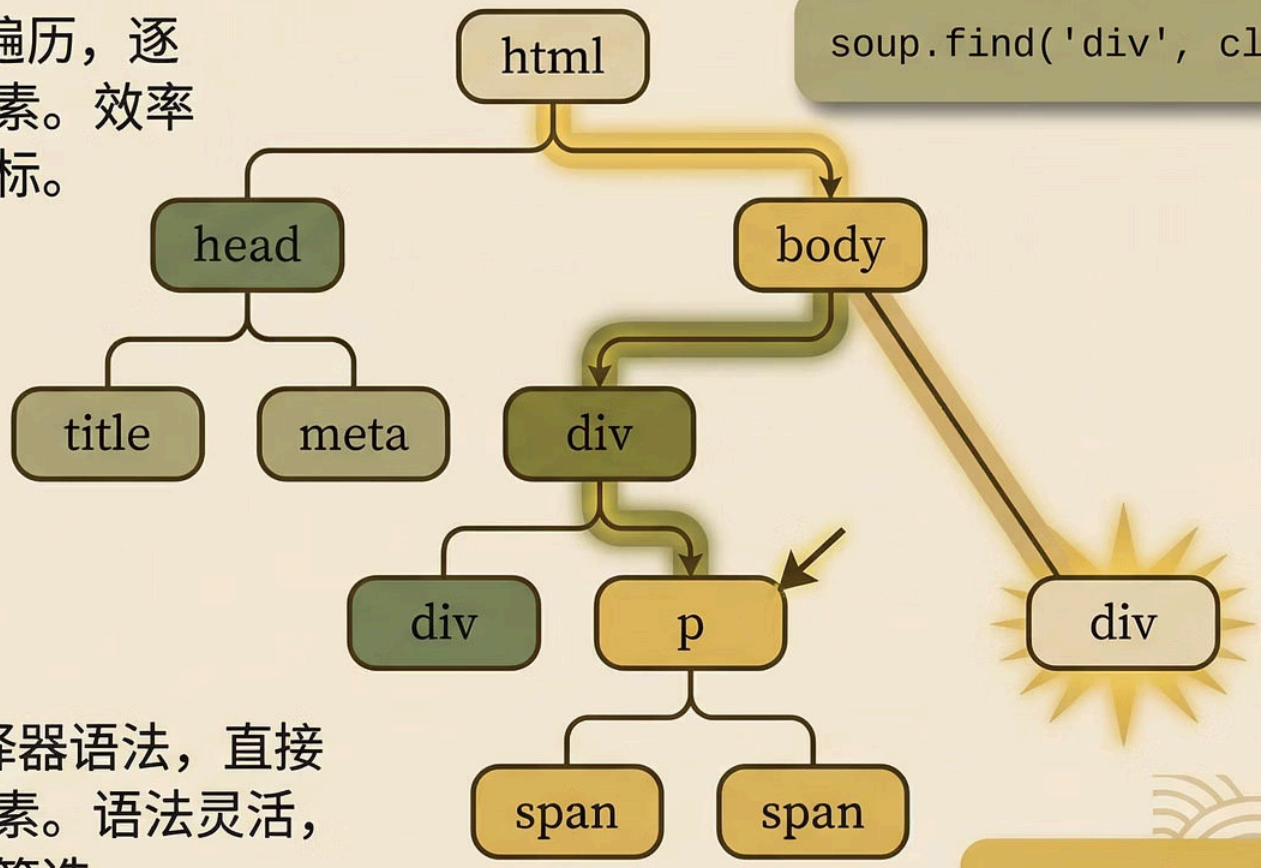
探索代码底层的复杂逻辑与结构。理解数据如何在系统内流动并转化为功能，揭示技术本质。

创新路径

将技术理解转化为突破性的解决方案。利用底层知识构建前瞻性的算法和应用，推动行业进步。

Beautiful Soup核心机制深度解析

find()方法：深度优先遍历，逐层搜索匹配的第一个元素。效率较高，适合查找单个目标。




```
soup.find('div', class_='content')
```

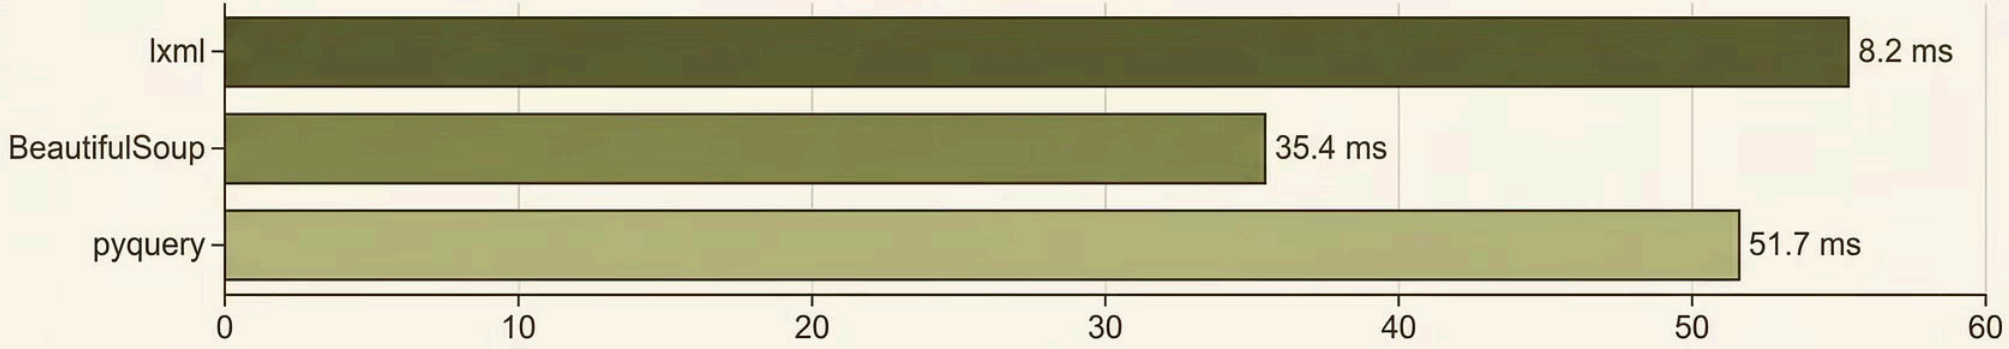
select()方法：CSS选择器语法，直接定位符合条件的所有元素。语法灵活，适合复杂查询和多目标筛选。

```
soup.select('div.content')
```

多库对比：算法逻辑的深度剖析

本幻灯片全面对比了 lxml，BeautifulSoup 和 pyquery 三种主流 Python 解析库在速度和易用性上的差异，通过精确的数据和代码实例展示各自的优势。

解析速度对比（毫秒）




```c
from lxml import etree
html = "<html><body><div>Data</div>
</body></html>"
tree = etree.HTML(html)
data = tree.xpath('//div/text()')[0]
```

C加速

```c
from bs4 import BeautifulSoup
html = "<html><body><div>Data</div>
</body></html>"
soup = BeautifulSoup(html, 'html.parser')
data = soup.find('div').text
```

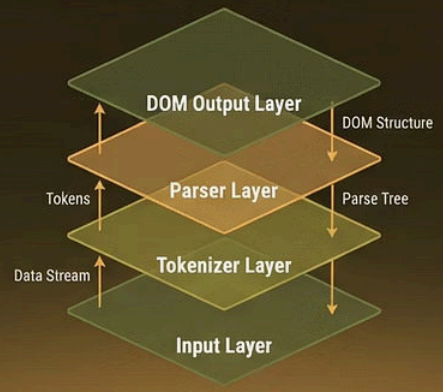
易用性

```c
from pyquery import PyQuery as pq
html = "<html><body><div>Data</div>
</body></html>"
doc = pq(html)
data = doc('div').text()
```

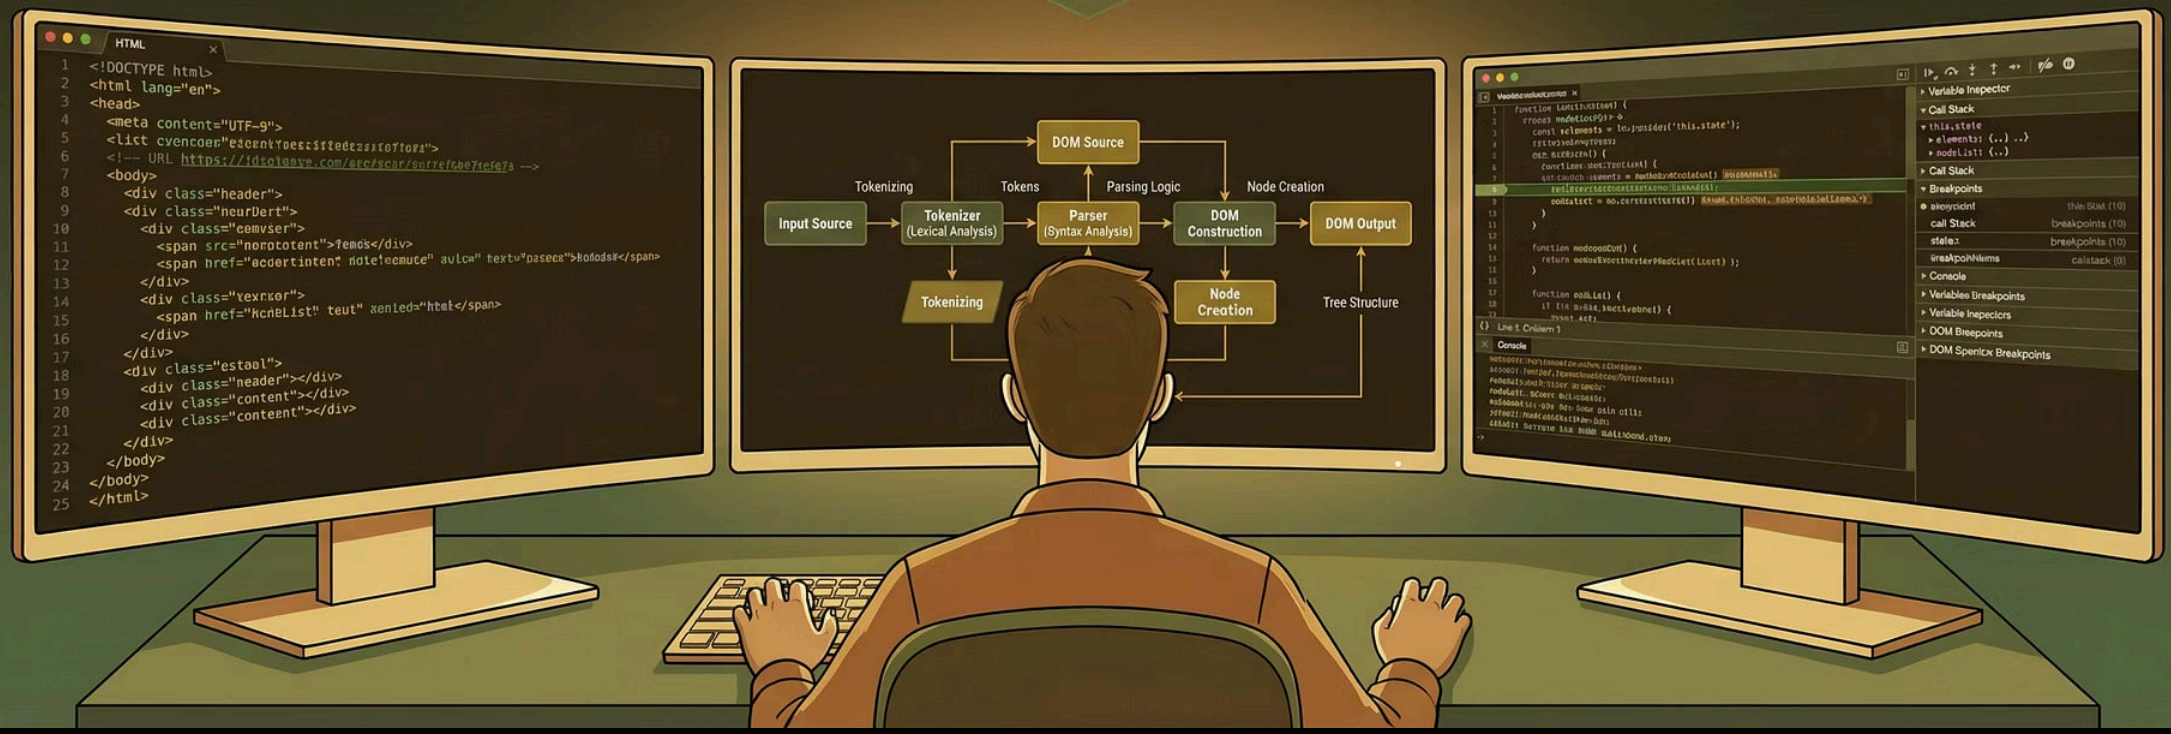
jQuery风格

源码阅读：从表象到本质的技术洞察

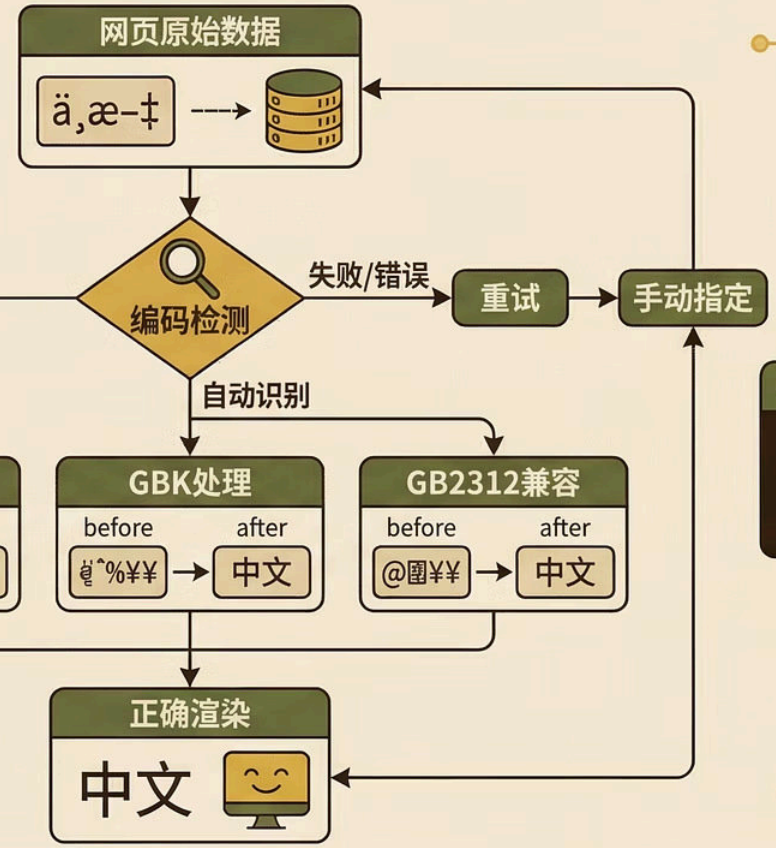
理解技术实现的底层逻辑，不仅是阅读代码表象，更是洞察其设计思想和核心算法。通过调试和分析，我们将深入解析代码背后的数据流转与结构构建过程。



从HTML源码到DOM树的构建，是一个复杂而精妙的解析之旅。我们将剖析词法分析、语法分析以及最终的DOM生成，揭示浏览器如何理解网页内容，从而掌握技术本质。



中文网页特殊挑战的技术攻克



chardet 使用

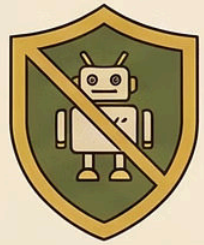
```
import chardet;

raw_data = b'\x...';
result = chardet.detect(raw_data);
print(result['encoding'])
```

编码声明示例

```
<meta charset="UTF-8">
Content-Type: text/html;
charset=GBK
```

技术挑战：不同编码标准（UTF-8，GBK，GB2312）共存导致显示乱码。编码错误可阻止内容索引与分析。需精确识别与转换。



解决方案：多层次编码检测，chardet库辅助，智能识别常见错误。实施严格的编码声明策略，确保数据一致性。

反爬虫：动态请求头，频率限制，IP轮询，模拟用户行为。

技术自主创新的未来图景

