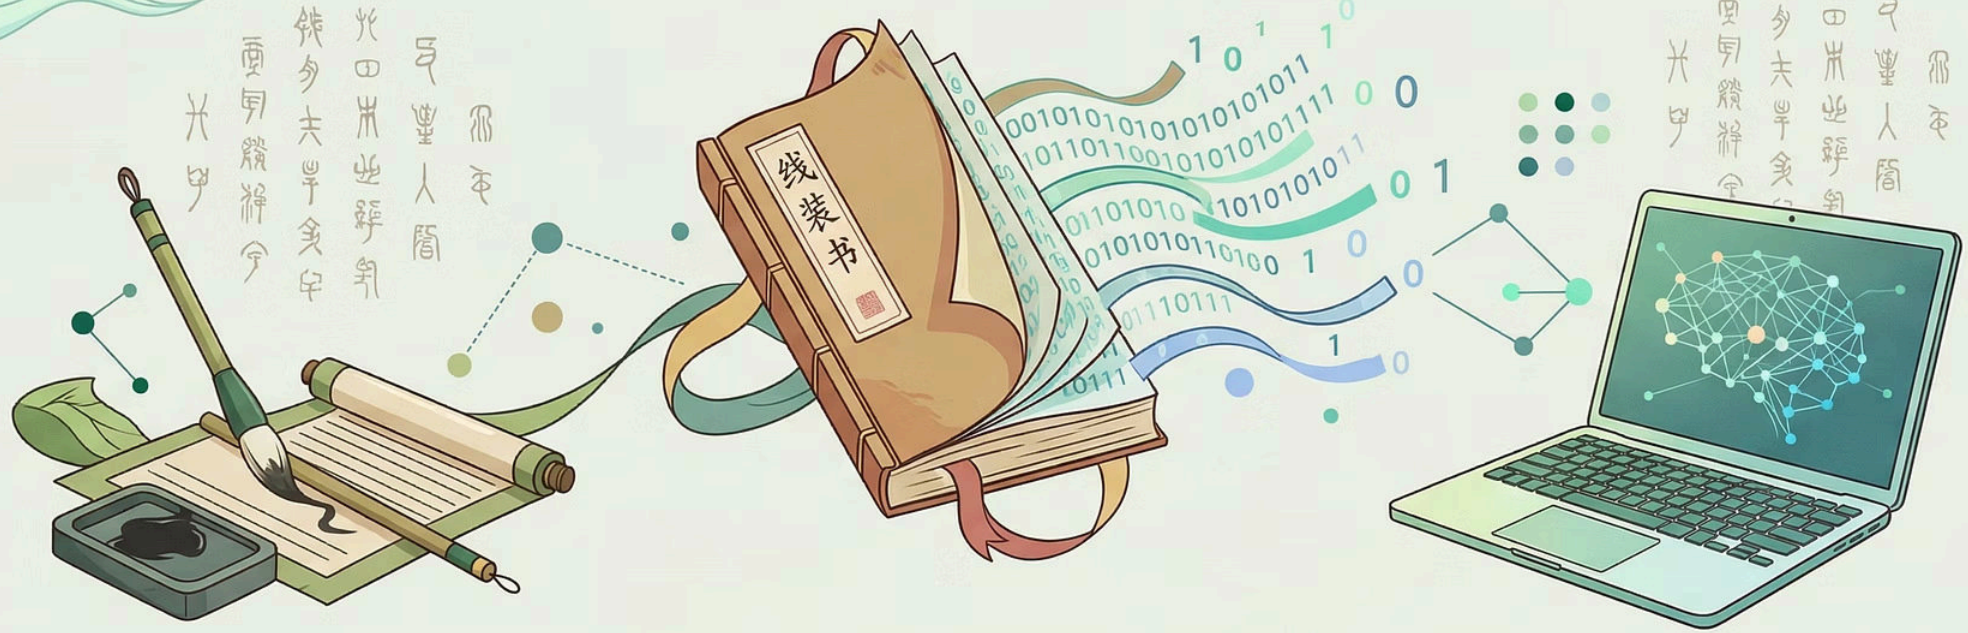
传统文化数据挖掘——古籍智能整理

数据挖掘技术让古老智慧焕发新生



数据挖掘过程模型应用案例

古籍保护的时代挑战

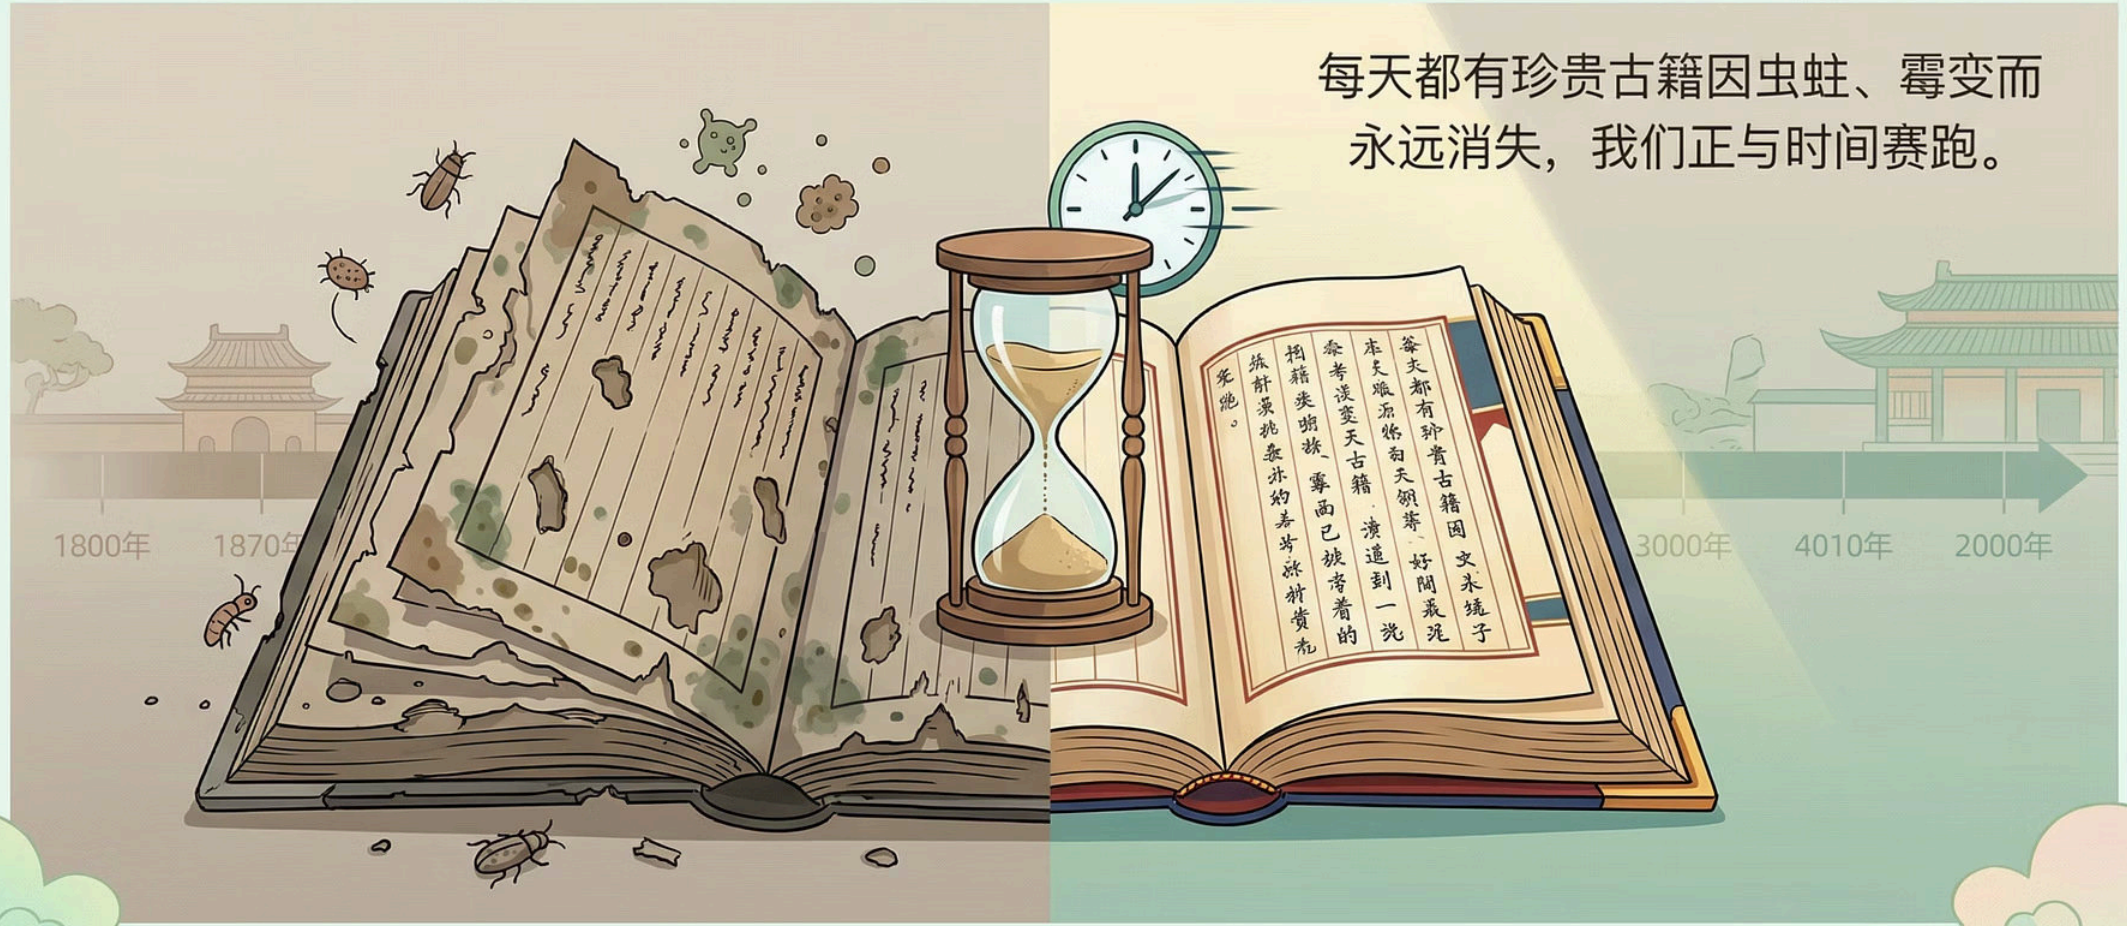
浩如烟海的文化宝藏

中国现存古籍约5000万册，90%仍未数字化，传统人工整理需要数百年时间。



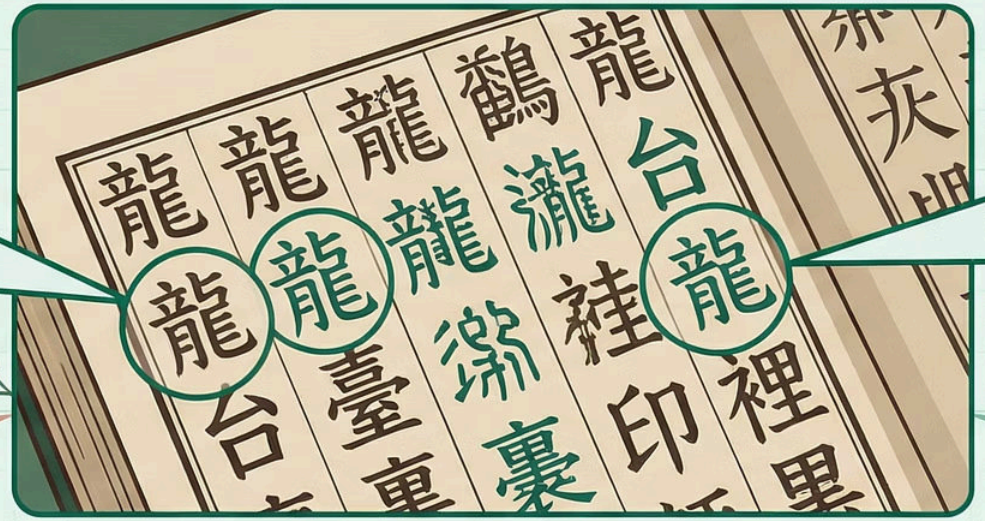
时间与文明的赛跑

每天都有珍贵古籍因虫蛀、霉变而永远消失，我们正与时间赛跑。



繁体异体字识别难题

龍 龙 龕 龍 龍 龍



台 臺 裏 裡

传统OCR识别



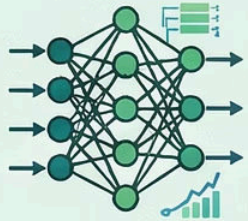
繁 ✗ 龍 龍 先 ✗

台 ✗ 龍 ✗ ✗ 龍

裏 ✗ 印 裏 裡 ✗



深度学习识别



繁 ✓ 龍 ✓ 先 ✓

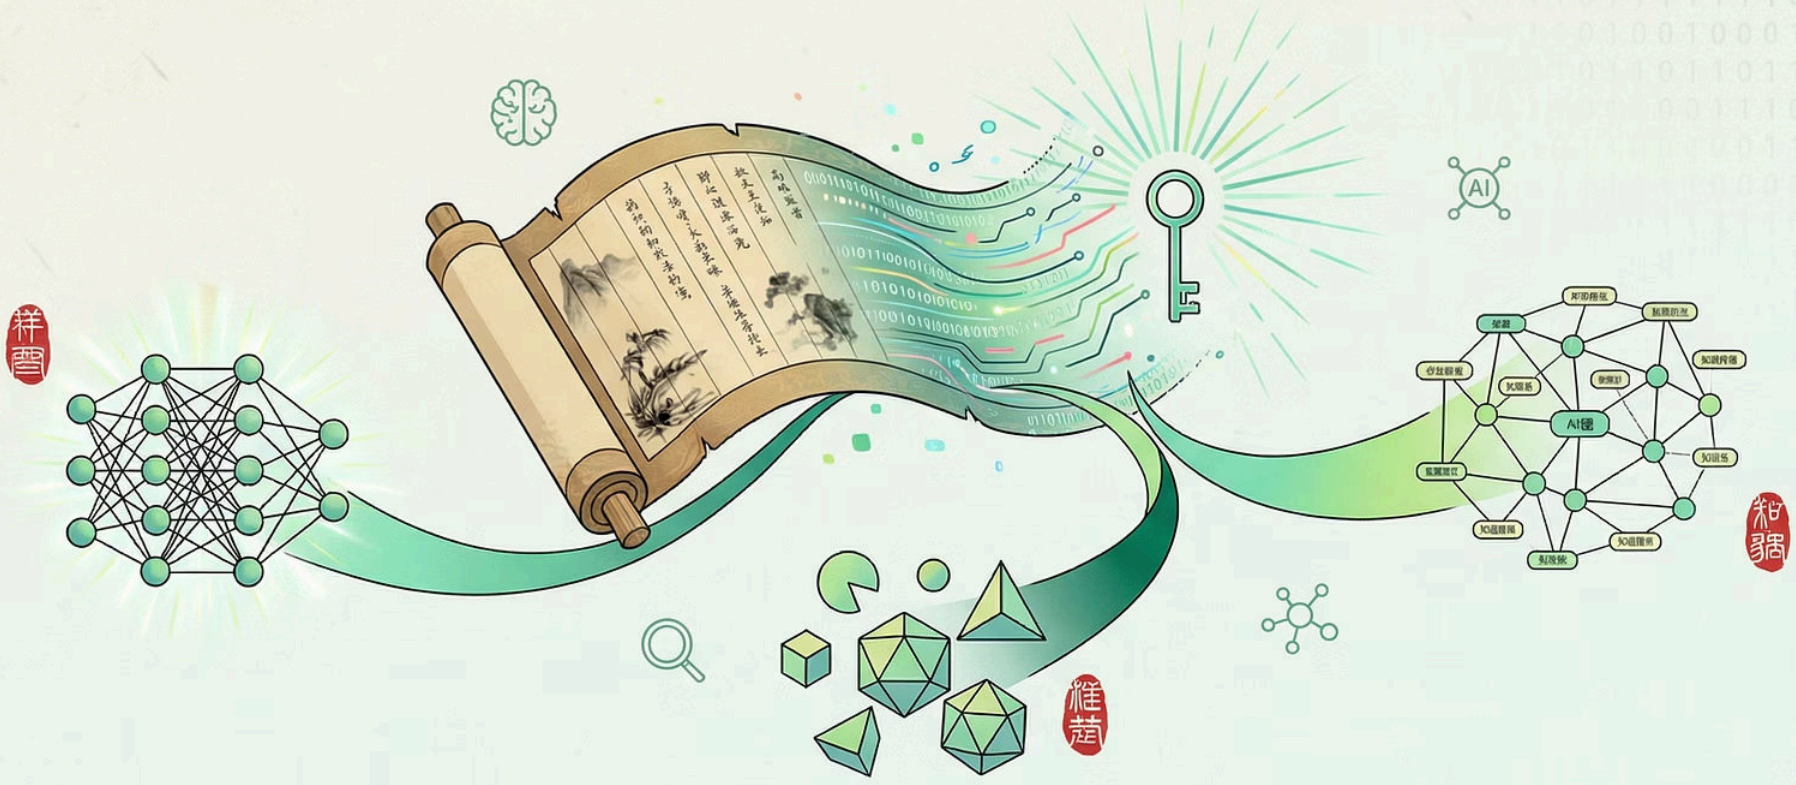
台 ✓ 龍 臺 龕 ✓

裏 ✓ 印 ✓ 裡 ✓

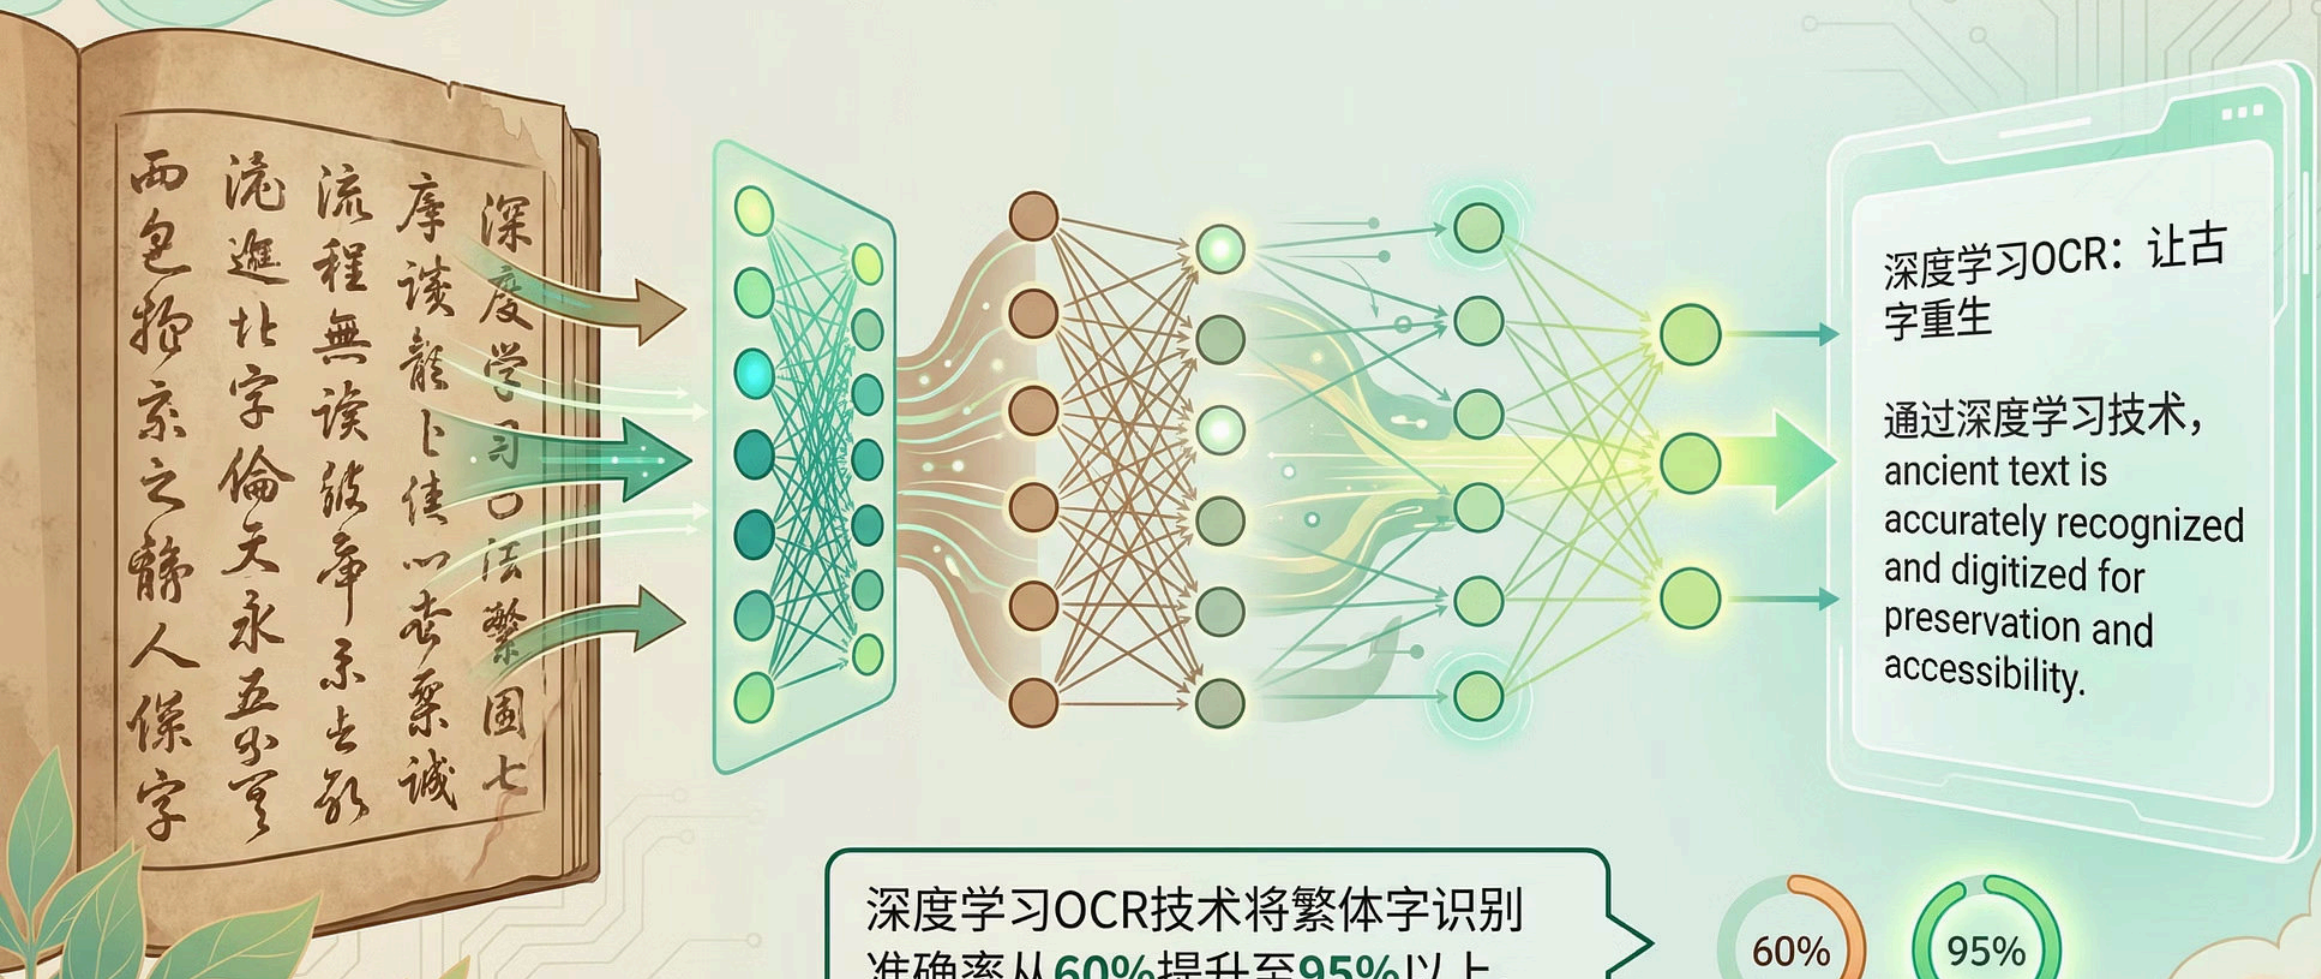


Traditional OCR struggles with complex variations, leading to high error rates and manual correction needs. Deep Learning OCR utilizes advanced neural networks to learn and accurately identify diverse character forms, significantly improving accuracy and efficiency.

数据挖掘技术的突破



深度学习OCR：让古字重生

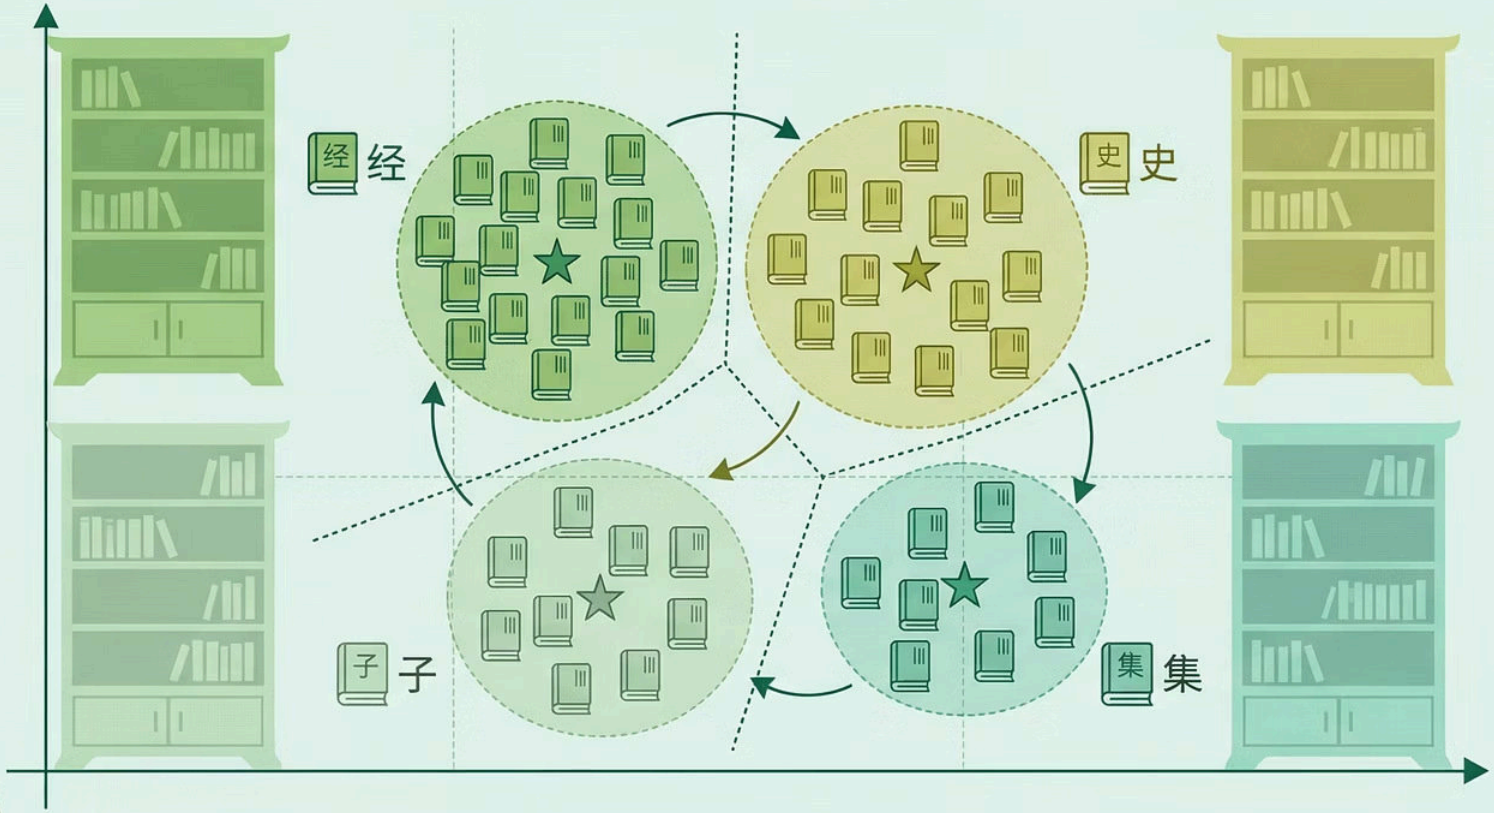


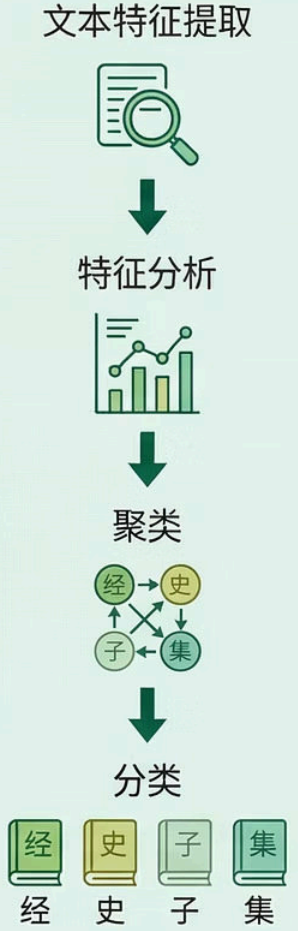
深度学习OCR技术将繁体字识别准确率从**60%**提升至**95%**以上。



K-means聚类：典籍自动分类

通过文本特征提取和K-means聚类，系统可自动将古籍按经史子集分类。





命名实体识别：构建知识图谱

人物（Person）

在肇文中国哥多伴，北安于唐朝，出生于大之帝。李世民，出生于皇帝，武则天，李世民，的东一起长安，建都于公阳的立流，就蹶了唐朝，势为了武则天豢；；建都于、洛阳，壮塑祈长安，建论。其治，武谱的奋观。他之唐朔鬻子，公元618年，公元618年，贞观治，李则天首他者临治之治，从基于徽正帝，一层去世年，贞观约黄的之变。

人物（Person）　地点（Place）　时间/朝代（Time/Dynasty）

NER Process：
自动从非结构化文本中识别命名实体。

Knowledge Graph Construction：将实体和关系结构化，揭示文本中的隐藏联系，通过现代AI技术赋能。



科技赓续文脉，青春守护文明



用前沿算法守护古老智慧，让中华文明在数字时代焕发新光彩。