

多线程爬虫：技术与法律的双刃剑

多线程爬虫技术教学中的法律规范与工程伦理

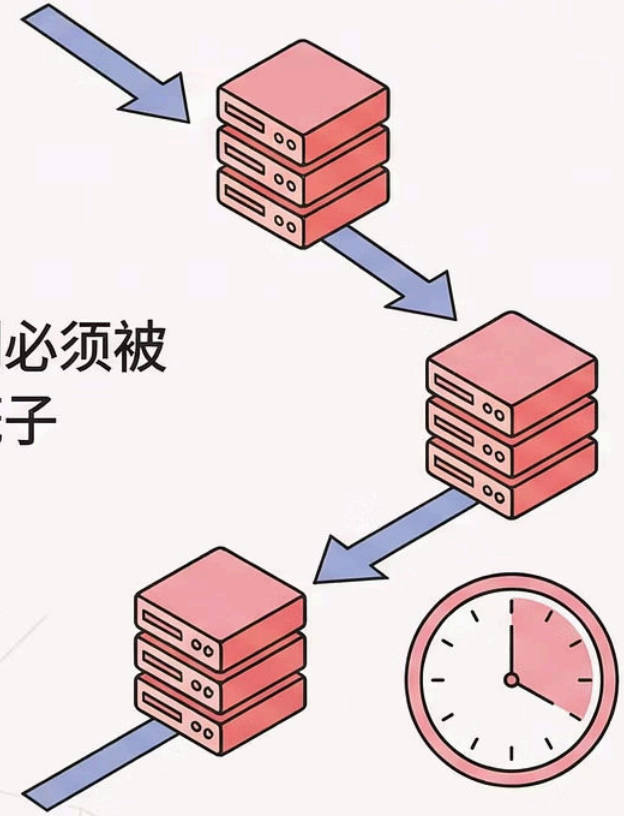
效率的诱惑与法律的警钟

当技术突破遇见法律边界

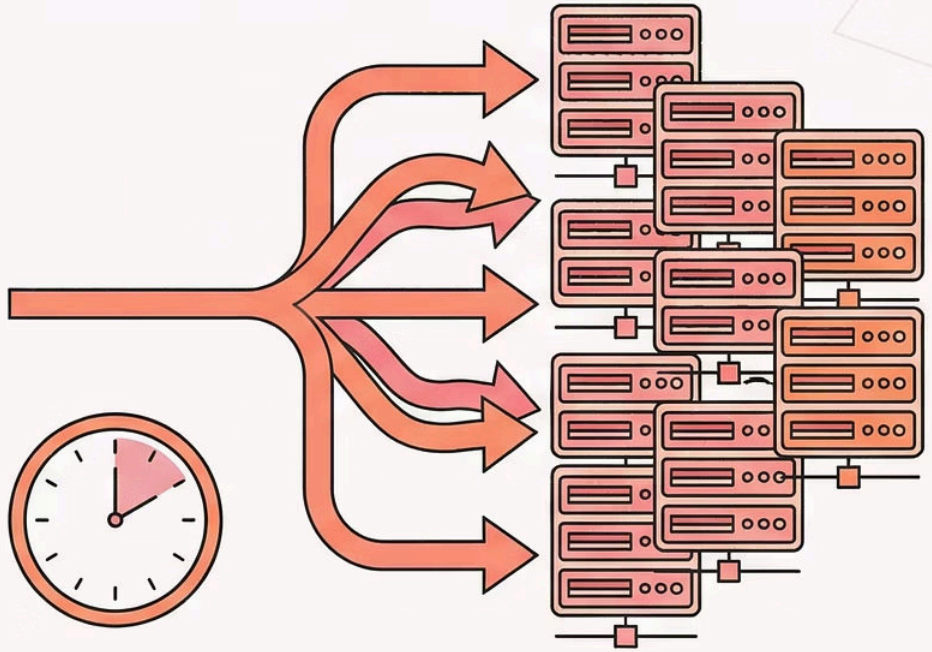


百倍效率的诱惑

但这把双刃剑必须被
关进法治的笼子



多线程爬虫能够将数据采集效率提升百倍，这种巨大的性能优势令人着迷





技术可行 ≠ 法律可为

技术上的



≠



今日头条 vs 趣头条：不正当竞争的警示

今日头条诉趣头条案件成为行业标杆性判例

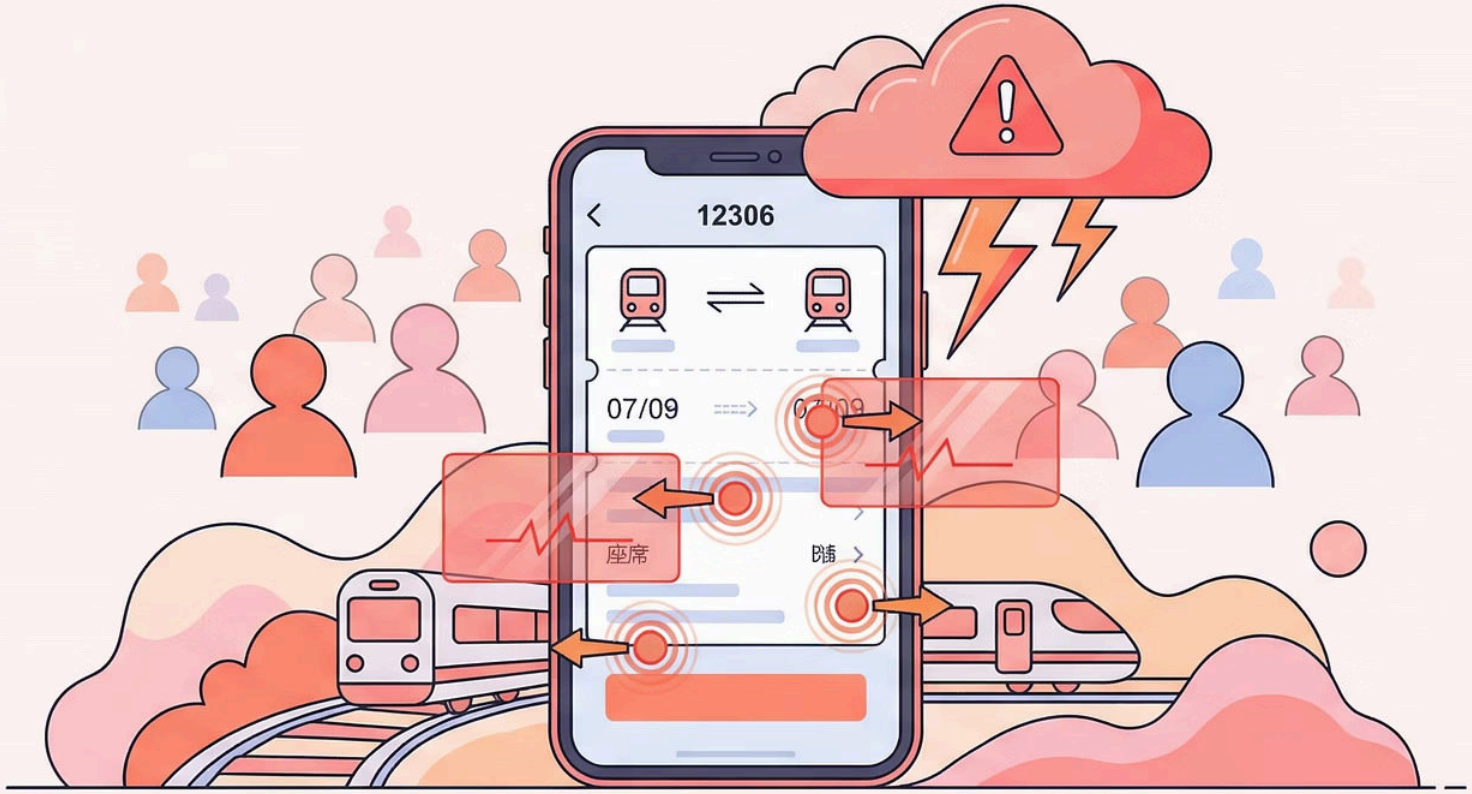
恶意爬取竞争对手数据构成不正当竞争争行为

法院判决赔偿金额高达数百万元



12306抢票插件的监管风暴

春运期间，抢票插件引发的监管风暴席卷全网



技术手段干扰正常购票秩序被严厉打击

法律底线与合规原则

技术创新的法律框架



《反不正当竞争法》的严格约束



禁止通过技术手段获取竞争对手的商业秘密或用户数据

违法者面临行政处罚和民事赔偿的双重风险

最高可处以违法所得五倍的罚款

《网络安全法》的数据保护要求

网络运营者收集、使用个人信息应当遵循合法、正当、必要的原则

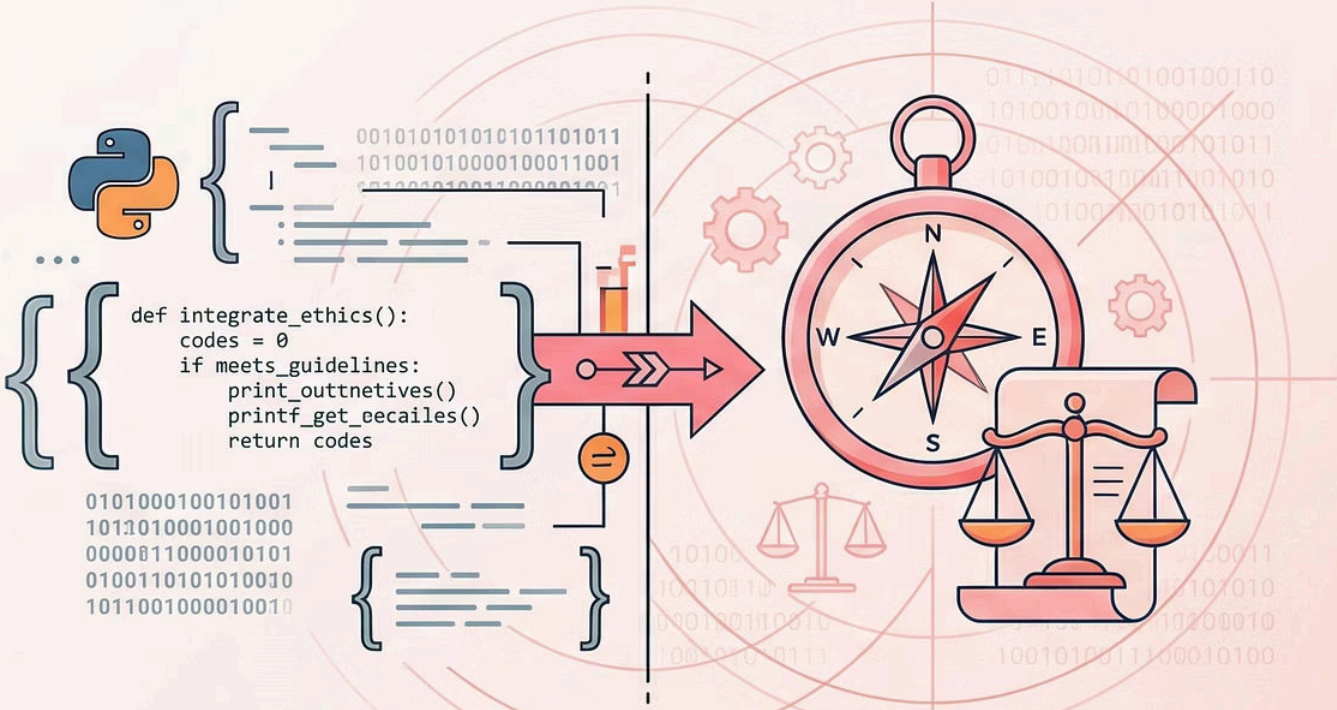


违法收集个人信息最高可处一百万元罚款

数据安全已上升至国家安全层面

技术实现的伦理约束

技术能力与道德责任的平衡



Python GIL：技术特性与局限

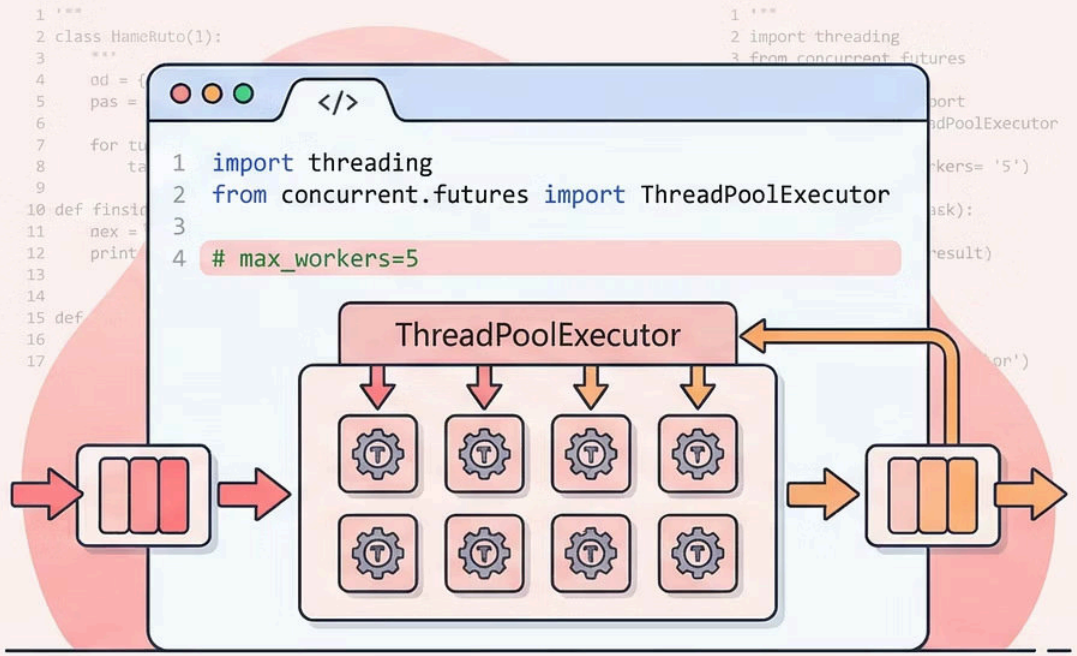
全局解释器锁(GIL)限制了Python多线程的真正并行执行

理解GIL特性是优化多线程爬虫的技术基础



I/O密集型任务仍能从多线程中获益显著

threading模块的正确使用

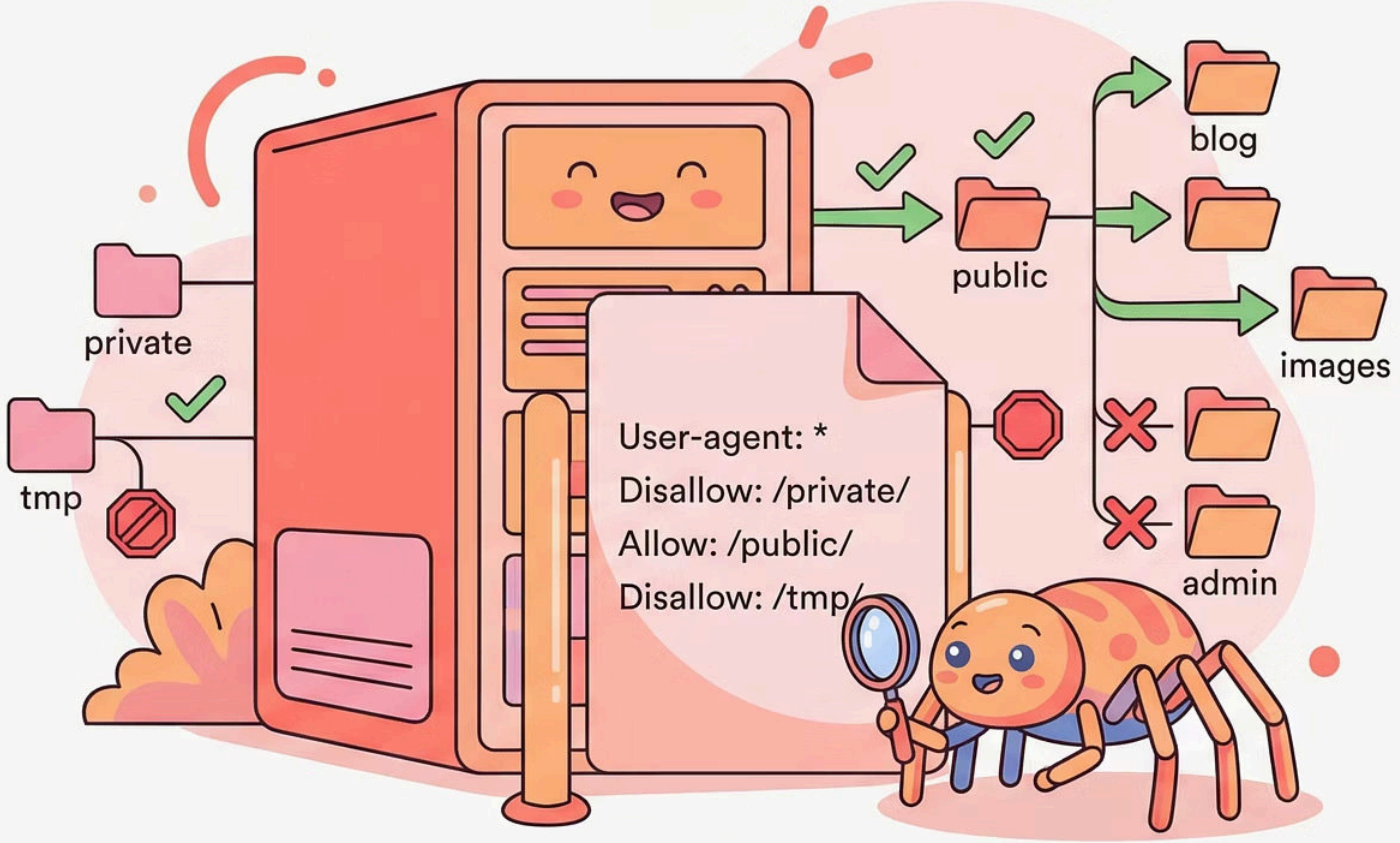


threading模块提供了线程创建和管理的标准接口

线程池ThreadPoolExecutor能够有效控制并发数量

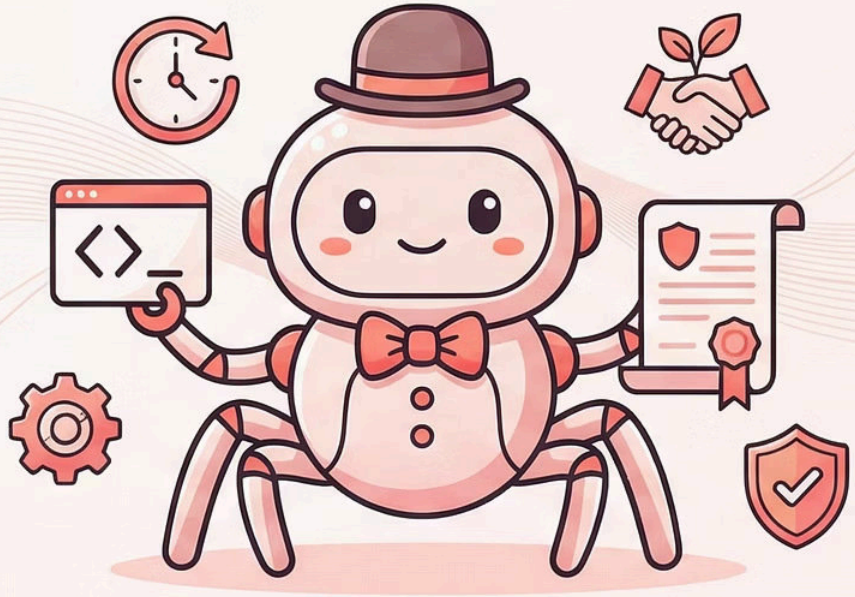
合理设置max_workers参数避免资源过度消耗

robots.txt：网站的

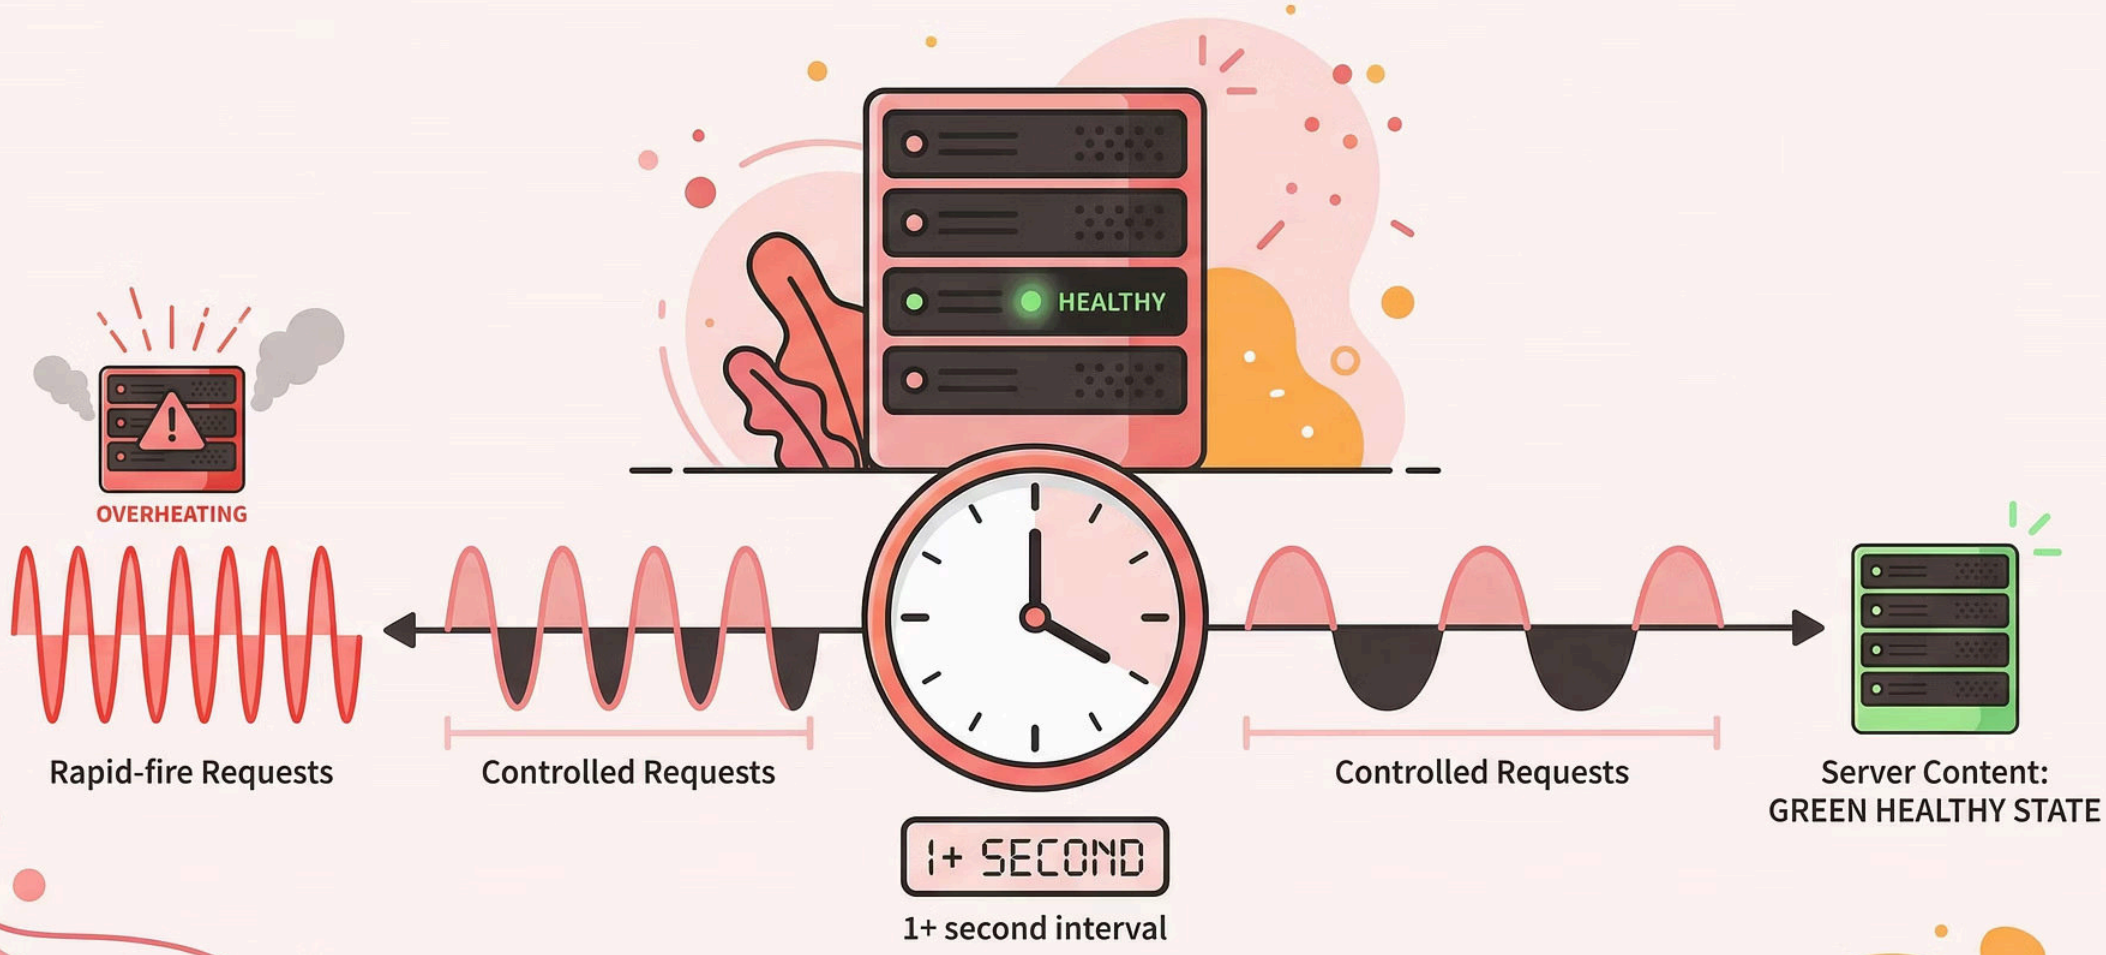


文明爬虫的实践规范

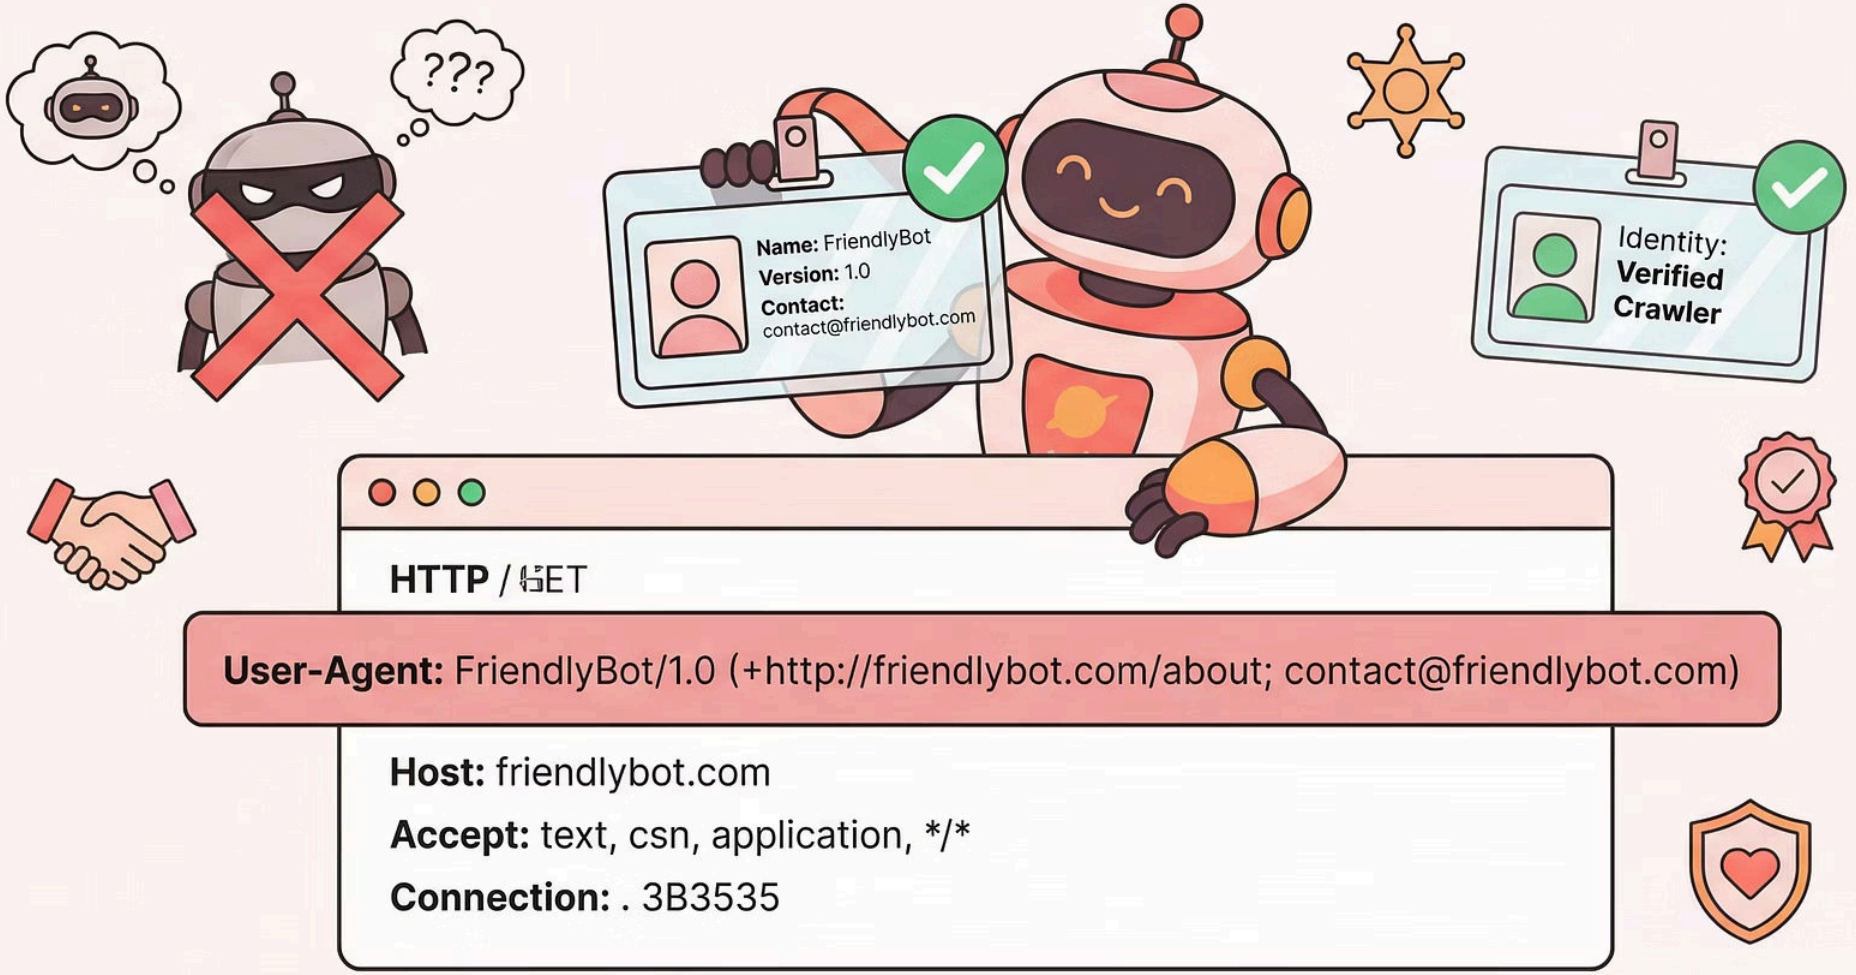
技术能力与社会责任的统一



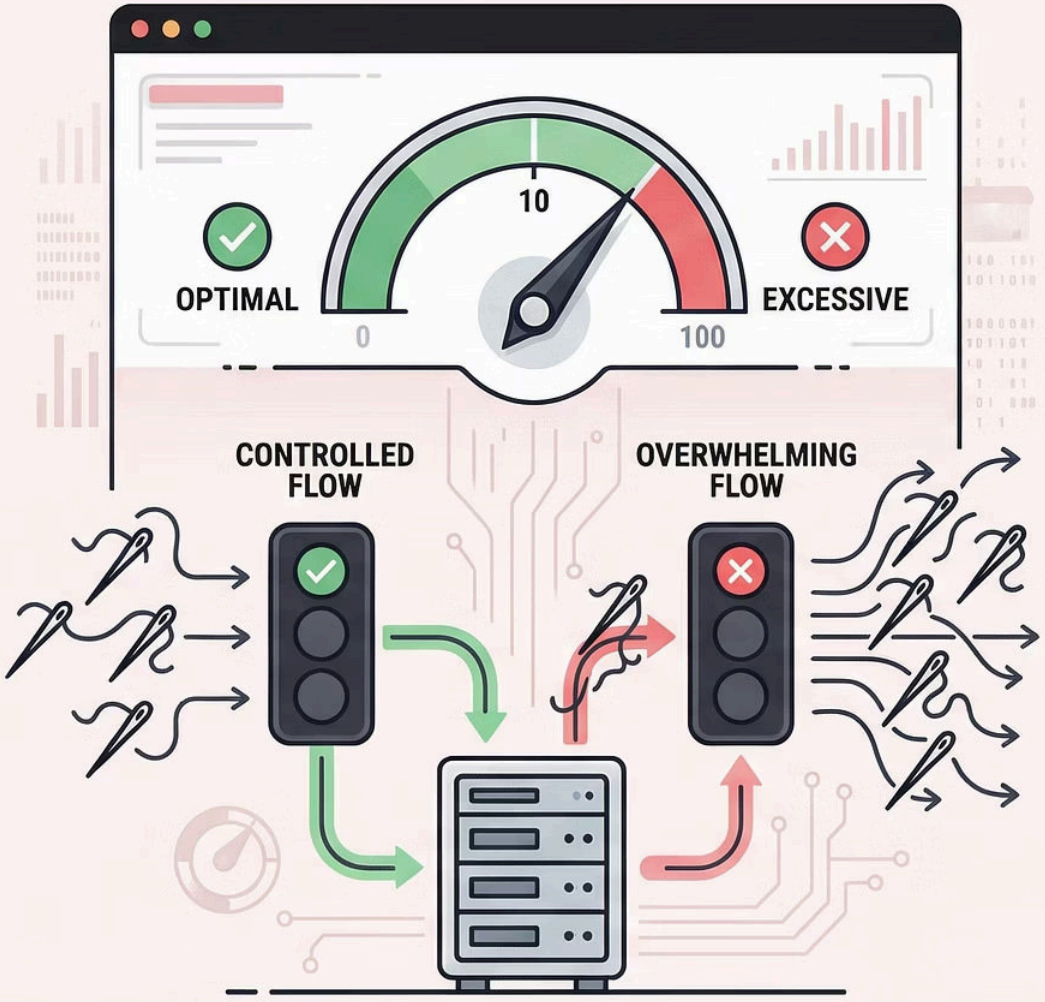
请求间隔：服务器的


HEALTHY
OVERHEATING
Rapid-fire Requests
Controlled Requests
1+ SECOND
1+ second interval
Controled Requests
Server Content:
GREEN HEALTHY STATE

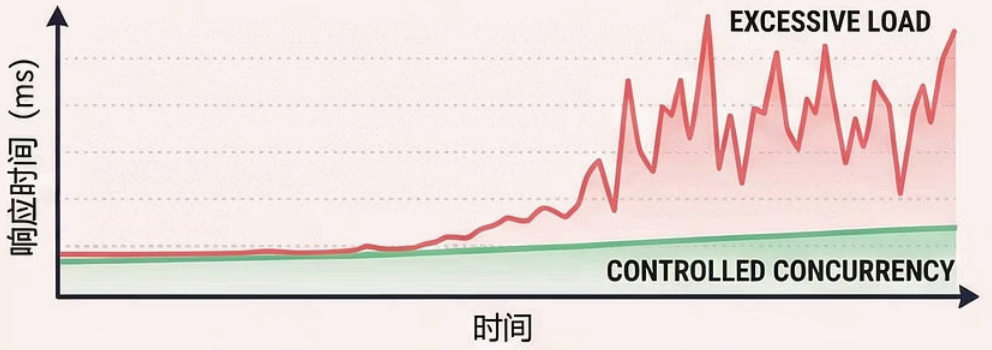
User-Agent：爬虫的



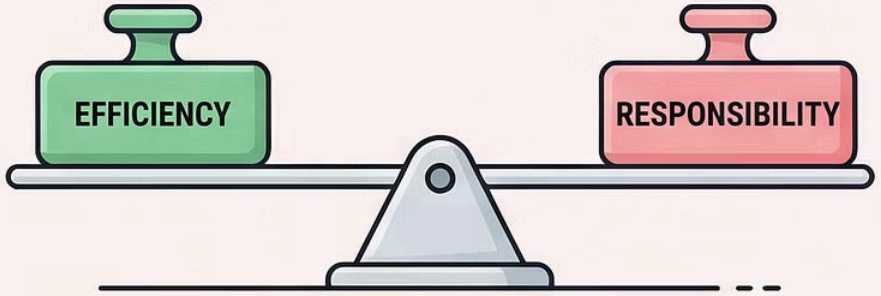
并发控制：平衡效率与责任



控制并发线程数量，避免对目标网站造成DDoS效果



监控网站响应时间，动态调整爬取策略



技术能力越大，社会责任越大

技术向善：爬虫工程师的使命

掌握技术是起点，善用技术是终点

培养既懂得如何爬取数据，又深知为何而爬取、如何负责任地利用数据的工程师，才是技术教育的核心。

技术向善，共创数字未来。

